



桂林电子科技大学

GUILIN UNIVERSITY OF ELECTRONIC TECHNOLOGY

本科毕业设计（论文）

题目： 基于 RAG 的“三高”慢性病医学问答系统设
计与实现

学	号:	2200820924
姓	名:	牛嘉贺
学	院:	计算机与信息安全学院
专	业:	计算机科学与技术
指 导 教 师:		李优
指导教师职称:		教授

2026 年 5 月 7 日

本科生毕业设计（论文）独创性声明

本人声明所呈交的毕业设计（论文）是我个人在指导老师指导下进行的工作及取得的成果。尽我所知，除了文中特别加以标注和致谢中所罗列的内容以外，文中不包含其他人或其它机构已经发表或撰写过的成果；也不包含为获得桂林电子科技大学或其他教育机构的学位或证书而使用过的材料。其他同志对本工作的启发和所做的任何贡献均已在毕业设计（论文）中做了明确的说明并表示了谢意。

毕业设计（论文）若有不实之处，本人承担一切相关责任。

本人签名：

日期：

本科生毕业设计（论文）使用授权说明

桂林电子科技大学有权保留并向国家有关部门或机构送交毕业设计说明书（论文）的复印件，允许毕业设计（论文）被查阅和借阅。本人授权桂林电子科技大学可以公布毕业设计（论文）的全部或部分内容，可以采用影印、缩印或其它复制手段保存、汇编毕业设计（论文）。

作者签名：

日期：

导师签名：

日期：

摘 要

近年来，人口老龄化问题不断加深，慢性病人规模持续扩大，关于慢性病的相关健康咨询需求不断增加；然而，传统线下问诊在便利性和及时性方面存在一定限制，难以满足用户日常持续性的健康信息获取需求。与此同时，大语言模型在自然语言理解和生成任务中展现出了较强的能力，为智能问答系统在医疗健康领域的应用提供了新的技术路径。

但是，在医学等高风险应用场景中，大语言模型仍存在一定局限，例如会产生事实性错误（幻觉）、安全性约束不足以及专业知识的理解不足。因此，有必要结合外部知识与模型优化方法，对模型进行优化，以提升其在医学场景中的安全性与可靠性。

针对上述问题，本文围绕“三高”慢性病的咨询场景，设计并实现基于检索增强生成的医学问答系统。本文通过国家政策、学术期刊和医学指南等可靠来源搜集相关资料，构建医学知识库，并结合语义检索和关键词检索精准匹配医学文档，从而为大语言模型提供外部知识支撑。针对模型安全性约束不足等问题，本文引入人类偏好优化方法，通过偏好数据对模型进行微调，使其生成内容更符合医学场景下的安全性和规范性要求。在此基础上，本文完成了医学问答系统的整体设计与实现，实现了从知识构建、检索增强到模型生成的完整问答流程。

实验结果表明，混合检索在召回覆盖率上优于单一路径检索，Recall@5 召回率达到 89%；同时，基于 DPO 优化后的模型在盲评中相较于基础模型取得 59.2% 的胜率，优化后的模型在事实一致性和完备性上均优于基础模型。

关键词：检索增强生成；大语言模型；混合检索；直接偏好优化；医学问答系统

Abstract

In recent years, the problem of population aging has been deepening, the scale of people with chronic diseases has been expanding, and the demand for health consultation about chronic diseases has been increasing. However, the traditional offline consultation has some limitations in convenience and timeliness, and it is difficult to meet the daily and continuous health information acquisition needs of users. At the same time, the large language model shows strong ability in the task of natural language understanding and generation, which provides a new technical path for the application of intelligent question answering system in the medical and health field.

However, in high-risk application scenarios such as medicine, the big language model still has some limitations, such as factual errors (hallucinations), insufficient security constraints and insufficient understanding of professional knowledge. Therefore, it is necessary to combine external knowledge and model optimization methods to optimize the model to improve its safety and reliability in medical scenes.

In order to solve the above problems, this paper designs and implements a medical question answering system based on retrieval enhancement generation around the consultation scene of "three high" chronic diseases. The system collects relevant information from reliable sources such as national policies, academic journals and medical guides, constructs a medical knowledge base, and combines semantic retrieval and keyword retrieval to accurately match medical documents, thus providing external knowledge support for the large language model. In order to solve the problem of insufficient security constraints of the model, this paper introduces human preference optimization method, and fine-tunes the model through preference data to make its generated content more in line with the safety and normative requirements in medical scenes. On this basis, this paper completed the overall design and implementation of the medical question answering system, and realized the complete question answering process from knowledge construction, retrieval enhancement to model generation.

The experimental results show that hybrid retrieval is superior to single-path retrieval in recall coverage, and the recall rate of Recall@5 reaches 89%. At the same time, compared with the basic model, the optimized model based on DPO achieved a winning rate of 59.2% in blind evaluation, and the optimized model was superior to the basic model in fact consistency and completeness.

Keywords: Retrieval-Augmented Generation; Large Language Model; Hybrid Retrieval; Direct Preference Optimization; Medical Question Answering System

目 录

1 绪论	1
1.1 课题的研究背景与意义	1
1.2 国内外研究现状	1
1.2.1 互联网问诊的发展现状	1
1.2.2 传统医学问答模型的发展现状	2
1.3 本文研究内容	3
2 相关理论和技术介绍	4
2.1 大语言模型概述	4
2.1.1 Transformer 模型	4
2.1.2 现代大模型	5
2.1.3 模型训练技术	6
2.2 检索增强生成（RAG）技术	7
2.3 本章小结	8
3 医学知识库构建与检索方法	9
3.1 医学知识库构建方法	9
3.1.1 数据来源	9
3.1.2 数据预处理	9
3.1.3 文本语义切分	9
3.1.4 Embedding 向量化表示	11
3.1.5 向量数据库构建	11
3.2 医学文本检索方法	11
3.2.1 BM25 关键词检索	11
3.2.2 向量检索	12
3.2.3 混合检索策略	12
3.3 实验与结果分析	13
3.4 本章小结	14
4 医学问答模型构建与优化	15
4.1 RAG 问答生成方法	15
4.1.1 检索增强生成流程	15

4.1.2 Prompt 与上下文构建	15
4.2 基于 DPO 的模型优化策略	17
4.2.1 偏好数据构建	17
4.2.2 DPO 训练流程	17
4.3 实验结果分析	18
4.3.1 DPO 训练过程及分析	18
4.3.2 回答质量评测结果	19
4.4 本章小结	21
5 系统设计与实现	22
5.1 系统需求分析	22
5.1.1 功能需求	22
5.1.2 非功能需求	22
5.2 开发技术选择	23
5.3 系统总体架构	24
5.4 系统流程设计	25
5.5 业务层实现	26
5.5.1 后端服务架构设计	26
5.5.2 用户身份认证	26
5.5.3 会话管理	27
5.5.4 消息流式转发	27
5.5.5 知识库管理接口	27
5.6 数据库设计	28
5.7 模型推理服务实现	29
5.7.1 模型服务功能设计	29
5.7.2 模型加载与推理组织	29
5.7.3 接口设计与结果返回	30
5.7.4 检索链路调度	30
5.7.5 证据封装与结果回传	30
5.8 前端实现	31
5.8.1 登录与注册页面	31
5.8.2 问答主页	31
5.8.3 知识库管理页面	32

5.9 本章小结 33

6 总结与展望 34

6.1 总结 34

6.2 展望 35

参考文献..... 36

谢辞..... 38

1 绪论

1.1 课题的研究背景与意义

随着人口老龄化不断加深，慢性病管理已成为公共健康领域的长期议题。在常见慢性病中，高血压、高血糖和高血脂患者数量大、管理周期长、复发风险高，患者往往不能只依赖少数几次门诊完成健康管理。与急性疾病不同，慢性病管理更强调日常监测和持续干预，患者在真实生活中会频繁遇到诸如指标是否异常、饮食如何调整、药物需不需要复查、症状是否需要就医等具体问题^[1]。这类问题看似琐碎，却直接影响持续治疗情况和病情控制效果。

传统医疗服务以线下诊疗为主，患者通常只有感到身体不适或按固定的时间安排才会选择就医，患者难以获得持续、及时的健康指导。同时，由于医疗资源分布不均以及医生数量相对有限，患者在非就诊期间获取专业医疗建议的渠道较为有限。所以很多患者选择去互联网搜索相关健康信息，但互联网上信息来源复杂、质量参差不齐，用户很难从中获得可靠的医学建议。

近年来，大语言模型（Large Language Model, LLM）发展很快，在理解和生成文本方面都有明显提升，通过大语言模型构建智能医疗问答系统成为可能。基于 LLM 的问答系统能够理解用户提出的问题，并生成相对流畅的回答，在医疗咨询等场景中展现出一定应用潜力。但是将通用 LLM 直接应用在医学领域时，会面临知识更新滞后、事实错误（幻觉）以及缺乏依据等问题^[2]。

基于这一背景，本文引入检索增强生成（Retrieval-Augmented Generation, RAG）技术，将外部医学知识库与大语言模型结合起来^[3]。其核心思路是在模型生成答案前先检索相关医学资料，根据资料组织回答，而不是单纯依靠模型的“记忆”作答。这样做的价值主要体现在三个方面：第一，可以降低医学问答中的幻觉风险；第二，可以让回答建立在可追溯的证据基础上；第三，更便于系统随知识更新而持续维护。因而，围绕“三高”慢病场景研究并实现一套基于 RAG 的医学问答系统，既具有现实应用意义，也具有一定的技术研究价值。

1.2 国内外研究现状

1.2.1 互联网问诊的发展现状

随着互联网技术和智能手机的普及，互联网问诊模式出现并迅速发展。根据中国互联网络信息中心第 56 次《中国互联网络发展状况统计报告》显示，截至 2025 年底，中国网民规模达 11.25 亿，互联网普及率突破 80%^[4]。互联网问诊依托其便捷高效、实时互动、及良好的隐私保护特性等优势，迅速普及，吸引了大量互联网企业、传统医疗机构及新兴在线医疗平台积极参与^[5]。目前，国内的互联网医疗代表性平台有微医、好大

夫在线、京东健康、平安健康和阿里健康等，其主要提供医生在线问诊、健康信息发布以及购药等服务。这些平台更多是作为传统线下医疗服务的补充形式，在一定程度上提升了患者获取医疗信息的便利性。不过，平台提供的信息质量参差不齐，不同来源之间可能存在内容差异，影响用户判断；在线问诊以人工问答为主，受限于有限的医疗资源，患者还是会面临回复不及时等问题。

国外的医疗平台则更侧重于远程医疗。例如，瑞典的 KRY 和美国 Teladoc Health、Doctor on Demand 等平台实行线上预约并利用会议视频实时问诊，让患者在家里即可享受到专业的医疗问诊^[6]。但这类服务仍有很多不足，首先是患者可能需要支出额外的费用，以享受远程问诊的服务；而且平台签约医生数量相对固定，高峰时段还需预约排队；如果涉及身体检查的情况，仍需要去线下医院就诊。

现阶段互联网问诊仍主要依赖人工医生答复，其服务能力、响应效率和服务成本都受到现实医疗资源的制约。在这一背景下，如何借助自然语言处理与智能问答技术，为用户提供更及时、更稳定的医学信息支持，逐渐成为医学人工智能研究的重要问题，因此也推动了医学问答模型的持续发展。

1.2.2 传统医学问答模型的发展现状

早期医学自然语言处理模型主要集中在医学术语识别、实体抽取和文献理解等任务上，代表性工作包括 BioBERT、BlueBERT、ClinicalBERT 和 PubMedBERT 等。这类模型大多建立在 BERT 框架之上，通过 PubMed 文献、临床记录或生物医学语料继续预训练，使模型在医学词汇和专业语义建模方面明显优于通用语言模型。其主要价值在于提升医学文本表示能力，为后续问答、分类和关系抽取等任务提供基础，但这类模型主要是以理解任务为主。

随着大模型技术的发展，医学问答研究进一步转向生成式模型。例如，由 Google 提出的 Med-PaLM 和 Med-PaLM 2 模型，Med-PaLM 系列模型是专门针对于医学领域的大语言模型，Med-PaLM 通过医学领域微调和人工评估，使其在医学考试题、患者咨询和临床推理任务中相较于通用大语言模型有更好的表现，Med-PaLM 也是第一个在美国医师执照考试样例问题中获得“合格”的模型^[7]。国内的科研机构也在积极推进大模型在医学领域的应用，也推出了许多针对于医学领域的大模型，例如：DoctorGLM、华佗 GPT 等。DoctorGLM 是基于 ChatGLM 的中文问诊模型，其对通用大语言做了针对医疗领域进行微调与优化工作；香港中文大学和深圳大数据研究院的研究团队推出的华佗 GPT-o1，首次将推理能力融入到了医学大模型。

医学问答模型虽然已经从 BioBERT、PubMedBERT 一类的领域预训练模型发展到 Med-PaLM、HuatuoGPT、DISC-MedLLM、MedFound 等生成式医学模型，但在真实应用场景中仍存在明显不足。其一，很多模型在考试题或标准问答集上表现较好，但面对日常慢病咨询中的口语化表达、连续追问和个性化问题时，稳定性仍然不足。其二，纯

生成式模型往往难以同时满足“回答自然”和“证据清晰”这两个要求，尤其在治疗建议、药物说明和风险判断等问题上更容易暴露安全边界问题。其三，现有研究更多关注模型能力本身，而对知识更新、检索链路、证据展示和系统落地等系统实现环节关注不足。

1.3 本文研究内容

针对“三高”慢性病场景下大语言模型在可信性、安全性以及系统落地方面存在的问题^[8]，本文围绕基于检索增强生成（Retrieval-Augmented Generation, RAG）的医学问答系统展开研究与实现。本文主要工作包括面向垂直医疗场景的关键技术设计以及系统工程实现。

本文的具体研究内容如下：

（1）围绕“三高”相关慢性病主题构建医学知识库，对相关政策文件、临床诊疗指南、健康科普资料以及互联网医学文本等数据进行整理和预处理，并通过文本切分和向量编码等方式，形成适用于检索增强生成框架的结构化知识基础。针对医学文本专业术语密集、信息表达高度压缩以及上下文依赖性较强等特点，重点分析了知识组织方式对后续检索效果与生成质量的影响。

（2）针对医学问答场景中单一检索策略难以同时兼顾精确匹配与语义召回的问题，设计了关键词检索与向量检索相结合的混合检索策略，并引入重排序与结果筛选机制，以提升检索证据的相关性与可靠性。在此基础上，构建基于大语言模型的生成流程，使模型能够结合检索到的外部医学证据进行答案生成，从而在一定程度上提升回答的准确性与可解释性。

（3）设计并实现了一套面向实际应用的医学问答系统，围绕用户问答交互、知识检索服务、模型推理调用以及结果展示等核心模块进行整体架构设计，实现了从知识导入、索引构建到在线问答服务的完整流程。同时，系统支持多轮对话、证据来源展示以及知识库管理等功能，使系统能够较好地服务于实际慢病健康咨询场景。

2 相关理论和技术介绍

2.1 大语言模型概述

大语言模型（Large Language Models, LLM）是近来自然语言处理领域中很有代表性的一类技术，它的基本思路是通过大规模文本训练，让模型学到语言里的语法规律、语义关系和上下文联系。和传统模型相比，大语言模型的参数规模更大，能处理更复杂的语言现象，在问答、对话、摘要和内容生成等任务中，通常会表现出更强的泛化能力。当前主流大语言模型大多使用 Transformer 框架。

2.1.1 Transformer 模型

Transformer 模型是一种基于自注意力机制的神经网络模型，由 Vaswani 等人在 2017 年提出^[9]。相比于传统的循环神经网络（RNN）和长短期记忆网络（LSTM），Transformer 仅依靠自注意力机制来建模序列数据之间的关系。这使得它具备两个关键优势：一是拥有更好的并行性和更高的训练效率；二是缓解了 RNN 在处理长序列时面临的梯度消失或爆炸问题^[10]。




图 2.1 Transformer 结构图

Transformer 的整体结构如图2.1所示，它由编码器和解码器两个部分组成。编码器对输入序列进行特征提取，将其编码为高维的连续向量；解码器根据编码结果逐步生成

输出序列。其中，编码器由多层相同的子层堆叠而成，每一层都包含多头自注意力机制（Multi-Head Self-Attention）和前馈神经网络（Feed Forward Network）两个子模块，并在每个子模块后引入残差连接与层归一化（Layer Normalization）。解码器同样由多层结构组成，在每一层中除了包含与编码器类似的多头自注意力和前馈网络外，还额外引入了编码器-解码器注意力机制（Encoder-Decoder Attention），用于融合输入序列的语义信息。与编码器不同的是，解码器中的自注意力采用掩码机制（Masked Self-Attention），将下文用掩码遮盖，以保证模型在生成过程中不会利用“未来”的信息，从而符合自回归生成的特性。

自注意力机制是 Transformer 的核心组成部分，其主要思想是通过计算序列中各元素之间的相关性来动态调整不同位置之间的信息权重。在计算过程中，每个输入向量会被映射为查询（Query）、键（Key）和值（Value）三个向量，通过 Query 与 Key 之间的相似度计算得到注意力权重，并对 Value 进行加权求和。Attention 机制使模型能够在全局范围内建模序列依赖关系，有效捕捉长距离语义信息，并且支持并行计算，显著提升了模型的训练效率与表达能力^[11]。它的标准形式为：

$$Attention(Q, K, V) = softmax(\frac{QK^T}{\sqrt{d_k}})V \quad (\text{公式 2.1})$$

其中， Q 、 K 、 V 分别表示查询、键和值三个向量矩阵， d_k 表示键向量的维度。通过对 QK^T 进行缩放处理，可以避免在维度较大时点积结果过大，使 softmax 函数进入梯度较小的区域，影响模型训练效果。

在实际应用中，Transformer 进一步引入多头注意力机制（Multi-Head Attention），通过并行地执行多组注意力计算，使模型能够从不同子空间对序列信息进行建模，从而增强特征表达能力。

2.1.2 现代大模型

现代主流大语言模型大多采用仅解码器架构，代表有 GPT、LLaMA、Qwen 等，这种结构更适合自回归语言任务，因为解码器的自注意力掩码只依赖上文预测下一个词，与文本逐词生成的过程天然一致，这使它成了通用大模型的首选^[12,13]。

整体上，现代大模型依然继承 Transformer 由多层注意力模块和前馈网络模块堆叠并通过残差连接的基本框架，但对多个核心部分做了优化，以提升处理长上下文的能力、训练效率或推理效率；在归一化方面，现代大模型普遍把归一化位置从模块输出之后移到输入之前，也就是先对输入进行归一化再送入注意力或前馈网络，使训练更稳定，还有一些模型把传统的层归一化换成了计算更轻量的 RMSNorm；位置编码上，旋转位置编码（Rotary Position Embedding, RoPE）已经广泛替代了绝对位置编码，它在注意力计算中直接融入相对位置信息，从而能更好地捕捉长距离依赖关系^[14]；前馈网络部分，现代大模型常采用 SwiGLU 等门控线性单元，这种带门控的结构比标准两层线性映射拥有

更强的非线性表达能力和更高的参数利用效率，在相近的参数量下能获得更好的建模效果；注意力机制方面，围绕长上下文支持和推理效率，现代模型进行了整体优化：一方面通过让多个查询头共享或分组共享键值表示（即多查询 MQA 或分组查询 GQA）^[15]，有效压缩键值缓存规模、降低显存占用，另一方面引入更高效的 FlashAttention 来重写标准注意力的计算过程——标准注意力在序列长度为 n 时要构造 $n \times n$ 的注意力矩阵，带来 $O(n^2)$ 显存开销和大量内存读写，而 FlashAttention 不显式存储完整注意力矩阵，改为把查询、键、值矩阵分成小块，在片上高速缓存中分块计算 QK 转置、局部 softmax 以及与 V 的乘积，并在线维护 softmax 的归一化项^[16]，由公式 2.2 等价地完成注意力计算。

$$y_i = \sum_j \frac{\exp\left(q_i \cdot \frac{k_j}{\sqrt{d}}\right)}{\sum_l \exp\left(q_i \cdot \frac{k_l}{\sqrt{d}}\right)} v_j \quad (\text{公式 2.2})$$

这些优化显著增强了模型的长上下文建模能力、训练稳定性、参数利用效率以及推理阶段的计算效率，使大模型能够在复杂语义理解、多轮对话和长文本生成等任务中表现出更强的能力。

2.1.3 模型训练技术

大语言模型的训练通常由多个阶段构成，不同阶段用来发展模型不同方面的能力。通过分阶段训练，模型可以逐步从基础语言建模能力过渡到面向具体任务的应用能力，从而在保证语言理解能力的同时提升实际使用效果。

训练初期，一般采用大规模无标注语料进行预训练。该阶段的目标只是为了让模型学习自然语言中的基本结构、词语之间的统计关系以及上下文特征，模型通过大量的学习，会学习到自然语言中潜在的特征，从而自然的获得通用的语言表示能力。常见的训练方式是基于自监督学习，通过预测文本中的部分内容来完成训练，使模型在无需人工标注数据的情况下获取丰富的语言知识。经过预训练后，模型已经具备了根据上文进行“下一词预测”的能力，能够根据已有文本生成连贯的后续内容。

在此基础上，引入监督微调（Supervised Fine-Tuning, SFT）阶段。该阶段使用人工标注的数据，对模型进行进一步训练，让模型的输出更契合所要解决的具体任务。例如，在问答或对话任务中，通过构建“问题—答案”或“指令—响应”的数据对，引导模型学习更符合实际应用场景的表达方式。与预训练阶段不同的是，微调数据规模通常较小，但针对性较强，更有利于模型学习产生结构化的正确输出。

在完成有监督微调之后，为了使模型输出的结构更符合人类偏好，通常还会进一步引入基于人类反馈的强化学习阶段。在这一阶段，让模型所生成的结果更加符合人类偏好，在内容的准确性、表达的合理性、结果的安全性诸方面都加以改进^[17]。人类反馈强化学习（RLHF）中最常用、最典型的策略优化方法是近端策略优化（Proximal Policy Optimization, PPO）^[18]。PPO 算法通常会引入两个小规模模型：奖励模型和价值模型。

奖励模型用于学习人类对不同输出结果的偏好，并对生成结果进行评分；价值模型用于估计当前生成策略在后续过程中的回报情况。整个训练过程与现实中的考试很相近，Base 模型就是“学生”，奖励模型相当于“教师”，“教师”对“学生”的答卷评分，“学生”根据打分进行学习。具体来说，模型会根据当前策略生成回答，奖励模型计算对应的奖励信号，接着价值模型对整个序列的整体收益进行估计，这样就得到了用于优化的优势函数。优势函数用于衡量当前生成行为相对于基准策略的优劣程度，并作为权重参与策略优化过程。更重要的是，PPO 有明确而巧妙的机制来控制新旧策略的变化幅度，即在保证训练稳定性的基础上缓慢、审慎地调整生成分布，让优势为正的行为概率增大，优势为负的行为概率缩小。因此 PPO 在保持生成能力稳定性的同时，能更可靠、更充分地遵循人类偏好。

虽然 PPO 算法能够提升模型对人类偏好的对齐程度，但其训练过程一般都极为复杂。在训练过程中不仅引入了奖励模型和价值模型两个需要额外训练的新模型，还要将原始模型保存一份作为参考模型，这带来了极大的计算和存储开销。2023 年，由斯坦福大学提出直接偏好优化（Direct Preference Optimization, DPO）算法，DPO 的基本思想是利用“优选回答-非优选回答”成对数据，直接优化模型对高质量回答的偏好^[19]。相较于 PPO 算法，DPO 训练流程不需要独立的奖励模型和价值模型，这也让 DPO 训练更简单也更稳定。DPO 的目标函数通常可表示为：

$$\mathcal{L}_{DPO}(\theta) = -\mathbb{E}_{(x, y_w, y_l) \sim \mathcal{D}} \left[\log \sigma \left(\beta \log \frac{\pi_{\theta}(y_w|x)}{\pi_{ref}(y_w|x)} - \beta \log \frac{\pi_{\theta}(y_l|x)}{\pi_{ref}(y_l|x)} \right) \right] \quad (\text{公式 2.3})$$

其中， x 表示输入问题， y_w 表示优选回答， y_l 表示非优选回答， π_{θ} 表示待优化模型， π_{ref} 表示参考模型， β 表示偏好强度参数。这个目标函数的含义在于：当面对同一个输入时，提升模型对优选回答的相对概率，并且还要降低它对非优选回答的概率，从而使模型输出更符合人类的偏好。

2.2 检索增强生成（RAG）技术

检索增强生成（Retrieval-Augmented Generation, RAG）是一种把信息检索和文本生成结合起来的方法，目标在于提升大语言模型在专业领域或需要大量事实信息的任务上的表现^[20]。与单纯依赖模型自身参数进行生成的方式相比，RAG 通过引入一个外部的知识库，为模型提供更加准确且更具有时效性的信息支持。

在传统的大语言模型中，模型掌握的知识几乎全部来自预训练阶段存入参数中的信息，这种方式虽然具备较强的泛化能力，但在面对专业领域问题或最新信息时，就很容易暴露出知识不足或生成内容不够准确的缺陷。RAG 把检索模块加入到了生成过程当中，有效地缓解了这类问题。

2.3 本章小结

本章首先对 Transformer 模型的结构进行了详细的介绍，随后介绍了目前热门的大语言模型的对 Transformer 结构的改进以及模型的训练方法，并介绍了检索增强生成技术的应用场景。

3 医学知识库构建与检索方法

本章主要研究医学问答系统中知识库的关键内容，包括医学知识库构建、文本语义切分、向量化表示以及混合检索策略设计。对 RAG 系统来说，知识库的质量和检索效果会直接影响后续生成阶段能否获得可靠证据。

3.1 医学知识库构建方法

3.1.1 数据来源

医学知识库的数据来源，会直接影响系统问答的准确性和可靠性。围绕“三高”（高血压、高血糖、高血脂）相关内容，系统主要选取公开、并且具有一定权威性的医学资料，用来保证知识内容在科学性和可信度方面更有依据。数据主要来自以下三个方面：

- (1) 权威医学指南与报告：主要包括国家卫生健康委员会等官方的政策文件、指南与规范和健康报告。
- (2) 医疗机构与专业平台内容：主要包括丁香园、医知源等平台发布的疾病科普文章和健康建议。
- (3) 医学科普网站与百科类资源：主要包括维基百科等平台中“三高”相关词条。

3.1.2 数据预处理

本系统的医学知识库由多种格式的原始文档组成，主要包括 PDF 文档和 HTML 网页内容。由于不同来源的数据在结构上差异较大，系统针对不同类型的数据分别设计了预处理方式，先把原始文档转成适合后续处理的文本格式，再继续进行文本切分和向量化表示。

- (1) PDF 文档处理：对于 PDF 格式的医学资料，系统使用 MinerU 工具进行解析。MinerU 基于多模态大模型，能够识别不同排版结构的 PDF 文档，并把它们转换成结构化的 Markdown（.md）格式。
- (2) HTML 网页处理：对于 HTML 网页数据，系统通过解析网页内容，并使用 `document.body.innerText` 提取其中的主要文本信息，再把它转换成纯文本（.txt）格式，便于后续统一处理。

3.1.3 文本语义切分

在 RAG 系统中，模型通常不需要把整篇文档原封不动地作为生成时的输入，而且过长的文档还会导致向量化表示和检索的难度增加。这就要求必须对文本进行合理的切分，在尽可能保留原始医学文本语义结构的前提下，将长文档划分为适合检索与生成使用的文本块。如果切分后 chunk 过长，单个文本块中会包含过多无关信息，影响检索精

度；若切分后 chunk 过短，则容易破坏上下文完整性，导致关键知识被割裂。因此，本系统切分策略并不是简单的按固定长度截断，而是要按照标题和段落结构来切分文档。

对于 PDF 解析得到的 Markdown 文本，系统会先去除文末的参考文献、页脚等与问答无关的内容，之后则按照 Markdown 语法识别标题与正文块。系统会创建一个标题栈，通过维护标题栈记录当前文本所在的层级路径，当遇到新的标题时，先把之前缓存的内容输出，再更新标题路径；当遇到普通段落时，则将其合并到当前标题对应的缓冲区中。如果缓冲区内容超过长度阈值，系统会优先按照句号、问号、感叹号等语句结束标点进行切分，并将上一个文本块末尾的 120 字符作为下一文本块的开头，从而形成带重叠的连续片段，尽量避免关键信息被分割。经过这样的处理，Markdown 文本最终被切分为“标题路径 + 正文内容”的结构化片段。

对于网页提取得到的 TXT 文本，由于其与 Markdown 不同，并不具有“标题”和“正文”的标识，系统采用启发式规则进行语义切分，但总体的切分思路相同。程序首先按连续空行划分自然段，再对单行或多行段落进行标题识别。标题识别主要依据中文医学资料中常见的编号形式，如“一、”“(一)”“1.”“(1)”等，同时对长度较短且不以句末标点结束的行引入隐式标题判定规则，以适应网页文本中未显式标注层级但具备标题特征的内容。与 Markdown 文档处理方式相同的是，系统仍会创建一个标题栈用于记录段落所属的层级关系。在具体合并策略上，若新标题属于同级或更高层级，则输出当前缓存内容并开始新的文本块；若仅为更深层级的子标题，则不立即切分，而是继续在父级主题下聚合内容。这样可以将同一主题下若干较短的小节内容合并为一个较完整的语义单元，避免切分过碎。当缓冲区长度超出阈值时，采用和之前同样的策略，按照语句结束标点切分，并且使两段又一部分重叠的片段，保留上下文的信息。

完成处理后，所有文档都统一保存为 JSON 格式，JSON 字段如图 3.1 所示，每个文本块包含 chunk_id、source、category、headings 和 content 等字段，方便后续对检索结果的溯源。

```
{  
  "chunk_id": 5,  
  "source": "国家基层糖尿病防治管理指南（2025）.pdf",  
  "category": "Diabetes",  
  "headings": "二、 制定原则",  
  "content": "本指南根据国家发布的糖尿病防治管理工作规范要  
  "page_range": "p2"  
},
```

图 3.1 切分后的 chunk 示例

3.1.4 Embedding 向量化表示

文本切分完成之后，知识库里的每个文本块都还需要经过一步转换，变成能够支持语义检索的向量表示。Embedding 模型会把离散文本映射到一个统一的高维语义空间中，使语义相近的文本在向量空间中的距离更近，从而支持后续基于相似度的向量检索。

本系统采用 BGE 系列 Embedding 模型对医学文本块进行向量化处理。BGE 模型具有较好的中文语义表示能力，能够较好地适应医学问答场景中常见的疾病名称、症状描述、用药建议以及生活化表达等多种文本形式。在知识库构建阶段，系统使用 BGE 模型对切分后的 chunk 逐条编码，生成对应的稠密向量；在在线检索阶段，则对用户问题执行相同的编码操作，并通过计算问题向量与知识块向量之间的相似度来完成召回。

Embedding 向量化的意义在于，它把知识库的检索方式从单一依赖关键词匹配，转变成了兼具基于语义理解进行检索的能力；针对医学问答中大量存在的同义表达、口语化描述和隐含问题，这种向量化表示正是扩大召回覆盖面、增强检索稳健性的关键基础。

3.1.5 向量数据库构建

在获得文本块的向量表示后，还需要构建能够支持高效近邻检索的向量数据库或向量索引结构。若仅对全部向量进行线性遍历比对，在知识规模增长后会显著增加检索开销，难以满足在线问答场景对响应速度的要求。因此，知识库构建不仅包括文本组织和向量生成，也包括向量检索结构的建立。

本系统采用 FAISS 构建医学知识库的向量索引，把每个文本块向量与它对应的原文内容、标题路径和来源信息建立起映射关系，这样在向量检索时系统既能快速获得与查询最相近的文本块，又能把结果回溯到原始文本内容和来源元数据，为后续的证据展示与可解释性分析提供支撑。

3.2 医学文本检索方法

3.2.1 BM25 关键词检索

BM25 是一种比较经典的关键词检索模型，主要根据查询词在文档中的出现情况来计算相关性，因此更适合处理以词面匹配为主的检索任务。对于查询 q 和文档 d ，它的得分公式可以写作

$$\text{score}(q, d) = \sum_{t \in q} \text{idf}(t) \cdot \frac{f(t, d) \cdot (k_1 + 1)}{f(t, d) + k_1 \cdot (1 - b + b \cdot \frac{|d|}{\text{avgdl}})} \quad (\text{公式 3.1})$$

其中， $f(t, d)$ 表示词项 t 在文档 d 中的出现次数， $\text{idf}(t)$ 表示逆文档频率， $|d|$ 表示文档长度， avgdl 表示平均文档长度， k_1 和 b 则用来控制词频影响和长度归一化程度。

在医学问答场景里，疾病名称、药物名称、检查指标和各类专业术语往往具有很强

的区分作用，而 BM25 正好比较擅长保留这类关键词信息，所以在精确匹配方面表现比较稳定。它的不足也很明显，就是对同义表达、口语化提问和更深一层的语义关系不够敏感，因此只依赖 BM25 时，系统容易漏掉一些意思接近但表述不同的内容。

3.2.2 向量检索

向量检索的思路和关键词检索不同，它不是检索词是否匹配，而是先借助嵌入模型把用户问题和文档内容都表示成向量，再放到同一个语义空间中进行比较，语义越接近，向量之间通常也越接近，系统就更容易把对应文本检索出来。本文选用 BGE-M3 作为嵌入模型^[21]，并把知识库中的每个文本块编码成稠密向量，再写入 FAISS 索引中保存。

在相似度计算方面，常见方法主要有余弦相似度和内积两种形式，当向量完成归一化以后，这两种方法在数学上等价。结合实际应用，本文在 FAISS 中采用内积检索方式，这样既能保持较高的检索效率，也能较好反映语义层面的接近程度。

和关键词检索相比，向量检索更擅长处理同义表达、上下位概念以及长句语义理解这类问题，比如提问方式发生变化以后，它仍然有可能找到意思接近的文本。不过，它对局部关键词的约束相对较弱，有时会召回语义上看起来相关、但关键实体并不一致的文本片段。医学问答对术语准确性要求较高，所以只依靠向量检索也很难保证结果始终稳定，通常还需要和关键词检索配合使用。

3.2.3 混合检索策略

为兼顾“术语精确匹配”与“语义泛化召回”两个目标，本文采用 BM25 与向量检索的混合策略，并设计了一条“双路召回到融合排序再到重排精筛”的处理流程：

首先，系统让两种检索逻辑各自独立地从知识库中检索出各自认为最相关的候选文档列表，形成两路结果；然后，对这双路结果进行融合排序，采用的算法是倒数排序融合^[22]，它的计算形式可以写作：

$$RRF(d) = \sum_{r \in R} \frac{1}{k + r(d)} \quad (\text{公式 3.2})$$

其中 R 代表参与融合的各路排序列表的集合， $r(d)$ 表示某篇文档 d 在对应列表中的排列位次， k 是一个用来平滑结果的常数，本系统取 $k=60$ ，这个公式综合了一篇文档在不同排序列表中的名次信息，名次越靠前最终得分越高；第三步，融合出统一的候选列表后，再引入 BGE-Reranker-v2-M3 的专门重排模型，对候选文档进行交叉编码式的高精度重排，最终截取出靠前的 Top-K 份证据。

与单用一种检索方式相比，混合策略有几方面的好处：第一，BM25 防止了关键专业术语不会因为语义而无法被准确检索；第二，向量检索弥补了同义改写和口语表达的语义召回盲区；第三，重排模型进一步提升了最终送去给生成模型用的证据的相关性，

有效滤掉那些“初看沾边但不支持直接做答”的噪声片段；这样的组合策略，在同一套检索链路里同时回应了医学问答对“高召回”和“高精度”的双重严苛要求。

3.3 实验与结果分析

为了验证不同检索方法在医学知识库中的实际召回效果，本文围绕已经构建完成的 FAISS 索引开展了检索实验。实验中，先从知识库中随机抽取 60 个文本段，再根据这些文本段的内容人工设计相关问题，每个问题都对应一个预期命中的目标文本块，只要这个目标文本块出现在前 K 个检索结果中，就记作一次命中。本文选用 Recall@1、Recall@5 和 Recall@10 作为评价指标，用来衡量系统在只返回 1 条、前 5 条和前 10 条候选结果时的召回能力。

实验共比较了三种检索方式，一种是基于 BM25 的关键词检索，一种是基于 BGE 向量表示和 FAISS 索引的向量检索，另一种是本文采用的混合检索策略，也就是先结合 BM25 和向量检索进行双路召回，再通过 Reranker 完成重排，最后给出排序结果。三种方法的实验结果如表 3.1 所示。

表 3.1 RAG 检索方法 Recall@K 对比结果

检索方法	Recall@1	Recall@5	Recall@10
BM25 检索	0.26	0.81	0.92
向量检索	0.48	0.81	0.85
混合检索 + Rerank 重排	0.59	0.89	0.96

从实验结果来看，三种检索方法在不同 K 值下表现出比较明显的差异。先看 Recall@1，BM25 检索为 0.26，说明如果系统只返回首条结果，只依靠关键词匹配很难稳定命中目标文本；向量检索的 Recall@1 提升到 0.48，说明语义检索对口语化表达、近义改写和不完全词面匹配的问题有更好的适应能力；混合检索结合 Rerank 重排以后，Recall@1 进一步提升到 0.59，是三种方法中最高的。这说明在最靠前的排序位置上，混合检索策略更容易把真正相关的证据提前放出来。

再看 Recall@5，BM25 检索和向量检索都达到 0.81，混合检索则提升到 0.89。这说明当候选范围扩大到前 5 条时，单一检索方法已经能够召回大部分相关文本，但仍然会出现一定程度的漏召回；相比之下，混合检索同时利用了关键词匹配和语义匹配两类信息，又经过重排模型进一步筛选，因此在前 5 条结果里保留了更多有效证据。对 RAG 系统来说，这一点很重要，因为生成模型通常不会使用过多检索结果，如果前几条证据质量不够高，最终回答质量也会直接受到影响。

最后看 Recall@10，BM25 检索达到 0.92，高于向量检索的 0.85，这说明当候选集合进一步放宽以后，BM25 在专业术语、数字指标这类关键词层面的覆盖能力会更明显，更容易把目标文本放进较长的候选列表里。不过，混合检索加 Rerank 重排的 Recall@10

仍然达到 0.96，依然是三种方法中最好的结果。这说明混合检索并不是简单把两种方法拼在一起，而是在不同检索机制之间形成了比较明显的互补关系，BM25 负责尽量保住专业术语、药物名称和指标数值这类关键信息不被漏掉，向量检索负责补足语义层面的相似表达，重排模型再进一步减少“看起来相关、但并不是最佳证据”的干扰。

综上所述，单独使用 BM25 更适合术语比较明确的问题，但对自然语言表达变化会更敏感；单独使用向量检索在语义匹配上更有优势，不过在一些依赖精确术语和细粒度实体区分的问题上，仍然可能出现误召回。相比之下，混合检索结合重排策略在 Recall@1、Recall@5 和 Recall@10 三个指标上都取得了最好结果，说明这种方法更适合医学问答场景中“专业术语精确匹配”和“自然语言语义召回”同时存在的需求。因此，本文最终选择混合检索加 Rerank 重排作为 RAG 问答系统的默认检索方案。

3.4 本章小结

本章围绕医学知识库构建与检索方法展开，介绍了知识数据来源、文本预处理、语义切分、Embedding 向量化表示以及向量索引构建过程，并进一步分析了 BM25、向量检索和混合检索策略在医学问答场景中的特点与差异。实验结果表明，混合检索结合重排策略在召回覆盖和结果稳定性方面表现更好，能够为后续回答生成提供更可靠的证据基础。

4 医学问答模型构建与优化

在完成知识库的构建与检索设计之后，系统还需要进一步解决“如何基于检索证据生成回答”以及“如何让模型回答更符合医学场景要求”这两个问题。因此，本章重点讨论 RAG 输入组织方式、Prompt 设计、DPO 偏好数据构建以及模型优化效果分析。

4.1 RAG 问答生成方法

4.1.1 检索增强生成流程

RAG 问答生成的核心流程可以概括为“检索—增强—生成”三个环节：先从用户输入的问题出发构造检索查询，在医学知识库把与之相关的候选文本召回；接着对召回的一批候选文本做去重、排序和筛选，挑出最有价值的证据组合成增强上下文；最后把用户问题和增强后的证据上下文一起交给大语言模型，由模型将这些证据转化为用户可以理解的自然语言回答。通过这样一条链路，模型的输出就不再单纯依赖存留在参数里的记忆，而是建立在外部知识的支撑之上，从而让回答的准确程度与内容可追溯程度都得到提升。




图 4.1 RAG 流程图

4.1.2Prompt 与上下文构建

在医学问答场景下，系统需要将提示信息、对话上下文与检索结果进行统一组织，作为大语言模型的输入。系统送入大语言模型的内容主要包括三部分，一部分是系统提示词，用来明确模型的角色定位和回答原则，一部分是必要的历史对话信息，用来支持多轮问答中的语义衔接，另一部分是当前用户问题和检索得到的外部证据，用来约束模型在生成时优先依据可以核对的资料作答。这样组织输入内容，主要是为了减少没有依据的扩展，让模型输出尽量建立在检索证据和医学常识的共同基础上。

如图4.2所示，系统提示词先把模型设定为“严谨、审慎的医疗问答助手”，并明确

要求它优先依据检索资料回答问题。在回答规则上，提示词进一步限制模型不能编造和资料内容或医学共识相矛盾的信息，还要求模型先判断检索资料和问题之间的相关程度，再决定是以资料为主进行回答，还是结合通用医学知识作适当补充；如果问题本身比较宽泛，就先给出简要概述，再围绕检索证据展开重点说明，回答形式也要尽量清楚、具体、容易理解。对于治疗和用药这类更敏感的问题，系统还要求模型避免给出过于绝对的建议；如果问题中出现胸痛、呼吸困难、意识改变、持续高热或明显出血等急危重症信号，则应优先建议立即线下就医或进行急诊处理。这样设计 Prompt，不只是告诉模型要回答什么，更重要的是限制模型该怎样回答，以及回答应当控制在什么边界内。

```
DEFAULT_SYSTEM_PROMPT = (  
    "你是一名严谨、审慎的医疗问答助手。\\n\\n"  
    "请优先基于“检索资料”回答问题，并结合必要的医学常识进行补充说明，以确保回答完整、准确。\\n\\n"  
    "要求：\\n"  
    "1. 不得编造与资料或医学共识相矛盾的内容。\\n\\n"  
    "2. 请判断检索资料与问题的相关性：\\n"  
    "- 若高度相关：以资料为主回答。\\n"  
    "- 若部分相关：结合资料与医学常识补充。\\n"  
    "- 若相关性较低：以通用医学知识为主，并说明“检索资料未充分覆盖该问题”。\\n\\n"  
    "3. 若问题较宽泛（如疾病名称）：\\n"  
    "- 先进行简要概述（定义/常见表现）。\\n"  
    "- 再结合检索资料重点展开。\\n\\n"  
    "4. 回答使用markdown格式，内容应清晰、具体、通俗易懂。\\n\\n"  
    "5. 涉及治疗或用药时：\\n"  
    "- 避免给出绝对化或个体化用药方案。\\n"  
    "- 若缺少年龄、体重、肝肾功能、合并用药、过敏史等关键信息，应先提示补充。\\n\\n"  
    "6. 若出现急危重症信号（如胸痛、呼吸困难、意识改变、持续高热、明显出血等），应优先建议立即线下就医或急诊。\\n\\n"  
    "7. 当检索资料不足以完整回答问题时：\\n"  
    "- 可以基于通用医学知识进行补充。\\n"  
    "- 并适当说明信息来源类型（如“通用医学知识”）。"  
)
```

图 4.2 系统提示词

对于用户的输入，系统采用较为固定的组织格式，将当前问题和检索证据封装为统一文本。其中，用户问题以“问题:”字段引出；若存在检索结果，则继续追加“检索资料:”字段，并将检索证据整体附在其后。对于多轮对话场景，系统会在当前用户输入之前插入经过清洗后的历史消息序列，仅保留角色合法且内容有效的最近若干轮消息，并对连续同角色消息进行合并，以减少噪声上下文对生成的干扰。这样的组织方式既保持了对话输入格式的一致性，也使模型能够明确区分“历史对话”“当前问题”和“外部证据”三类信息。

在检索证据的构建上，系统对重排后的候选文档按相关性顺序逐条组织，每条证据均采用统一格式表示为“编号 + 来源 + 标题 + 内容”。这种结构化的输入方式，模型不仅能够利用正文内容，还能够同时利用来源信息和标题路径辅助判断证据的主题归属。

最终，系统将“系统提示词 + 历史对话 + 问题 + 检索资料”共同输入模型，实现面向医学 RAG 场景的统一 Prompt 构建。

4.2 基于 DPO 的模型优化策略

4.2.1 偏好数据构建

为了让 DPO 训练更贴近医学问答场景，本文选用了 cMedQA v2.0 和 Huatuo-26M 两个中文医疗问答数据集。前者是面向中文医疗问答任务整理的数据集，包含 10 万个问答对，覆盖了疾病、症状、治疗方法等多类医学知识；后者规模更大，约有 2600 万个问答对，而且其中大部分内容来自真实医疗咨询场景，因此更接近实际问答中的表达方式。

在这两个数据集中，本文先筛选出和“三高”相关的问题，再对重复内容进行去重，最终得到 6351 条问答数据。在这个基础上，又继续挑选出那些更容易产生歧义、或者更容易引发模型幻觉的问题样本，最后整理出 431 个具有代表性的偏好数据问题。

在具体构造过程中，本文借助高质量大语言模型生成偏好数据对，也就是 Chosen-Rejected 回答对，同时再引入评估模型对生成结果进行筛选和比较，用这种方式提高数据对的可靠性和区分度。

一是优质回答，也就是 Chosen 回答的生成，这部分提示词设计与 3.3.2 节保持一致，用来尽量保证训练阶段和实际使用阶段的提示环境相同；二是劣质回答，也就是 Rejected 回答的生成，本文通过提示词引导模型产出“表面上看起来合理、但实际存在缺陷”的回答，并有意识地加入几类常见问题，比如对不确定结论表达得过于肯定、忽略检索资料中的细节、缺少必要的安全提示，或者回答内容过于空泛，不过同时也会控制负样本不要出现明显错误或极端不安全内容，使它仍然停留在“容易混淆”的合理范围里，这样更有利于偏好学习；三是偏好对的筛选和质量控制，在得到候选正负回答后，再由另一个评估模型从事实一致性、安全性、相关性、完整性和表达清晰度等角度进行比较，只保留优劣关系比较明确的样本对，用于后续 DPO 训练。

如图4.3所示，本文最终将 DPO 训练数据组织为三元组形式，也就是 (prompt, chosen, rejected)，其中 prompt 表示用户问题，chosen 表示质量更高的回答，rejected 表示相对较差的回答。

4.2.2 DPO 训练流程

本文基于 TRL 框架实现 DPO 训练，并结合 LoRA 参数高效微调方法对 Qwen 基础模型进行优化，以提升模型在医学问答任务中的回答质量、安全性和场景适配能力。由于基础模型参数规模较大，若直接采用全参数训练，会带来较高的显存占用和训练开销，因此本文采用 LoRA 方法，仅在部分关键模块中引入可训练的低秩参数，从而在降低训练成本的同时实现对模型的有效优化。

在训练阶段，模型以偏好数据三元组作为输入，通过比较同一问题下的优选回答与非优选回答，学习更符合人工偏好的输出分布。考虑到单张 RTX 4090 显卡只有 24G 的显存容量，本文使用 bitsandbytes 库对模型进行 4-bit 量化加载，降低模型占用；训练过

```
"prompt": "问题：一型糖尿病并发症有哪些症状",
"chosen": "### 概述\n一型糖尿病若长期血糖控制不佳，慢性高血糖会逐渐损害全身微血管、大血管及周围神经，",
"rejected": "一型糖尿病的并发症症状其实和其他糖尿病基本一样，主要是血糖没控制好导致的全身性问题。最常",
"meta": {
  "question": "一型糖尿病并发症有哪些症状",
  "context": "",
  "source_answer": "糖尿病是一组由多病因引起的以慢性高血糖为特征的终身性代谢性疾病。长期血糖增高，",
  "judge": {
    "winner": "A",
    "score_a": 9,
    "score_b": 2,
    "reason": "回答A内容专业全面且包含紧急就医指引，回答B存在严重医疗安全隐患（建议无需频繁复查）",
  },
  "similarity": 0.0509
}
```

图 4.3 DPO 训练数据示例

程中采用小批量训练并结合梯度累加策略，用小显存近似模拟大批量的训练；同时设置 warmup 机制和合适的 DPO 偏好强度系数，以增强训练稳定性。

训练中使用的主要超参数如表4.1所示。

表 4.1 DPO 训练主要超参数

超参数	取值	作用
learning_rate	10^{-5}	学习率
lora_r	16	低秩矩阵的秩
lora_alpha	32	LoRA 缩放系数
batch_size	2	批大小
gradient_accumulation_steps	2	梯度累加步数
beta	0.1	DPO 偏好优化强度系数
warmup_ratio	0.03	学习率 warmup 比例

4.3 实验结果分析

4.3.1DPO 训练过程及分析

为验证 DPO 训练过程是否有效，本文结合训练日志对 loss、奖励准确率（reward accuracy）、奖励间隔（reward margin）以及平均 token 准确率等指标进行了分析，结果如图4.4和图4.5所示。整体来看，本次训练共记录 108 个训练点，训练历经约 1 个 epoch 后完成收敛，主要指标呈现出较为清晰的阶段性变化，说明模型在偏好学习过程中形成了相对稳定的优化趋势。

从 loss 变化来看，训练初始时 loss 为 0.6931，这一数值接近二分类随机判别时的初

始状态，说明模型在训练开始阶段尚未对 **chosen** 回答和 **rejected** 回答形成明确区分。随着训练推进，**loss** 整体呈下降趋势，最终降至 0.0836，最低值达到 0.0364。若按照训练早期、中期和后期三个阶段进行统计，其平均 **loss** 分别为 0.5542、0.2414 和 0.1579，表现出较为明显的递减特征。这说明模型在训练过程中逐步学会了对偏好对进行有效区分，**DPO** 目标函数得到了较充分优化。需要说明的是，训练后期 **loss** 曲线虽存在局部波动，但总体仍保持在较低水平，并未出现持续性反弹，因此可以认为模型整体收敛趋势较好。

从奖励相关指标来看，**DPO** 训练的偏好学习效果更为直观。训练开始时，奖励准确率和奖励间隔均为 0，表明模型尚未体现出明显的优劣排序能力。随着训练进行，奖励准确率在第 7 个 **step**、约 0.065 个 **epoch** 时即达到 1.0，说明模型较早就能够在当前批次上正确判断 **chosen** 与 **rejected** 回答的相对优劣。与此同时，奖励间隔由初始的 0 逐步增长至训练结束时的 2.6441，最大值达到 3.3355。按阶段统计可见，奖励准确率均值由早期的 0.7917 提升至中期的 0.9861，并在后期稳定在 1.0；奖励间隔均值则由 0.3414 进一步提升至 1.4702 和 2.0445。这表明模型不仅学会了“选对答案”，而且对优选回答与非优选回答之间的区分幅度也在不断扩大，说明偏好对齐过程并非偶然波动，而是形成了较稳定的排序优势。




图 4.4 模型训练过程曲线

除偏好学习效果外，还需要关注训练是否对基础模型原有生成能力造成明显破坏。为此，本文进一步观察了平均 **token** 准确率的变化情况。平均 **token** 准确率在整个训练过程中基本稳定在 0.59 附近，起始值为 0.6062，最终值为 0.5756，均值为 0.5915，标准差仅为 0.0212，整体波动较小。这说明尽管模型在偏好对齐过程中不断强化对优选回答的倾向，但并未明显削弱其原有的基本生成能力。

4.3.2 回答质量评测结果

为了评估优化后的模型在“三高”慢性病问答场景下的生成质量，本文构建了 120 条典型的“三高”领域问题，分别由基础模型 **Qwe2.5-7B-Instruct** 和 **DPO** 优化后的模型




图 4.5 平均 token 准确率

生成回答，并对两个模型的回答进行评估，以分析优化方法对医学问答性能的影响。

为了保证评测过程的一致性与客观性，本文采用大语言模型作为评审（LLM-as-a-Judge）的方式对两个模型的回答进行对比评价。具体来说，对于每一个测试问题，分别获取基础模型与 DPO 优化模型生成的回答，并对回答顺序进行随机打乱，使评审模型在不知模型来源的情况下进行判断。

在评价维度上，本文主要从事实一致性、安全性、相关性以及表达清晰度等方面对回答质量进行综合评估。其中，事实一致性用于衡量回答是否符合医学常识及检索证据内容；安全性关注回答中是否存在潜在风险或缺乏必要的就医提示；相关性用于判断回答是否紧密围绕用户问题；表达清晰度则评估回答结构是否合理、语言是否易于理解。

在具体评判方式上，模型需在两个回答中选择质量更优的一项，或在无法区分优劣时标记为“平局”。基于全部样本的评测结果，统计 DPO 优化模型相对于基础模型的胜率，以反映其在整体生成质量上的提升情况。

详细评测结果如表4.2所示。可以看出，相较于基础模型，DPO 优化后的模型在整体生成质量上取得了一定提升，总体得分由 9.0750 提升至 9.3667，增幅为 0.2917，说明模型在综合表现上有所改善。

从各项评价维度来看，DPO 优化在事实一致性和完整性方面提升较为明显，其中 `factual_consistency` 提升 0.1667，`completeness` 提升 0.2083，表明模型在生成过程中能够更好地利用检索证据，并减少关键信息遗漏。同时，在安全性和边界意识指标上也有一定提升，分别增加 0.1250 和 0.0917，说明模型在回答中对风险提示和边界控制的表现有所改善，更符合医学问答场景的安全性要求。

相比之下，`relevance` 和 `clarity` 的提升幅度相对较小，分别仅为 0.0083 和 0.0417。这一现象可能是因为基础模型在语义理解与语言表达方面已具备较强能力，DPO 优化对这些维度的影响相对有限。

总体来看，DPO 优化主要体现在提升模型对医学知识的使用质量以及回答过程中

表 4.2 Base 与 DPO 的多维评测统计对比

Metric	Base	DPO	Δ (DPO-Base)
overall_score	9.0750	9.3667	0.2917
factual_consistency	4.6583	4.8250	0.1667
safety	4.7000	4.8250	0.1250
relevance	4.9667	4.9750	0.0083
completeness	4.4667	4.6750	0.2083
clarity	4.9333	4.9750	0.0417
boundary_awareness	4.6333	4.7250	0.0917

注： Δ 为 DPO 模型相对于 Base 模型的均值提升。

的安全性、完整性，而在通用语言能力方面变化较小。该结果进一步验证了基于偏好学习的优化方法能够在不显著影响原有生成能力的前提下，对模型在特定领域中的表现进行有效改进。

4.4 本章小结

本章围绕模型侧方法展开，系统梳理了 RAG 问答生成流程、Prompt 与上下文构建方式、偏好数据组织过程，以及基于 DPO 的模型优化与实验分析。结果表明，DPO 优化在回答完整性、事实一致性和医学场景适配能力方面带来了较稳定提升。

综合本章研究可以看出，模型不仅具备了“基于证据生成回答”的核心能力，也在输出稳健性和风险边界控制方面得到强化。

5 系统设计与实现

针对传统医疗咨询方式在获取便捷性、响应及时性以及信息一致性等方面存在的不足，以及通用大语言模型在医学问答场景下存在的幻觉问题和安全性风险，本章基于前文提出的检索增强生成方法与模型优化策略，设计并实现了一套面向“三高”慢性病管理的医学问答系统。

5.1 系统需求分析

5.1.1 功能需求

结合“三高”慢性病问答场景的实际使用需求，本文将系统功能需求概括为以下几个方面：

- (1) **自然语言问答功能。**系统应能够接收用户以自然语言形式提出的健康咨询问题，并对问题内容进行理解，生成语义完整、表达清晰的回答。这是系统面向用户提供服务的基础功能，也是后续检索增强与模型推理的前提。
- (2) **多轮会话管理功能。**慢性病咨询具有较强的连续性，用户往往围绕同一主题进行追问，因此系统不仅要支持单轮问答，还应能够保存历史对话内容，并结合上下文理解当前问题的真实意图，以保证回答过程的连贯性和上下文一致性。
- (3) **知识检索与证据支撑功能。**针对医学问答对准确性和可靠性的需求，系统应能够在回答生成前，从医学知识库中检索出与问题相关的参考资料，并将检索结果作为模型生成回答的重要依据，从而提升回答的专业性和可信度。
- (4) **引用展示功能。**系统在返回答案的同时，应能够展示回答所依赖的文档来源或参考片段，使用户能够进一步了解回答依据，提高系统输出的可核验性与可解释性。
- (5) **知识库维护与后台管理功能。**为了满足系统长期运行需要，还应支持知识文档入库、索引更新、会话记录保存以及管理员后台维护等功能，使系统能够适应医学知识持续更新和后续扩展的需求。

5.1.2 非功能需求

除功能层面的要求外，医学问答系统还需要满足一定的非功能需求，以保证其在真实场景中的可用性和稳定性。本文认为主要包括以下几个方面：

- (1) **准确性与安全性。**医学问答不同于一般信息问答，回答内容若出现事实性错误、表述失当或风险边界不清，可能对用户产生误导。因此，系统应尽量降低模型幻觉带来的影响，使生成内容与外部知识依据保持一致，并在高风险问题上体现必要的审慎性。
- (2) **可解释性。**系统不仅需要给出回答结果，还应能够说明回答所依赖的知识来源，

使用户能够了解答案并非完全来自模型参数记忆，而是建立在外部医学资料支撑的基础之上，从而增强系统的可信度。

- (3) **响应效率**。在实际交互过程中，用户通常希望在较短时间内得到反馈，因此系统在知识检索、结果重排、上下文构建和模型推理等环节都应具备较好的处理效率，并提供流式传输的功能，以满足在线问答场景下的实时性要求。
- (4) **可维护性**。医学知识内容具有持续更新的特点，系统应便于进行知识文档补充、索引重建和服务维护，以保证系统能够随着知识更新而不断完善。
- (5) **可扩展性**。考虑到后续 Embedding 模型、重排模型和生成模型均可能被替换或升级，系统架构应尽量保持模块间的相对独立，使系统能够方便地进行功能扩展和技术迭代。

5.2 开发技术选择

在医学问答系统的开发过程中，技术选型不仅关系到系统功能能否顺利实现，也会直接影响后续模型部署、服务联调、界面交互和知识库维护的效率。目前面向智能问答系统的实现方式通常包括一体化桌面应用、传统前后端分离式 Web 应用以及将模型服务独立部署的分层式 Web 架构等几种思路。桌面应用能够在本地集成较完整的交互界面，但往往对用户运行环境和本地算力依赖较强；传统 Web 框架虽然具备成熟的服务组织能力，但如果将业务逻辑、模型推理和知识检索全部耦合在同一服务中，后续在 GPU 资源调度、模型迭代和接口维护方面容易增加实现复杂度。考虑到本文系统既涉及多轮问答交互，又依赖检索增强和大模型推理能力，因此采用分层式的 Web 系统实现方案更为合适。

在前端技术选择方面，常见方案包括 Vue、React 以及基于模板的服务端渲染框架。Vue 框架上手相对较快，适合中小型交互页面开发；传统模板渲染方式实现简单，但在复杂状态管理和流式交互展示方面灵活性相对不足。相比之下，React 采用组件化开发思想，在多轮会话展示、消息局部刷新和前端状态复用等方面具有更好的适应性，更适合构建具有持续交互特征的问答界面。本文系统需要实现历史会话切换、回答流式输出、引用证据展示以及后台知识管理等功能，因此最终选用 React 作为前端实现框架，以提高界面组织能力和交互扩展能力。

在业务后端技术选择方面，常见方案包括 Flask、Spring Boot 以及 Node.js 生态下的 Express 等。Spring Boot 工程体系成熟，但整体配置和学习成本相对较高；Flask 轻量灵活，适合封装模型推理接口，但若同时承担认证、会话管理和复杂业务编排，开发效率和异步处理优势并不突出。考虑到本文系统需要频繁处理前端请求转发、会话读写、流式响应和模型服务编排等任务，因此业务层选择基于 Node.js 的 Express 框架实现。Node.js 在高并发 I/O 和流式通信方面具有较好适应性，能够较方便地完成 SSE 数据转发、接口组织和多模块协同，从而满足在线问答场景下的后端服务需求。

在模型服务与数据支撑技术选择方面，本文将模型推理部分独立部署为 Python 服务，并采用 Flask 对外提供接口。这样做的原因在于，Embedding 模型、重排模型和生成模型的调用均依赖 Python 生态，若直接在业务后端中嵌入模型推理流程，不仅会增加服务耦合程度，也不利于 GPU 资源的独立管理。将模型推理单独封装为 Flask 服务后，一方面能够便于加载和管理深度学习模型，另一方面也有利于后续替换模型版本或调整 RAG 链路。

数据存储方面，系统选用 PostgreSQL 保存用户、会话、消息和文档元信息，并利用其对 JSONB 字段的支持存储半结构化问答内容；在知识检索方面，系统采用 FAISS 构建向量索引，以满足医学文本语义检索的效率需求。

综上所述，系统各模块的开发技术如表5.1所示。

表 5.1 开发技术

技术层次	开发技术
系统架构	分层式 Web 架构
前端框架	React
业务后端	Node.js + Express
模型服务	Python + Flask
数据与检索	PostgreSQL + FAISS

5.3 系统总体架构

本系统整体架构采用分层式设计，将交互逻辑、业务逻辑、模型能力与数据能力进行划分，各模块之间相对独立，能够在一定程度上实现故障隔离。系统架构如图5.1所示，主要由四个层次构成。

前端应用层只承担交互和状态管理，不直接参与模型推理，具体包括用户登录、会话管理、消息渲染、流式展示、引用证据呈现以及管理员知识库入口等功能。

业务服务层基于 Node.js，采用 Express 框架构建统一的 API 网关，用于对外提供服务接口。业务服务层主要负责身份认证与权限控制、会话上下文组织、消息持久化、模型服务编排和知识库维护。

模型推理层是一套独立的 Python 服务，部署在高性能 GPU 服务器上，基于 Flask 框架对外提供接口。该层主要负责向量数据库检索、相关文档重排序、提示词组装、模型推理及流式事件输出。模型服务对外暴露同步与流式两类接口，业务服务可以根据实际场景灵活选择调用方式。将推理服务独立部署后，可在不影响业务 API 的情况下单独升级模型和检索策略。

数据与索引层中使用关系型数据库保存用户、会话、消息与文档元数据；使用 FAISS 向量索引存储医学指南等医学资料，并将文本编码为向量构建索引结构以支持向

量检索和 BM25 检索。




图 5.1 系统架构图

5.4 系统流程设计

针对“三高”慢病管理场景，本文将问答流程划分为“输入解析—知识检索—上下文增强—答案生成”四个阶段。系统流程如5.2所示。




图 5.2 系统流程图

在输入解析阶段，系统会先接收用户发来的自然语言问句，再结合之前几轮对话的历史信息对查询做语义补全和规范化处理，从而让后续检索能更精准地锁定用户真正的意图。

在知识检索阶段，系统采用混合检索策略，一路是基于向量的语义检索，它依靠 Embedding 模型把文本映射到高维的向量空间中来表示语义、捕捉深层的语义相似性；另一路则是基于关键词的 BM25 检索，专门负责精确锁定关键字上的匹配，特别针对于医学领域海量的专业术语。如果只依赖向量检索，有可能会漏掉或误判某些关键医学名词，于是把 BM25 作为补充手段能有效提高整个检索结果的准确度和覆盖面，两路结果检索完成之后，系统再经过融合、排序和重排这几道处理，筛选出最相关的一批文本片段。

在上下文增强阶段，系统将上一阶段筛选出的文本片段，用户问题和对话历史，通过事先设计好的 prompt 模板结合，构建成一份结构清晰的输入，让模型在阅读时能轻易分辨出哪一部分来自使用者的提问、哪一部分是从知识库调出来的参考资料。

在答案生成阶段，模型依据这份组合好的输入来产出回答，以流式方式逐字输出。在生成全部完成后，系统会把检索到的文献信息返还给用户当成参考，同时也会记录下这次输入和输出所消耗的 token 数量，后者将会跟对话历史一同保存进数据库，为下一次用户提问时构建多轮对话上下文时估算长度提供依据。

5.5 业务层实现

业务层后端服务基于 Node.js 的框架 Express 开发，负责用户身份认证与权限控制、会话管理、消息持久化、模型服务编排与知识库运维接口。

5.5.1 后端服务架构设计

系统后端入口位于统一应用服务中，主要路由模块包括用户认证、会话管理、消息管理、模型调用和知识库管理。各模块职责如下：

- (1) 认证模块：提供注册与登录接口，完成密码加密与令牌签发；
- (2) 会话模块：管理会话创建、查询、更新与软删除；
- (3) 消息模块：管理消息读写与 token 信息回填；
- (4) 模型模块：接收问题请求，调用本地模型服务并返回生成结果；
- (5) 知识库模块：提供文档元信息管理、索引状态查询与重建能力。

5.5.2 用户身份认证

用户身份认证在本系统中不是单独的“登录功能”，而是后续会话管理、权限控制和后台维护操作的统一入口。由于系统同时面向普通用户问答和管理员知识库维护两类场景，后端既要判断用户是否已登录，也要识别用户权限等级，确保不同角色只能访问对应功能。

认证模块主要包括注册、登录和令牌校验三部分。用户注册时，后端接收用户名与密码等基础信息，并在密码加密后写入数据库，避免敏感数据明文存储；用户登录成功

后，系统会签发包含身份标识和权限字段的访问令牌，前端在访问受保护接口时需要携带该令牌完成身份校验，后端再根据令牌信息判断请求是否合法以及用户权限范围。通过这一流程，普通用户可正常访问问答能力，知识库管理与索引维护等高权限操作仅向管理员开放，从而在保证使用便利性的同时控制系统安全边界。

系统采用 JWT 令牌校验机制。前端在请求头中携带 `Authorization: Bearer <token>` 后，后端认证中间件会先解析令牌格式，再使用服务端密钥校验签名与有效期，并检查载荷中的用户标识和权限字段。若令牌缺失、签名不合法或已过期，接口会直接返回未授权状态（如 401）；若用户身份有效但权限不足，则返回禁止访问状态（如 403）。校验通过后，系统将用户信息写入请求上下文，供后续会话、消息和知识库接口复用，以避免重复解析并保证权限判断一致性。

5.5.3 会话管理

会话管理是后端业务逻辑中的核心部分。系统为每个用户维护独立会话空间，并将每轮对话中的角色、正文、时间戳、引用证据和统计信息写入数据库，以支撑历史记录查询和多轮上下文组织。

在具体流程上，当用户提交问题时，后端会先判断当前会话是否存在；若不存在，则创建新会话并写入用户消息；若已存在，则直接在原会话下追加消息。模型返回回答后，系统再将助手回答与证据一并写回，并同步更新会话摘要和更新时间。这样既能保证多轮对话连续性，也方便前端展示最近会话状态。

5.5.4 消息流式转发

为了缩短用户等待时的空白感，后端加入了面向前端的流式转发机制，Node.js 服务接收到模型服务返回的增量文本后，会继续通过 SSE 把内容持续发送到前端，这样回答还没有完全生成时，界面上就已经能看到文本逐步显示出来，整体交互会更连贯。

具体处理时，后端会先把用户消息和助手占位消息写入数据库，再和模型服务建立流式连接，后续只要模型服务持续返回新的文本片段，后端就会把这些内容整理成前端可以解析的事件数据并立即转发出去；等回答生成结束后，再统一回写完整结果和相关统计信息，这样一来，界面能够及时更新，数据库里保存的内容也能保持完整一致。

5.5.5 知识库管理接口

知识库管理接口主要面向管理员使用，任务是把文档维护和索引管理这一类后台操作组织起来，接口内容包括文档元信息查询、文本上传入库、索引状态查看、增量更新和全量重建等，这样知识库相关操作就能放在统一入口中处理，管理起来也更方便。

在知识入库过程中，后端接收到文本内容和来源信息后，会继续调用后续处理流程，依次完成文本清洗、内容切分、Embedding 编码和索引写入，写入成功以后，再触发模型服务对索引进行热更新；如果中间某个环节出现问题，系统会把错误状态记录下

来，并返回较明确的提示信息，方便后面排查和恢复，这样处理之后，知识更新就不再是彼此分散的单独步骤，而是能和在线问答过程更自然地衔接起来。

5.6 数据库设计

后端数据库使用 PostgreSQL，PostgreSQL 可支持使用“JSONB 内容字段”的存储。在保存用户与模型的对话历史时，用户消息和模型消息、系统消息的结构并不完全相同，例如：模型消息在返回时会携带 RAG 过程中检索到的资料信息，而用户消息则不需要这个字段。面对这类字段需求不同的情况，JSONB 格式比常规的关系型表设计要灵活得多，能很好地应对问答消息里字段不固定、结构可能时常变动的状况。系统将用户、会话、消息等较为固定的实体信息保存在关系型字段里；将消息正文、引用资料信息、Token 消耗等可选字段的内容存放在 JSONB 字段中。通过这一混合存储方式，就能用同一张表适应模型消息和用户消息的不同格式，不必再去为每一种消息单独建表，或在一张表中留下大量的空字段。

表5.2中列出了系统中关键的数据表及其主要字段，其中，users 表用于存储用户信息，并且为每个用户分配独特的 id，用户 id 是对其他表查询的关键信息；conversations 表用于存储会话元信息（标题、更新时间、软删除标记等）；messages 表用于保存逐轮对话内容与 token 统计信息；medical_documents 表用于保存知识文档元数据；knowledge_index_meta 表用于记录索引状态（dirty/running/synced/error）。

表 5.2 后端核心数据表

数据表名	核心字段	作用
user	id, password_hash, is_admin	用户身份与权限管理
conversations	user_id, title, last_message, is_deleted	会话元信息管理
messages	conversation_id, role, content, tokens	多轮消息与 token 信息存储
medical_documents	title, source, ingest_key, tags	知识文档元信息维护
knowledge_index_meta	status, last_reindexed_at, last_error	索引状态追踪与运维监控

除关系型数据库外，系统还使用 FAISS 对知识文本的 Embedding 向量进行独立存储与管理，以支撑 RAG 流程中的高效向量检索。知识文档在完成清洗与切分后，会先由 Embedding 模型编码为稠密向量，再写入 FAISS 索引文件中；同时，每个文本片段对应的文档标识、分段标识及来源信息仍保存在 PostgreSQL 中。这样设计的原因在于，向量数据更适合交由 FAISS 执行相似度计算与近邻检索，而文档元数据、业务实体和状态信息则更适合由关系型数据库统一维护。

在索引结构设计上，系统采用基于内积相似度的 IndexFlatIP 作为底层索引，并在其外层封装 IndexIDMap2，使每一个文本片段向量都能够绑定显式的 faiss_id。通过这种设计，索引不仅能够完成初始批量构建，还支持后续按照 ID 进行增量维护。当知识库

中新增文档时，系统在完成文本切分和向量编码后，可以直接通过 `add_with_ids` 将新增片段追加到现有索引中，而不必每次都重新构建整个向量库；当文档被删除或更新时，也可以基于片段 ID 对相应向量执行移除或替换操作。相较于仅适合静态构建的索引方式，这种 ID 感知的索引结构更适合医学知识库持续更新的应用场景。

为了保证索引文件与业务数据始终保持一致，系统通过 `knowledge_index_meta` 表记录索引状态、最近重建时间和异常信息，并在文档新增、更新或删除后触发增量更新或全量重建流程。通过这种“FAISS 负责向量召回、PostgreSQL 负责业务管理”的协同方式，系统既能够满足医学问答对检索效率的要求，也能够保证知识来源的完整性、可追溯性以及后续索引维护的灵活性。

5.7 模型推理服务实现

5.7.1 模型服务功能设计

本文将模型推理部分独立部署为 Python 服务，并和业务后端解耦。这样设计，一是可以把 GPU 资源集中用于检索和推理任务，减少和业务逻辑混合部署带来的资源竞争，二是后续即使替换 Embedding 模型、重排模型或生成模型版本，也不需要同步改动业务层接口。

模型服务主要承担四个关键任务，一是接收业务层转发的问题、历史对话和生成参数，二是完成查询向量化、候选召回和重排，输出可供生成阶段使用的证据集合，三是按照提示词模板把问题、历史消息和检索证据组织成统一输入，再调用生成模型产出回答，四是以同步或流式方式把结果返回业务层，同时附带引用证据和必要状态信息。经过这样的拆分后，模型服务实际上成为系统中连接“知识检索”和“回答生成”的核心执行节点。

5.7.2 模型加载与推理组织

第三章和第四章已经分别对检索流程、Prompt 模板和模型输入组织进行了分析，因此本节主要说明这些方法在系统中的实际加载方式与运行组织方式。考虑到医学问答服务属于在线交互场景，系统若在每次请求到达后再动态加载 Embedding 模型、重排模型和生成模型，将带来较大的权重读取与显存分配开销，不利于响应时延控制。基于这一考虑，本文采用服务启动时一次性完成模型初始化的方式，将相关模型预先加载到推理环境中，并在服务运行期间保持常驻状态，使在线请求能够直接复用已有推理资源，从而提高系统响应的稳定性。

在生成模型组织方面，系统采用“基础模型 + 领域适配权重”的加载方式，即以通用大语言模型作为底座，在推理阶段叠加医学问答任务训练得到的 LoRA/DPO 适配权重。这样既保留了领域微调后模型在医学术语表达、回答风格控制和风险边界把握方面的优化效果，有便于后续对模型进一步的优化，增强了系统的可扩展性。

在在线推理过程中，系统接收业务层传入的问题和会话上下文后，先调用已加载的检索相关模型完成证据召回与筛选，再按照设计好的输入模板构造生成上下文，最后由生成模型输出回答结果。

这种“预加载 + 统一编排”的组织方式将模型初始化、检索调用和回答生成纳入同一推理框架之中，有助于减少重复加载带来的性能损耗，并保持在线服务过程的连续性。同时，由于不同模型和处理环节之间边界相对清晰，系统在后续替换 Embedding 模型、调整重排策略或升级生成模型时，也不需要对整体服务结构进行大幅修改，从而为系统的持续优化和扩展提供了较好的工程基础。

5.7.3 接口设计与结果返回

为了适应不同交互场景，模型服务对外提供同步调用和流式调用两类接口。同步接口更适合调试、批量测试和非实时任务，调用方在一次请求中等待完整回答返回；流式接口更适合在线问答场景，模型服务会把回答拆成连续文本片段逐步输出，让前端能够边接收边展示，减少等待完整回答时的停顿感。

在返回内容上，模型服务不只输出最终回答文本，还会同时返回检索证据、引用来源和必要状态字段。对于流式模式，服务通过事件形式持续返回增量内容，并在结束时统一发送完成标记；如果推理过程中出现异常，则返回错误事件并附带错误信息，便于业务层捕获和提示。通过这种接口设计，系统能够同时支持实时问答与普通推理任务，也便于后续功能扩展与服务维护。

5.7.4 检索链路调度

在系统实现上，RAG 服务通过统一调度入口管理检索相关步骤。系统不会把 BM25 检索、向量检索、融合排序和重排分别暴露为分散接口，而是由模型服务在内部完成链路编排，对外只表现为一次“检索增强问答”调用。这样设计可以减少业务层对模型服务检索细节的依赖，后续即使调整召回方式或更换重排模型，上层接口也不需要同步修改。

在调度过程中，系统先根据用户问题生成检索查询，再并行触发不同召回路径，随后对候选结果做统一编号、去重和排序。完成排序后，系统只保留数量受控的高相关证据进入下游生成流程，避免把大量低价值文本直接送入模型。RAG 服务在系统中的作用不只是“把资料找出来”，更重要的是在有限上下文窗口内尽可能选出最值得保留的证据。

5.7.5 证据封装与结果回传

完成检索与筛选后，RAG 服务还需要把中间结果整理成业务层和前端都能直接使用的结构。基于这一目标，系统会把最终证据统一封装为 JSON 对象，字段中包含文本内容、来源信息、标题路径、相关性顺序和必要标识。这样处理后，生成模型可以直接

使用这些证据构造输入，业务后端也可以在回答完成后把同一份证据回写数据库，前端则能够基于这些字段展示“引用来源”或“检索依据”等信息。

在结果返回阶段，RAG 服务输出的不仅是最终回答文本，还会同时返回检索证据、引用元数据和必要状态字段。将检索证据与生成结果作为同一次调用的统一返回内容后，系统能够较好保持“回答内容”和“回答依据”之间的一致性。

5.8 前端实现

前端采用 React 构建，并通过路由机制完成页面组织与切换，整体划分为登录页、注册页、问答主页和知识库管理页。这样的页面结构能够满足系统主要功能需求，并提高前端页面的组织性与交互清晰度。

5.8.1 登录与注册页面

根据系统使用流程，前端将登录页和注册页设置为统一入口，用来完成身份验证和基础账户信息提交。登录与注册页面如图5.3和图5.4所示，登录页提供账号、密码输入与登录操作，用户通过身份校验后进入问答主页；注册页用于新用户信息登记。



图 5.3 登录页面

5.8.2 问答主页

问答主页是系统的核心页面，也是用户与系统进行交互的主要界面。如图5.5所示，页面采用侧边栏与主内容区结合的布局方式：侧边栏用于展示历史会话、新建会话和退出登录等常用操作，主内容区用于展示消息内容、问题输入框和模型回答结果。该结构能够同时兼顾历史记录浏览与当前问答操作，较好适配“三高”场景下连续追问的使用需求。

在交互流程上，问答主页围绕多轮会话管理和流式回答展示展开。系统进入主页后，会优先加载用户已有会话，并按更新时间显示在侧边栏；当用户切换会话时，页面会同步加载对应历史消息。用户发送问题后，前端先插入用户消息和助手占位消息，再



图 5.4 注册页面



图 5.5 问答主页

通过流式接口接收模型返回的增量文本，使回答逐步展开。如图5.6所示，回答生成结束后，页面会展示检索证据，使答案内容与支撑依据在同一界面中统一呈现。

5.8.3 知识库管理页面

除普通用户问答页面外，系统还设计了面向管理员的知识库管理页面，用于支持医学文档维护与知识更新。系统将知识库管理能力独立为单独页面，并通过管理员身份识别控制页面可见性。

如图5.7所示，知识库管理页面主要用于展示知识文档列表、执行文档上传入库、查看索引状态，以及触发必要的知识维护操作。和命令行或脚本式维护相比，页面化管理入口让知识更新流程更直观，也更适合系统上线后的日常维护。这一页面不仅补全了前




图 5.6 检索结果展示



图 5.7 知识库管理页面

端功能，也体现了系统在工程应用中对知识持续更新能力的支持，使问答服务与知识维护形成较完整闭环。

5.9 本章小结

本章围绕医学问答系统的设计与实现展开论述。首先，根据“三高”慢性病问答场景的特点，对系统的功能需求与非功能需求进行了分析，并在此基础上说明了系统开发技术的选择依据。随后，结合系统总体架构与业务流程，对后端服务、数据存储、模型服务以及前端页面实现进行了完整的介绍，说明了系统如何将知识检索、模型生成、多轮会话和证据展示等能力组织为统一的在线问答流程。

6 总结与展望

6.1 总结

随着“三高”慢性病患者数量不断增加，围绕血压、血糖、血脂管理的日常健康咨询需求持续增长。与一次性诊疗不同，“三高”管理更强调长期随访、重复咨询和生活方式干预，因此患者在日常生活中往往会提出大量细致且连续的问题。传统线下医疗服务在即时响应、高频咨询和长期陪伴方面存在一定局限，而普通互联网检索又容易出现信息来源分散、专业性不足和结论不一致等问题。与此同时，大语言模型虽然在自然语言理解与生成方面展现出较强能力，但若直接应用于医学问答场景，仍然可能出现知识幻觉、回答依据不足以及安全边界不清等风险。因此，研究如何将外部医学知识与大语言模型有效结合，构建兼顾准确性和可解释性的医学问答系统。

本文主要研究内容和结论如下：

- (1) 针对医学问答系统对知识可靠性和可追溯性的要求，本文完成了面向“三高”场景的医学知识库构建工作。研究中对政策文件、临床指南、专家共识及相关科普资料进行了采集、清洗、格式统一和结构整理，并结合医学文本特点设计了语义切分方法，在提高知识片段可检索性的同时尽量保留上下文语义完整性。此外，本文还组织了文档来源、标题层级和时间信息等元数据，为后续检索、引用展示和知识追溯提供了支撑。该部分工作为整个 RAG 问答系统提供了可靠的外部知识基础。
- (2) 针对医学问题中同时存在术语精确匹配需求和语义理解需求的特点，本文设计了结合 BM25 与向量检索的混合检索方法，并引入重排机制对候选证据进行进一步筛选与排序。实验结果表明，混合检索结合重排策略在召回效果上优于单一 BM25 检索和单一向量检索，能够更有效地兼顾医学术语精确性与语义相关性，为后续答案生成阶段提供质量更高的检索证据。
- (3) 针对基础大语言模型直接应用于医学问答时存在的回答风格不稳定、事实表达不够严谨和安全边界把握不足等问题，本文采用 LoRA 参数高效微调和 DPO 偏好优化相结合的方法进行领域适配。其中，LoRA 用于以较低训练成本实现模型对医学问答任务的基础适应，DPO 则进一步通过偏好数据优化模型对高质量回答的倾向性。评测结果表明，经过 DPO 优化后的模型在综合得分、事实正确性、完整性和安全性等维度上整体优于基础模型，说明偏好优化能够有效提升医学问答场景下的回答质量与稳健性。
- (4) 在系统实现方面，本文完成了从前端页面到后端服务、从模型推理到知识维护的整体工程设计。系统前端围绕登录注册、问答主页和知识库管理页面展开，实现了用户身份验证、多轮对话交互、流式回答展示和引用证据可视化等功能；后端

服务承担会话管理、消息持久化、模型调用编排和知识库运维接口等任务；模型服务则负责将前文设计的检索方法、**Prompt** 模板和生成模型推理过程组织为统一的在线问答流程。通过这种分层架构设计，系统实现了知识检索、答案生成、证据返回和多轮交互等功能。

6.2 展望

尽管本文已经完成系统研究与实现，但仍存在两方面有待改进。

第一，模型优化方面，当前偏好训练数据的规模与覆盖范围仍然有限，对复杂医学问题和边界场景的约束能力还有提升空间；后续可引入更高质量偏好数据，并探索监督微调、偏好优化与检索增强的联合训练方式，以进一步提高模型稳定性与泛化能力。

第二，知识更新与应用扩展方面，当前系统主要面向“三高”慢性病场景构建知识库和问答流程，后续可进一步引入更多疾病领域的权威资料，并完善知识库的增量更新、版本管理与自动重建机制，使系统能够更方便地扩展到其他慢性病或医学场景中，从而增强系统的通用性。

参考文献

- [1] 张可妙, 乔静怡, 邓清文, 等. 居民慢性病患者现状及常见慢性病共病模式研究[J]. 中国卫生事业管理, 2026, 43(01): 62-67.
- [2] 李小鹏, 喻慧心, 常青, 等. 医疗基础大模型的应用现状、挑战及展望[J]. 医学信息学杂志, 2026, 47(01): 16-23.
- [3] Ji Z, Lee N, Frieske R, et al. Survey of hallucination in natural language generation[J]. ACM Computing Surveys, 2023, 55(12): 1-38.
- [4] 中国互联网络信息中心. 第 56 次《中国互联网络发展状况统计报告》[J]. 传媒论坛, 2025 (15): 121.
- [5] 孟群, 尹新, 梁宸. 中国“互联网 + 健康医疗”现状与发展综述[J]. 中国卫生信息管理杂志, 2017, 14(02): 110-118.
- [6] 牟岚, 金新政. 远程医疗发展现状综述[J]. 卫生软科学, 2012, 26(06): 506-509.
- [7] Singhal K, Tu T, Gottweis J, et al. Toward expert-level medical question answering with large language models[J]. Nature Medicine, 2025, 31: 943-950.
- [8] 白培发, 黄宗浩, 王奕. 大模型在智慧医院的应用研究综述[J]. 计算机应用与软件, 2024, 41 (07): 1-5+19.
- [9] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]. Advances in Neural Information Processing Systems 30 (NeurIPS 2017). 2017: 5998-6008.
- [10] Zucchet N, Orvieto A. Recurrent neural networks: vanishing and exploding gradients are not the end of the story[A]. 2024. arXiv: 2405.21064.
- [11] 李华旭. 基于 RNN 和 Transformer 模型的自然语言处理研究综述[J]. 信息记录材料, 2021, 22 (12): 7-10.
- [12] Touvron H, Lavril T, Izacard G, et al. Llama: Open and efficient foundation language models[A]. 2023. arXiv: 2302.13971.
- [13] Qwen, :, Yang A, et al. Qwen2.5 technical report[A]. 2025. arXiv: 2412.15115.
- [14] Su J, Lu Y, Pan S, et al. Roformer: Enhanced transformer with rotary position embedding[A]. 2023. arXiv: 2104.09864.
- [15] Ainslie J, Lee-Thorp J, de Jong M, et al. Gqa: Training generalized multi-query transformer models from multi-head checkpoints[A]. 2023. arXiv: 2305.13245.

-
- [16] Dao T, Fu D Y, Ermon S, et al. Flashattention: Fast and memory-efficient exact attention with io-awareness[A]. 2022. arXiv: 2205.14135.
 - [17] Ziegler D M, Stiennon N, Wu J, et al. Fine-tuning language models from human preferences[A]. 2020. arXiv: 1909.08593.
 - [18] Schulman J, Wolski F, Dhariwal P, et al. Proximal policy optimization algorithms[A]. 2017. arXiv: 1707.06347.
 - [19] Rafailov R, Sharma A, Mitchell E, et al. Direct preference optimization: Your language model is secretly a reward model[A]. 2024. arXiv: 2305.18290.
 - [20] Lewis P, Perez E, Piktus A, et al. Retrieval-augmented generation for knowledge-intensive nlp tasks [C]. NIPS '20: Proceedings of the 34th International Conference on Neural Information Processing Systems. Red Hook, NY, USA: Curran Associates Inc., 2020.
 - [21] Chen J, Xiao S, Zhang P, et al. M3-embedding: Multi-linguality, multi-functionality, multi-granularity text embeddings through self-knowledge distillation[A]. 2025. arXiv: 2402.03216.
 - [22] Cormack G V, Clarke C L A, Buettcher S. Reciprocal rank fusion outperforms condorcet and individual rank learning methods[C]. SIGIR '09: Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval. New York, NY, USA: Association for Computing Machinery, 2009: 758–759.

谢 辞

论文至此落笔，本科四年的学习生活也即将画上句号。回望这段时光，从初入校园时的懵懂，到如今完成毕业设计 with 论文撰写，一路上的成长与收获都值得珍惜。

首先，衷心感谢我的指导老师李优老师。在课题研究与论文撰写过程中，李老师给予了我耐心细致的指导与帮助。从研究思路的确定，到系统实现与论文修改，老师严谨认真的态度让我受益匪浅。

同时，感谢大学期间所有授课老师的教导与帮助。正是课堂上的积累与实践中的锻炼，让我逐渐具备了完成本课题的能力。

感谢一路陪伴我的同学与朋友。那些一起学习、讨论与努力的日子，让大学生活留下了许多珍贵回忆。

最后，感谢家人一直以来的理解、支持与陪伴。你们始终是我最坚定的依靠。