桂林電子科技大学
GUILIN UNIVERSITY OF ELECTRONIC TECHNOLOGY

本科毕业设计（论文）

题目： 基于 RAG 的“三高”慢性病医学问答系统设计与实现

学　　号： 2200820924

姓　　名： 牛嘉贺

学　　院： 计算机与信息安全学院

专　　业： 计算机科学与技术

指 导 教 师： 李优

指导教师职称： 教授

2026 年 5 月 1 日

本科生毕业设计（论文）独创性声明

本人声明所呈交的毕业设计（论文）是我个人在指导老师指导下进行的工作及取得的成果。尽我所知，除了文中特别加以标注和致谢中所罗列的内容以外，文中不包含其他人或其它机构已经发表或撰写过的成果；也不包含为获得桂林电子科技大学或其他教育机构的学位或证书而使用过的材料。其他同志对本工作的启发和所做的任何贡献均已在毕业设计（论文）中做了明确的说明并表示了谢意。

毕业设计（论文）若有不实之处，本人承担一切相关责任。

本人签名：　　日期：

本科生毕业设计（论文）使用授权说明

桂林电子科技大学有权保留并向国家有关部门或机构送交毕业设计说明书（论文）的复印件，允许毕业设计（论文）被查阅和借阅。本人授权桂林电子科技大学可以公布毕业设计（论文）的全部或部分内容，可以采用影印、缩印或其它复制手段保存、汇编毕业设计（论文）。

作者签名：　　日期：

导师签名：　　日期：

摘 要

随着人口老龄化和生活方式变化，慢性病人群规模持续扩大，高血压、高血糖和高血脂等“三高”相关健康咨询需求不断增加，传统线下问诊在连续性和及时性方面存在一定限制。近年来，大语言模型快速发展，在自然语言理解与生成任务中展现出较强能力，也推动了智能问答系统在医疗健康领域的应用探索。

但在医学场景中，直接使用通用大语言模型仍存在明显不足，例如知识幻觉、证据依据不清、风险提示不足以及回答稳定性不够等问题，难以满足医学问答对事实准确性、可追溯性和安全边界的要求。针对这些问题，本文围绕“三高”慢性病咨询场景，设计并实现了一套基于检索增强生成（Retrieval-Augmented Generation, RAG）的医学问答系统，并引入直接偏好优化（Direct Preference Optimization, DPO）进一步提升回答质量。

本文研究内容主要包括四个方面：一是构建面向“三高”主题的医学知识库，对多源医学文本进行清洗、格式统一、语义切分和元数据组织；二是设计 BM25 与向量检索结合的混合召回策略，并引入重排机制提高证据相关性；三是通过 Prompt 与上下文结构化组织，将检索证据稳定注入生成过程，并采用 LoRA+DPO 训练优化模型在事实表达、完整性与安全边界方面的输出偏好；四是完成前后端分离的系统实现，构建业务服务、模型服务和知识库管理模块，支持多轮问答、流式输出、引用展示和索引更新。

实验结果表明，混合检索在召回覆盖与相关性上优于单一路径检索，DPO 优化后模型在偏好胜率和综合评分上均优于基础模型，并在事实正确性、信息完整性和风险样本控制方面表现更稳健。总体来看，本文方案能够在保持交互效率的同时提升医学问答的准确性、可解释性和可用性，可为垂直医学问答系统的设计与实现提供参考。

关键词：慢性病医学问答；检索增强生成；混合检索；大语言模型；系统设计与实现

Abstract

With population aging and lifestyle changes, the number of patients with chronic diseases continues to grow, and consultation demands for the “three highs” (hypertension, hyperglycemia, and hyperlipidemia) are increasing rapidly. In parallel, large language models (LLMs) have advanced quickly and shown strong capabilities in natural language understanding and generation, which has encouraged their application in medical question answering.

However, directly applying general-purpose LLMs to medical scenarios still faces clear limitations, including hallucination, weak evidence grounding, insufficient risk reminders, and unstable response quality. These limitations make it difficult to satisfy strict medical requirements on factual accuracy, traceability, and safety boundaries. To address these issues, this thesis designs and implements a medical QA system for the “three highs” scenario based on Retrieval-Augmented Generation (RAG), and further improves response quality with Direct Preference Optimization (DPO).

The study includes four major parts. First, a domain-specific medical knowledge base is constructed from multi-source texts through cleaning, format normalization, semantic chunking, and metadata organization. Second, a hybrid retrieval strategy combining BM25 and dense vector retrieval is proposed, together with reranking to improve evidence relevance. Third, structured prompt and context construction is used to inject retrieved evidence into generation, while LoRA+DPO training is applied to optimize factuality, completeness, and safety-oriented response preference. Fourth, a decoupled front-end/back-end system is implemented with business service, model service, and knowledge management modules, supporting multi-turn dialogue, streaming output, citation display, and index updates.

Experimental results show that hybrid retrieval outperforms single-path retrieval in both coverage and relevance, and the DPO-optimized model consistently surpasses the base model in preference win rate and overall quality, with clearer gains in factual correctness, completeness, and risk control. Overall, the proposed system improves medical QA accuracy, interpretability, and robustness while preserving interactive efficiency, and provides a practical reference for vertical medical QA system design and deployment.

Keywords: Chronic Disease Medical QA; Retrieval-Augmented Generation; Hybrid Retrieval; Large Language Model; System Design and Implementation

目 录

1 绪论 1
1.1 课题的研究背景与意义 1
1.2 国内外研究现状 1
1.2.1 互联网问诊的发展现状 1
1.2.2 传统医学问答模型的发展现状 2
1.3 本文研究内容 3
1.4 论文组织结构 3
2 相关理论和技术介绍 4
2.1 大语言模型概述 4
2.1.1 Transformer 模型 4
2.1.2 现代大模型 5
2.1.3 模型训练技术 6
2.2 检索增强生成（RAG）技术 7
2.3 本章小结 8
3 医学知识库构建与检索方法 9
3.1 医学知识库构建方法 9
3.1.1 数据来源 9
3.1.2 数据预处理 9
3.1.3 文本语义切分 9
3.1.4 Embedding 向量化表示 11
3.1.5 向量数据库构建 11
3.2 医学文本检索方法 11
3.2.1 BM25 关键词检索原理 11
3.2.2 向量检索原理 12
3.2.3 混合检索策略 12
3.3 实验与结果分析 13
3.4 本章小结 14
4 医学问答模型构建与优化 15
4.1 RAG 问答生成方法 15

4.1.1检索增强生成流程 15
4.1.2Prompt 与上下文构建 15
4.2 基于 DPO 的模型优化策略 16
4.2.1偏好数据构建 16
4.2.2DPO 训练流程 17
4.3 实验结果分析 18
4.3.1DPO 训练过程分析 18
4.3.2回答质量评测结果 19
4.4 本章小结 21
5 系统设计与实现 22
5.1 系统设计目标 22
5.2 系统总体架构 22
5.3 系统流程设计 24
5.4 业务层实现 24
5.4.1后端服务架构设计 25
5.4.2会话管理 25
5.4.3数据库 25
5.4.4流式转发 26
5.4.5知识库管理接口 26
5.5 模型与 RAG 服务实现 26
5.5.1模型服务功能设计 26
5.5.2模型加载与推理组织 27
5.5.3接口设计与结果返回 27
5.5.4RAG 请求编排流程 27
5.5.5检索链路调度 28
5.5.6证据封装与结果回传 28
5.5.7索引更新与一致性维护 28
5.6 前端实现 29
5.6.1前端 UI 架构与路由设计 29
5.6.2对话交互与流式渲染实现 29
5.6.3消息展示与检索证据可视化 29
5.7 本章小结 30

6 全文总结与展望 31
6.1 全文总结 31
6.2 后续工作展望 31
参考文献 32
谢辞 34

1 绪论

1.1 课题的研究背景与意义

随着人口老龄化不断加深，慢性病管理已成为公共健康领域的长期议题。在常见慢性病中，高血压、高血糖和高血脂患者数量大、管理周期长、复发风险高，患者往往不能只依赖少数几次门诊完成健康管理。与急性疾病不同，慢性病管理更强调日常监测和持续干预，患者在真实生活中会频繁遇到诸如指标是否异常、饮食如何调整、药物需不需要复查、症状是否需要就医等具体问题[1]。这类问题看似琐碎，却直接影响治疗依从性和病情控制效果。

传统医疗服务以线下诊疗为主，患者通常只有感到身体不适或按固定的时间安排才会选择就医，患者难以获得持续、及时的健康指导。同时，由于医疗资源分布不均以及医生数量相对有限，患者在非就诊期间获取专业医疗建议的渠道较为有限。所以很多患者选择去互联网搜索相关健康信息，但互联网上信息来源复杂、质量参差不齐，用户很难从中获得可靠的医学建议。

近年来，大语言模型（Large Language Model，LLM）发展很快，在理解和生成文本方面都有明显提升，通过大语言模型构建智能医疗问答系统成为可能。基于 LLM 的问答系统能够理解用户提出的问题，并生成相对流畅的回答，在医疗咨询等场景中展现出一定应用潜力。但是将通用 LLM 直接应用在医学领域时，会面临知识更新滞后、事实错误（幻觉）以及缺乏依据等问题[2]。

基于这一背景，本文引入检索增强生成（Retrieval-Augmented Generation，RAG）技术，将外部医学知识库与大语言模型结合起来[3]。其核心思路不是让模型“凭记忆作答”，而是在生成前先检索相关医学资料，再据此组织回答。这样做的价值主要体现在三个方面：第一，可以降低医学问答中的幻觉风险；第二，可以让回答建立在可追溯的证据基础上；第三，更便于系统随知识更新而持续维护。因而，围绕“三高”慢病场景研究并实现一套基于 RAG 的医学问答系统，既具有现实应用意义，也具有一定的技术研究价值。

1.2 国内外研究现状

1.2.1 互联网问诊的发展现状

随着互联网技术和智能手机的普及，互联网问诊模式出现并迅速发展。根据中国互联网络信息中心第 57 次《中国互联网络发展状况统计报告》显示，截至 2025 年底，中国网民规模达 11.25 亿，互联网普及率突破 80%[4]。互联网问诊依托其便捷高效、实时互动、及良好的隐私保护特性等优势，迅速普及，吸引了大量互联网企业、传统医疗机构及新兴在线医疗平台积极参与[5]。目前，国内的互联网医疗代表性平台有微医、好大

夫在线、京东健康、平安健康和阿里健康等，其主要提供医生在线问诊、健康信息发布以及购药等服务。这些平台更多是作为传统线下医疗服务的补充形式，在一定程度上提升了患者获取医疗信息的便利性。不过，平台提供的信息质量参差不齐，不同来源之间可能存在内容差异，影响用户判断；在线问诊以人工问答为主，受限于有限的医疗资源，患者还是会面临回复不及时等问题。

国外的医疗平台则更注重于远程医疗。例如，瑞典的 KRY 和美国 Teladoc Health、Doctor on Demand 等平台实行线上预约并利用会议视频实时问诊，让患者在家里即可享受到专业的医疗问诊[6]。但这类服务仍有很多不足，首先是患者可能需要支出额外的费用，以享受远程问诊的服务；而且平台签约医生数量相对固定，高峰时段还需预约排队；如果涉及身体检查的情况，仍需要去线下医院就诊。

现阶段互联网问诊仍主要依赖人工医生答复，其服务能力、响应效率和服务成本都受到现实医疗资源的制约。在这一背景下，如何借助自然语言处理与智能问答技术，为用户提供更及时、更稳定的医学信息支持，逐渐成为医学人工智能研究的重要问题，因此也推动了医学问答模型的持续发展。

1.2.2 传统医学问答模型的发展现状

早期医学自然语言处理模型主要集中在医学术语识别、实体抽取和文献理解等任务上，代表性工作包括 BioBERT、BlueBERT、ClinicalBERT 和 PubMedBERT 等。这类模型大多建立在 BERT 框架之上，通过 PubMed 文献、临床记录或生物医学语料继续预训练，使模型在医学词汇和专业语义建模方面明显优于通用语言模型。其主要价值在于提升医学文本表示能力，为后续问答、分类和关系抽取等任务提供基础，但这类模型主要是以理解任务为主。

随着大模型技术的发展，医学问答研究进一步转向生成式模型。例如，由 Google 提出的 Med-PaLM 和 Med-PaLM 2 模型，Med-PaLM 系列模型是专门针对于医学领域的大语言模型，Med-PaLM 通过医学领域微调和人工评估，使其在医学考试题、患者咨询和临床推理任务中相较于通用大语言模型有更好的表现，Med-PaLM 也是第一个在美国医师执照考试样例问题中获得“合格”的模型[7]。国内的科研机构也在积极推进大模型在医学领域的应用，也推出了许多针对于医学领域的大模型，例如：DoctorGLM、华佗 GPT 等。DoctorGLM 是基于 ChatGLM 的中文问诊模型，其对通用大语言做了针对医疗领域进行微调与优化工作；香港中文大学和深圳大数据研究院的研究团队推出的华佗 GPT-o1，首次将推理能力融入到了医学大模型。

医学问答模型虽然已经从 BioBERT、PubMedBERT 一类的领域预训练模型发展到 Med-PaLM、HuatuoGPT、DISC-MedLLM、MedFound 等生成式医学模型，但在真实应用场景中仍存在明显不足。其一，很多模型在考试题或标准问答集上表现较好，但面对日常慢病咨询中的口语化表达、连续追问和个性化问题时，稳定性仍然不足。其二，纯

生成式模型往往难以同时满足“回答自然”和“证据清晰”这两个要求，尤其在治疗建议、药物说明和风险判断等问题上更容易暴露安全边界问题。其三，现有研究更多关注模型能力本身，而对知识更新、检索链路、证据展示和系统落地闭环关注不足。

1.3 本文研究内容

针对“三高”慢性病场景下大语言模型在可信性、安全性以及系统落地方面存在的问题[8]，本文围绕基于检索增强生成（Retrieval-Augmented Generation, RAG）的医学问答系统展开研究与实现。本文主要工作包括面向垂直医疗场景的关键技术设计以及系统工程实现。

本文的具体研究内容如下：

（1）围绕“三高”相关慢性病主题构建医学知识库，对相关政策文件、临床诊疗指南、健康科普资料以及互联网医学文本等数据进行整理和预处理，并通过文本切分和向量编码等方式，形成适用于检索增强生成框架的结构化知识基础。针对医学文本专业术语密集、信息表达高度压缩以及上下文依赖性较强等特点，重点分析了知识组织方式对后续检索效果与生成质量的影响。

（2）针对医学问答场景中单一检索策略难以同时兼顾精确匹配与语义召回的问题，设计了关键词检索与向量检索相结合的混合检索策略，并引入重排序与结果筛选机制，以提升检索证据的相关性与可靠性。在此基础上，构建基于大语言模型的生成流程，使模型能够结合检索到的外部医学证据进行答案生成，从而在一定程度上提升回答的准确性与可解释性。

（3）设计并实现了一套面向实际应用的医学问答系统，围绕用户问答交互、知识检索服务、模型推理调用以及结果展示等核心模块进行整体架构设计，实现了从知识导入、索引构建到在线问答服务的完整流程。同时，系统支持多轮对话、证据来源展示以及知识库管理等功能，使系统能够较好地服务于实际慢病健康咨询场景。

1.4 论文组织结构

本文的组织结构安排如下：

第一章：绪论。首先介绍慢性病医学问答系统的研究背景和意义，然后从互联网问诊与医学问答模型两个方面对国内外研究现状进行分析，最后介绍论文的主要工作和结构安排。

第二章：相关理论及技术介绍。

2 相关理论和技术介绍

2.1 大语言模型概述

大语言模型（Large Language Models，LLM）是近年来自然语言处理领域中很有代表性的一类技术，它的基本思路，是通过大规模文本训练，让模型学到语言里的语法规律、语义关系和上下文联系。和传统模型相比，大语言模型的参数规模更大，能处理更复杂的语言现象，所以在问答、对话、摘要和内容生成等任务中，通常会表现出更强的泛化能力；当前主流大语言模型大多建立在 Transformer 框架之上，因此，理解 Transformer 的基本原理，也是分析后续 RAG 系统与模型优化方法的重要前提。

2.1.1Transformer 模型

Transformer 模型是一种基于自注意力机制的神经网络模型，由 Vaswani 等人在 2017 年提出[9]。相比于传统的循环神经网络（RNN）和长短期记忆网络（LSTM），Transformer 仅依靠自注意力机制来建模序列数据之间的关系。这使得它具备两个关键优势：一是拥有更好的并行性和更高的训练效率；二是缓解了 RNN 在处理长序列时面临的梯度消失或爆炸问题[10]。

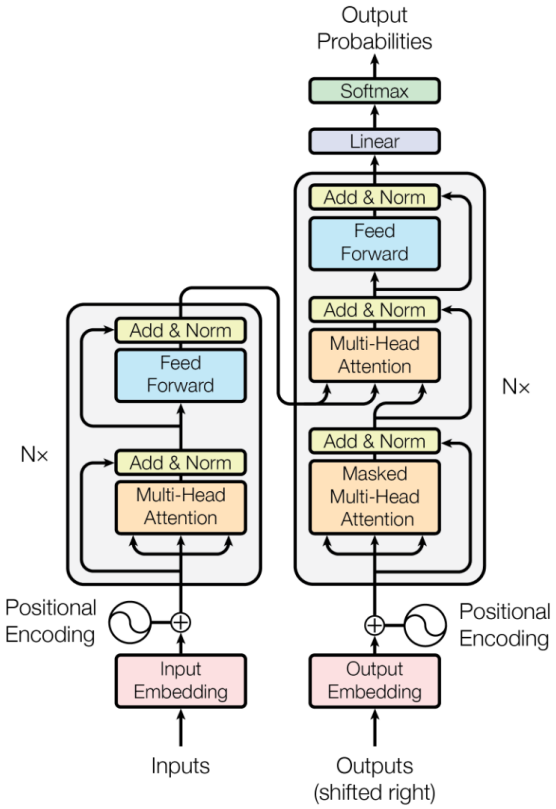

图 2.1 Transformer 结构图

Transformer 的整体结构如图2.1所示，它由编码器和解码器两个部分组成。编码器

对输入序列进行特征提取，将其编码为高维的连续向量；解码器根据编码结果逐步生成输出序列。其中，编码器由多层相同的子层堆叠而成，每一层都包含多头自注意力机制（Multi-Head Self-Attention）和前馈神经网络（Feed Forward Network）两个子模块，并在每个子模块后引入残差连接与层归一化（Layer Normalization）。解码器同样由多层结构组成，在每一层中除了包含与编码器类似的多头自注意力和前馈网络外，还额外引入了编码器-解码器注意力机制（Encoder-Decoder Attention），用于融合输入序列的语义信息。与编码器不同的是，解码器中的自注意力采用掩码机制（MaskedSelf-Attention），将下文用掩码遮盖，以保证模型在生成过程中不会利用“未来”的信息，从而符合自回归生成的特性。

自注意力机制是 Transformer 的核心组成部分，其主要思想是通过计算序列中各元素之间的相关性来动态调整不同位置之间的信息权重。在计算过程中，每个输入向量会被映射为查询（Query）、键（Key）和值（Value）三个向量，通过 Query 与 Key 之间的相似度计算得到注意力权重，并对 Value 进行加权求和。Attention 机制使模型能够在全局范围内建模序列依赖关系，有效捕捉长距离语义信息，并且支持并行计算，显著提升了模型的训练效率与表达能力[11]。它的标准形式为:

$$Attention(Q,K,V) = softmax(\frac{QK^T}{\sqrt{d_k}})V \qquad \text{(公式 2.1)}$$

其中，Q、K、V 分别表示查询、键和值三个向量矩阵，d_k 表示键向量的维度。通过对 QK^T 进行缩放处理，可以避免在维度较大时点积结果过大，使 softmax 函数进入梯度较小的区域，影响模型训练效果。

在实际应用中，Transformer 进一步引入多头注意力机制（Multi-Head Attention），通过并行地执行多组注意力计算，使模型能够从不同子空间对序列信息进行建模，从而增强特征表达能力。

2.1.2 现代大模型

现代主流大语言模型大多采用仅解码器架构，代表有 GPT、LLaMA、Qwen 等，这种结构更适合自回归语言任务，因为解码器的自注意力掩码只依赖上文预测下一个词，与文本逐词生成的过程天然一致，这使它成了通用大模型的首选[12,13]。

整体上，现代大模型依然继承 Transformer 由多层注意力模块和前馈网络模块堆叠并通过残差连接的基本框架，但对多个核心部分做了优化，以提升处理长上下文的能力、训练效率或推理效率；在归一化方面，现代大模型普遍把归一化位置从模块输出之后移到输入之前，也就是先对输入进行归一化再送入注意力或前馈网络，使训练更稳定，还有一些模型把传统的层归一化换成了计算更轻量的 RMSNorm；位置编码上，旋转位置编码（Rotary Position Embedding，RoPE）已经广泛替代了绝对位置编码，它在注意力计算中直接融入相对位置信息，从而能更好地捕捉长距离依赖关系[14]；前馈网络部分，现

代大模型常采用 SwiGLU 等门控线性单元，这种带门控的结构比标准两层线性映射拥有更强的非线性表达能力和更高的参数利用效率，在相近的参数量下能获得更好的建模效果；注意力机制方面，围绕长上下文支持和推理效率，现代模型进行了整体优化：一方面通过让多个查询头共享或分组共享键值表示（即多查询 MQA 或分组查询 GQA）[15]，有效压缩键值缓存规模、降低显存占用，另一方面引入更高效的 FlashAttention 来重写标准注意力的计算过程——标准注意力在序列长度为 n 时要构造 n×n 的注意力矩阵，带来 $O(n^2)$ 显存开销和大量内存读写，而 FlashAttention 不显式存储完整注意力矩阵，改为把查询、键、值矩阵分成小块，在片上高速缓存中分块计算 QK 转置、局部 softmax 以及与 V 的乘积，并在线维护 softmax 的归一化项[16]，由公式 2.2 等价地完成注意力计算。

$$y_i = \sum_j \frac{\exp\left(q_i \cdot \frac{k_j}{\sqrt{d}}\right)}{\sum_l \exp\left(q_i \cdot \frac{k_l}{\sqrt{d}}\right)} v_j \qquad \text{(公式 2.2)}$$

这些优化显著增强了模型的长上下文建模能力、训练稳定性、参数利用效率以及推理阶段的计算效率，使大模型能够在复杂语义理解、多轮对话和长文本生成等任务中表现出更强的能力。

2.1.3 模型训练技术

大语言模型的训练通常由多个阶段构成，不同阶段用来发展模型不同方面的能力。通过分阶段训练，模型可以逐步从基础语言建模能力过渡到面向具体任务的应用能力，从而在保证语言理解能力的同时提升实际使用效果。

训练初期，一般采用大规模无标注语料进行预训练。该阶段的目标只是为了让模型学习自然语言中的基本结构、词语之间的统计关系以及上下文特征，模型通过大量的学习，会学习到自然语言中潜在的特征，从而自然的获得通用的语言表示能力。常见的训练方式是基于自监督学习，通过预测文本中的部分内容来完成训练，使模型在无需人工标注数据的情况下获取丰富的语言知识。经过预训练后，模型已经具备了根据上文进行“下一词预测”的能力，能够根据已有文本生成连贯的后续内容。

在此基础上，引入监督微调（Supervised Fine-Tuning, SFT）阶段。该阶段使用人工标注的数据，对模型进行进一步训练，让模型的输出更契合所要解决的具体任务。例如，在问答或对话任务中，通过构建“问题—答案”或“指令—响应”的数据对，引导模型学习更符合实际应用场景的表达方式。与预训练阶段不同的是，微调数据规模通常较小，但针对性较强，更有利于模型学习产生结构化的正确输出。

在完成有监督微调之后，通常还会进一步引入基于人类反馈的强化学习阶段。在这一阶段，让模型所生成的结果更加符合人类偏好，在内容的准确性、表达的合理性、结果的安全性诸方面都加以改进。人类反馈强化学习（RLHF）中最常用、最典型的策略优化方法是近端策略优化（Proximal Policy Optimization, PPO）[17]。PPO 算法通常会引入

两个小规模的模型：奖励模型和价值模型。奖励模型用于学习人类对不同输出结果的偏好，并对生成结果进行评分；价值模型用于估计当前生成策略在后续过程中的回报情况。整个训练过程与现实中的考试很相近，Base 模型就是“学生”，奖励模型相当于“教师”，“教师”对“学生”的答卷评分，“学生”根据打分进行学习。具体来说，模型会根据当前策略生成回答，奖励模型计算对应的奖励信号，接着价值模型对整个序列的整体收益进行估计，这样就得到了用于优化的优势函数。优势函数用于衡量当前生成行为相对于基准策略的优劣程度，并作为权重参与策略优化过程。更重要的是，PPO 有明确而巧妙的机制来控制新旧策略的变化幅度，即在保证训练稳定性的基础上缓慢、审慎地调整生成分布，让优势为正的行为概率增大，优势为负的行为概率缩小。因此 PPO 在保持生成能力稳定性的同时，能更可靠、更充分地遵循人类偏好。

虽然 PPO 算法能够提升模型对人类偏好的对齐程度，但其训练过程一般都极为复杂。在训练过程中不仅引入了奖励模型和价值模型两个需要额外训练的新模型，还要将原始模型保存一份作为参考模型，这带来了极大的计算和存储开销。2023 年，由斯坦福大学提出直接偏好优化（Direct Preference Optimization, DPO）算法，DPO 的基本思想是利用“优选回答-非优选回答”成对数据，直接优化模型对高质量回答的偏好[18]。相较于 PPO 算法，DPO 训练流程不需要独立的奖励模型和价值模型，这也让 DPO 训练更简单也更稳定。DPO 的目标函数通常可表示为：

$$\mathcal{L}_{DPO}(\theta) = -\mathbb{E}_{(x,y_w,y_l)\sim\mathcal{D}}\left[\log\sigma\left(\beta\log\frac{\pi_\theta(y_w|x)}{\pi_{ref}(y_w|x)} - \beta\log\frac{\pi_\theta(y_l|x)}{\pi_{ref}(y_l|x)}\right)\right] \qquad \text{(公式 2.3)}$$

其中，x 表示输入问题，y_w 表示优选回答，y_l 表示非优选回答，π_θ 表示待优化模型，π_{ref} 表示参考模型，β 表示偏好强度参数。这个目标函数的含义在于：当面对同一个输入时，提升模型对优选回答的相对概率，并且还要降低它对非优选回答的概率，从而使模型输出更符合人类的偏好。

2.2 检索增强生成（RAG）技术

检索增强生成（Retrieval-Augmented Generation，RAG）是一种把信息检索和文本生成结合起来的方法，目标在于提升大语言模型在专业领域或需要大量事实信息的任务上的表现[19]。与单纯依赖模型自身参数进行生成的方式相比，RAG 通过引入一个外部的知识库，为模型提供更加准确且更具有时效性的信息支持。

在传统的大语言模型中，模型掌握的知识几乎全部来自预训练阶段存入参数中的信息，这种方式虽然具备较强的泛化能力，但在面对专业领域问题或最新信息时，就很容易暴露出知识不足或生成内容不够准确的缺陷。RAG 把检索模块加入到了生成过程当中，有效地缓解了这类问题。

RAG 的基本流程通常由两个阶段构成：第一阶段，先根据用户输入的问题，检索器采用稀疏检索（如 BM25）、稠密检索（如向量检索）或者混合检索策略，从外部知识

库中获取一批候选文档；在第二阶段，把检索到的文档与原始问题以及对话历史进行融合，一同输入到大语言模型中进行生成，最终产出更准确、更可靠的回答。

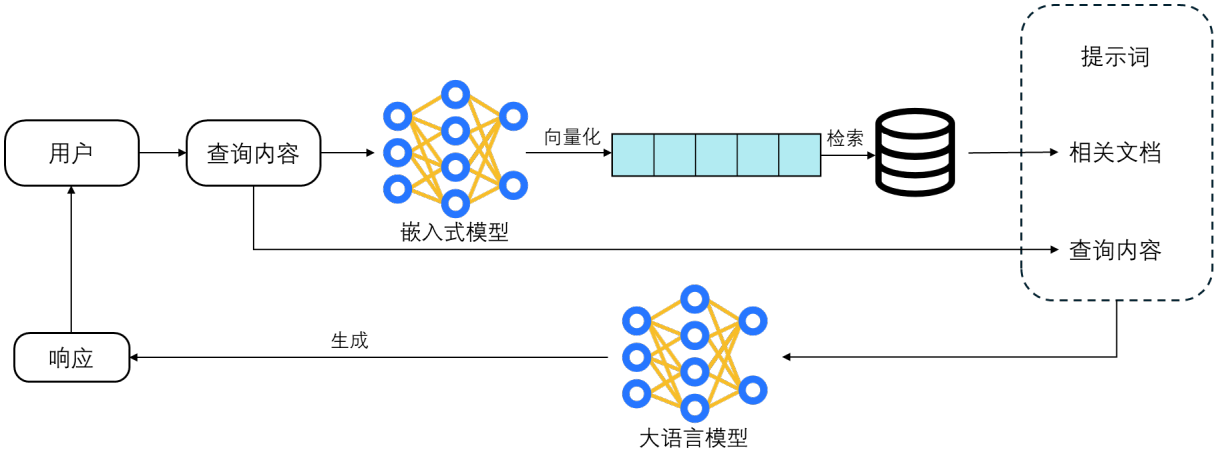

图 2.2 RAG 流程图

2.3 本章小结

本章首先对 Transformer 模型的结构进行了详细的介绍，随后介绍了目前热门的大语言模型的对 Transformer 结构的改进以及模型的训练方法，并介绍了检索增强生成技术的应用场景。

3 医学知识库构建与检索方法

本章主要研究医学问答系统中和知识侧有关的关键内容，重点包括医学知识库构建、文本语义切分、向量化表示以及混合检索策略设计。对 RAG 系统来说，知识库的质量和检索效果会直接影响后续生成阶段能否获得可靠证据，因此，本章重点讨论医学问答中的证据来源、知识组织方式以及检索支撑过程。

3.1 医学知识库构建方法

3.1.1 数据来源

医学知识库的数据来源，会直接影响系统问答的准确性和可靠性。围绕“三高”（高血压、高血糖、高血脂）相关内容，系统主要选取公开、并且具有一定权威性的医学资料，用来保证知识内容在科学性和可信度方面更有依据。整体来看，数据主要来自以下三个方面：

(1) 权威医学指南与报告：主要包括国家卫生健康委员会等官方的政策文件、指南与规范和健康报告。
(2) 医疗机构与专业平台内容：主要包括丁香园、医知源等平台发布的疾病科普文章和健康建议。
(3) 医学科普网站与百科类资源：主要包括维基百科等平台中“三高”相关词条。

3.1.2 数据预处理

本系统的医学知识库由多种格式的原始文档组成，主要包括 PDF 文档和 HTML 网页内容。由于不同来源的数据在结构上差异较大，系统针对不同类型的数据分别设计了预处理方式，先把原始文档转成适合后续处理的文本格式，再继续进行文本切分和向量化表示。

(1) PDF 文档处理：对于 PDF 格式的医学资料，系统使用 MinerU 工具进行解析。MinerU 基于多模态大模型，能够识别不同排版结构的 PDF 文档，并把它们转换成结构化的 Markdown（.md）格式。
(2) HTML 网页处理：对于 HTML 网页数据，系统通过解析网页内容，并使用 document.body.innerText 提取其中的主要文本信息，再把它转换成纯文本（.txt）格式，便于后续统一处理。

3.1.3 文本语义切分

在 RAG 系统中，模型通常不需要把整篇文档原封不动地作为生成时的输入，而且过长的文档还会导致向量化表示和检索的难度增加。这就要求必须对文本进行合理的切

分，在尽可能保留原始医学文本语义结构的前提下，将长文档划分为适合检索与生成使用的文本块。如果切分后 chunk 过长，单个文本块中会包含过多无关信息，影响检索精度；若切分后 chunk 过短，则容易破坏上下文完整性，导致关键知识被割裂。因此，本系统切分策略并不是简单的按固定长度截断，而是要按照标题和段落结构来切分文档。

对于 PDF 解析得到的 Markdown 文本，系统会先去除文末的参考文献、页脚等与问答无关的内容，之后则按照 Markdown 语法识别标题与正文块。系统会创建一个标题栈，通过维护标题栈记录当前文本所在的层级路径，当遇到新的标题时，先把之前缓存的内容输出，再更新标题路径；当遇到普通段落时，则将其合并到当前标题对应的缓冲区中。如果缓冲区内容超过长度阈值，系统会优先按照句号、问号、感叹号等语句结束标点进行切分，并将上一个文本块末尾的 120 字符作为下一文本块的开头，从而形成带重叠的连续片段，尽量避免关键信息被分割。经过这样的处理，Markdown 文本最终被切分为“标题路径 + 正文内容”的结构化片段。

对于网页提取得到的 TXT 文本，由于其与 Markdown 不同，并不具有“标题”和“正文”的标识，系统采用启发式规则进行语义切分，但总体的切分思路相同。程序首先按连续空行划分自然段，再对单行或多行段落进行标题识别。标题识别主要依据中文医学资料中常见的编号形式，如“一、”“（一）”“1.”“（1）”等，同时对长度较短且不以句末标点结束的行引入隐式标题判定规则，以适应网页文本中未显式标注层级但具备标题特征的内容。与 Markdown 文档处理方式相同的是，系统仍会创建一个标题栈用于记录段落所属的层级关系。在具体合并策略上，若新标题属于同级或更高层级，则输出当前缓存内容并开始新的文本块；若仅为更深层级的子标题，则不立即切分，而是继续在父级主题下聚合内容。这样可以将同一主题下若干较短的小节内容合并为一个较完整的语义单元，避免切分过碎。当缓冲区长度超出阈值时，采用和之前同样的策略，按照语句结束标点切分，并且使两段又一部分重叠的片段，保留上下文的信息。

完成处理后，所有文档都统一保存为 JSON 格式，JSON 字段如图3.1所示，每个文本块包含 chunk_id、source、category、headings 和 content 等字段，方便后续对检索结果的溯源。

```
{
  "chunk_id": 5,
  "source": "国家基层糖尿病防治管理指南（2025）.pdf",
  "category": "Diabetes",
  "headings": "二、 制定原则",
  "content": "本指南根据国家发布的糖尿病防治管理工作规范要
  "page_range": "p2"
},
```

图 3.1 切分后的 chunk 示例

3.1.4Embedding 向量化表示

文本切分完成之后，知识库里的每个文本块都还需要经过一步转换，变成能够支持语义检索的向量表示。Embedding 模型会把离散文本映射到一个统一的高维语义空间中，使语义相近的文本在向量空间中的距离更近，从而支持后续基于相似度的向量检索。

本系统采用 BGE 系列 Embedding 模型对医学文本块进行向量化处理。BGE 模型具有较好的中文语义表示能力，能够较好地适应医学问答场景中常见的疾病名称、症状描述、用药建议以及生活化表达等多种文本形式。在知识库构建阶段，系统使用 BGE 模型对切分后的 chunk 逐条编码，生成对应的稠密向量；在在线检索阶段，则对用户问题执行相同的编码操作，并通过计算问题向量与知识块向量之间的相似度来完成召回。

Embedding 向量化的意义在于，它把知识库的检索方式从单一依赖关键词匹配，转变成了兼具基于语义理解进行检索的能力；针对医学问答中大量存在的同义表达、口语化描述和隐含问题，这种向量化表示正是扩大召回覆盖面、增强检索稳健性的关键基础。

3.1.5 向量数据库构建

在获得文本块的向量表示后，还需要构建能够支持高效近邻检索的向量数据库或向量索引结构。若仅对全部向量进行线性遍历比对，在知识规模增长后会显著增加检索开销，难以满足在线问答场景对响应速度的要求。因此，知识库构建不仅包括文本组织和向量生成，也包括向量检索结构的建立。

本系统采用 FAISS 构建医学知识库的向量索引，把每个文本块向量与它对应的原文内容、标题路径和来源信息建立起映射关系，这样在向量检索时系统既能快速获得与查询最相近的文本块，又能把结果回溯到原始文本内容和来源元数据，为后续的证据展示与可解释性分析提供支撑。

3.2 医学文本检索方法

3.2.1BM25 关键词检索原理

BM25 是一种比较经典的关键词检索模型，主要根据查询词在文档中的出现情况来计算相关性，因此更适合处理以词面匹配为主的检索任务。对于查询 q 和文档 d，它的得分公式可以写作

$$\mathrm{score}(q,d)=\sum_{t\in q}\mathrm{idf}(t)\cdot\frac{f(t,d)\cdot(k_1+1)}{f(t,d)+k_1\cdot(1-b+b\cdot\frac{|d|}{\mathrm{avgdl}})} \qquad \text{(公式 3.1)}$$

式中，$f(t,d)$ 表示词项 t 在文档 d 中的出现次数，$\mathrm{idf}(t)$ 表示逆文档频率，$|d|$ 表示文档长度，avgdl 表示平均文档长度，k_1 和 b 则用来控制词频影响和长度归一化程度。

在医学问答场景里，疾病名称、药物名称、检查指标和各类专业术语往往具有很强

的区分作用，而 BM25 正好比较擅长保留这类关键词信息，所以在精确匹配方面表现比较稳定。它的不足也很明显，就是对同义表达、口语化提问和更深一层的语义关系不够敏感，因此只依赖 BM25 时，系统容易漏掉一些意思接近但表述不同的内容。

3.2.2 向量检索原理

向量检索的思路和关键词检索不同，它不是直接看词是否匹配，而是先借助嵌入模型把用户问题和文档内容都表示成向量，再放到同一个语义空间中进行比较，语义越接近，向量之间通常也越接近，系统就更容易把对应文本检索出来。本文选用 BGE-M3 作为嵌入模型，并把知识库中的每个文本块编码成稠密向量，再写入 FAISS 索引中保存。

在相似度计算方面，常见方法主要有余弦相似度和内积两种形式，当向量完成归一化以后，这两种做法在效果上可以看作基本一致。结合工程实现需求，本文在 FAISS 中采用内积检索方式，也就是 IndexFlatIP，这样既能保持较高的检索效率，也能较好反映语义层面的接近程度。

和关键词检索相比，向量检索更擅长处理同义表达、上下位概念以及长句语义理解这类问题，比如提问方式发生变化以后，它仍然有可能找到意思接近的文本。不过，它对局部关键词的约束相对较弱，有时会召回语义上看起来相关、但关键实体并不一致的文本片段。医学问答对术语准确性要求较高，所以只依靠向量检索也很难保证结果始终稳定，通常还需要和关键词检索配合使用。

3.2.3 混合检索策略

为兼顾“术语精确匹配”与“语义泛化召回”两个目标，本文采用 BM25 与向量检索的混合策略，并设计了一条“双路召回到融合排序再到重排精筛”的处理流程：

第一步，系统让两种检索逻辑各自独立地从知识库中检索出各自认为最相关的候选文档列表，形成两路结果；第二步，对这双路结果执行融合排序，采用的算法是倒数排序融合，它的计算形式可以写作：

$$RRF(d) = \sum_{r \in R} \frac{1}{k + r(d)} \qquad \text{(公式 3.2)}$$

其中 R 代表参与融合的各路排序列表的集合，r(d) 表示某篇文档 d 在对应列表中的排列位次，k 是一个用来平滑结果的常数，本系统取 k=60，这个公式综合了一篇文档在不同排序列表中的名次信息，名次越靠前最终得分越高；第三步，融合出统一的候选列表后，再引入 BGE-Reranker-v2-M3 的专门重排模型，对候选文档进行交叉编码式的高精度重排，最终截取出靠前的 Top-K 份证据。

与单用一种检索方式相比，混合策略有几方面的好处：第一，BM25 防止了关键专业术语不会因为语义而无法被准确检索；第二，向量检索弥补了同义改写和口语表达的

语义召回盲区；第三，重排模型进一步提升了最终送去给生成模型用的证据的相关性，有效滤掉那些“初看沾边但不支持直接做答”的噪声片段；这样的组合策略，在同一套检索链路里同时回应了医学问答对“高召回”和“高精度”的双重严苛要求。

3.3 实验与结果分析

为了验证不同检索方法在医学知识库中的实际召回效果，本文围绕已经构建完成的 FAISS 索引开展了检索实验。实验中，先从知识库里随机抽取 60 个文本段，再根据这些文本段的内容人工设计相关问题，每个问题都对应一个预期命中的目标文本块，只要这个目标文本块出现在前 K 个检索结果中，就记作一次命中。本文选用 Recall@1、Recall@5 和 Recall@10 作为评价指标，用来衡量系统在只返回 1 条、前 5 条和前 10 条候选结果时的召回能力。

实验共比较了三种检索方式，一种是基于 BM25 的关键词检索，一种是基于 BGE 向量表示和 FAISS 索引的向量检索，另一种是本文采用的混合检索策略，也就是先结合 BM25 和向量检索进行双路召回，再通过 Reranker 完成重排，最后给出排序结果。三种方法的实验结果如表3.1所示。

表 3.1 RAG 检索方法 Recall@K 对比结果

检索方法	Recall@1	Recall@5	Recall@10
BM25 检索	0.26	0.81	0.92
向量检索	0.48	0.81	0.85
混合检索 + Rerank 重排	0.59	0.89	0.96

从实验结果来看，三种检索方法在不同 K 值下表现出比较明显的差异。先看 Recall@1，BM25 检索为 0.26，说明如果系统只返回首条结果，只依靠关键词匹配很难稳定命中目标文本；向量检索的 Recall@1 提升到 0.48，说明语义检索对口语化表达、近义改写和不完全词面匹配的问题有更好的适应能力；混合检索结合 Rerank 重排以后，Recall@1 进一步提升到 0.59，是三种方法中最高的。这说明在最靠前的排序位置上，混合检索策略更容易把真正相关的证据提前放出来。

再看 Recall@5，BM25 检索和向量检索都达到 0.81，混合检索则提升到 0.89。这说明当候选范围扩大到前 5 条时，单一检索方法已经能够召回大部分相关文本，但仍然会出现一定程度的漏召回；相比之下，混合检索同时利用了关键词匹配和语义匹配两类信息，又经过重排模型进一步筛选，因此在前 5 条结果里保留了更多有效证据。对 RAG 系统来说，这一点很重要，因为生成模型通常不会使用过多检索结果，如果前几条证据质量不够高，最终回答质量也会直接受到影响。

最后看 Recall@10，BM25 检索达到 0.92，高于向量检索的 0.85，这说明当候选集合进一步放宽以后，BM25 在专业术语、数字指标这类关键词层面的覆盖能力会更明显，

更容易把目标文本放进较长的候选列表里。不过，混合检索加 Rerank 重排的 Recall@10 仍然达到 0.96，依然是三种方法中最好的结果。这说明混合检索并不是简单把两种方法拼在一起，而是在不同检索机制之间形成了比较明显的互补关系，BM25 负责尽量保住专业术语、药物名称和指标数值这类关键信息不被漏掉，向量检索负责补足语义层面的相似表达，重排模型再进一步减少“看起来相关、但并不是最佳证据”的干扰。

综合来看，单独使用 BM25 更适合术语比较明确的问题，但对自然语言表达变化会更敏感；单独使用向量检索在语义匹配上更有优势，不过在一些依赖精确术语和细粒度实体区分的问题上，仍然可能出现误召回。相比之下，混合检索结合重排策略在 Recall@1、Recall@5 和 Recall@10 三个指标上都取得了最好结果，说明这种方法更适合医学问答场景中“专业术语精确匹配”和“自然语言语义召回”同时存在的需求。因此，本文最终选择混合检索加 Rerank 重排作为 RAG 问答系统的默认检索方案。

3.4 本章小结

本章前半部分围绕医学知识库构建与检索方法展开，介绍了知识数据来源、文本预处理、语义切分、Embedding 向量化表示以及向量索引构建过程，并进一步分析了 BM25、向量检索和混合检索策略在医学问答场景中的特点与差异。实验结果表明，混合检索结合重排策略在召回覆盖和结果稳定性方面表现更好，能够为后续回答生成提供更可靠的证据基础。

通过这一部分的研究，系统已经基本解决了“回答依据从哪里来”的问题，也为后续围绕 RAG 输入组织、Prompt 设计和模型优化展开分析提供了支撑。

4 医学问答模型构建与优化

在完成知识库的构建与检索设计之后，系统还需要进一步解决“如何基于检索证据生成回答”以及“如何让模型回答更符合医学场景要求”这两个问题。因此，本章重点讨论 RAG 输入组织方式、Prompt 设计、DPO 偏好数据构建以及模型优化效果分析。

4.1 RAG 问答生成方法

4.1.1 检索增强生成流程

RAG 问答生成的核心流程可以概括为“检索—增强—生成”三个环节：先从用户输入的问题出发构造检索查询，在医学知识库里把与之相关的候选文本召回来，这一步解决的是回答依据从哪里来的问题；接着对召回的一批候选文本做去重、排序和筛选，挑出最有价值的证据组合成增强上下文，这一步处理的是哪些证据最值得交给模型去参考的问题；最后把用户问题和增强后的证据上下文一起交给大语言模型，由模型将这些证据转化为用户可以理解的自然语言回答。通过这样一条链路，模型的输出就不再单纯依赖存留在参数里的记忆，而是建立在外部知识的支撑之上，从而让回答的准确程度与内容可追溯程度都得到提升。

4.1.2Prompt 与上下文构建

为了让模型生成的回答更符合医学问答场景的要求，本文把 Prompt 设计和上下文构建放在同一个流程里统一处理，而不是把两者分开。系统送入大语言模型的内容主要包括三部分，一部分是系统提示词，用来明确模型的角色定位和回答原则，一部分是必要的历史对话信息，用来支持多轮问答中的语义衔接，另一部分是当前用户问题和检索得到的外部证据，用来约束模型在生成时优先依据可以核对的资料作答。这样组织输入内容，主要是为了减少没有依据的扩展，让模型输出尽量建立在检索证据和医学常识的共同基础上。

如图4.1所示，系统提示词先把模型设定为“严谨、审慎的医疗问答助手”，并明确要求它优先依据检索资料回答问题。在回答规则上，提示词进一步限制模型不能编造和资料内容或医学共识相矛盾的信息，还要求模型先判断检索资料和问题之间的相关程度，再决定是以资料为主进行回答，还是结合通用医学知识作适当补充；如果问题本身比较宽泛，就先给出简要概述，再围绕检索证据展开重点说明，回答形式也要尽量清楚、具体、容易理解。对于治疗和用药这类更敏感的问题，系统还要求模型避免给出过于绝对的建议，如果缺少年龄、体重、肝肾功能、合并用药和过敏史等关键信息，就要主动提示补充；如果问题中出现胸痛、呼吸困难、意识改变、持续高热或明显出血等急危重症信号，则应优先建议立即线下就医或进行急诊处理。这样设计 Prompt，不只是告诉模

型要回答什么，更重要的是限制模型该怎样回答，以及回答应当控制在什么边界内。

```
DEFAULT_SYSTEM_PROMPT = (
    "你是一名严谨、审慎的医疗问答助手。\n\n"
    "请优先基于“检索资料”回答问题，并结合必要的医学常识进行补充说明，以确保回答完整、准确。\n\n"
    "要求：\n"
    "1. 不得编造与资料或医学共识相矛盾的内容。\n\n"
    "2. 请判断检索资料与问题的相关性：\n"
    "- 若高度相关：以资料为主回答。\n"
    "- 若部分相关：结合资料与医学常识补充。\n"
    "- 若相关性较低：以通用医学知识为主，并说明“检索资料未充分覆盖该问题”。\n\n"
    "3. 若问题较宽泛（如疾病名称）：\n"
    "- 先进行简要概述（定义/常见表现）。\n"
    "- 再结合检索资料重点展开。\n\n"
    "4. 回答使用markdown格式，内容应清晰、具体、通俗易懂。\n\n"
    "5. 涉及治疗或用药时：\n"
    "- 避免给出绝对化或个体化用药方案。\n"
    "- 若缺少年龄、体重、肝肾功能、合并用药、过敏史等关键信息，应先提示补充。\n\n"
    "6. 若出现急危重症信号（如胸痛、呼吸困难、意识改变、持续高热、明显出血等），应优先建议立即线下就医或急诊。\n\n"
    "7. 当检索资料不足以完整回答问题时：\n"
    "- 可以基于通用医学知识进行补充。\n"
    "- 并适当说明信息来源类型（如“通用医学知识”）。"
)
```

图 4.1 系统提示词

在用户输入侧，系统采用较为固定的组织格式，将当前问题和检索证据封装为统一文本。其中，用户问题以“问题：”字段引出；若存在检索结果，则继续追加“检索资料：”字段，并将检索证据整体附在其后。对于多轮对话场景，系统会在当前用户输入之前插入经过清洗后的历史消息序列，仅保留角色合法且内容有效的最近若干轮消息，并对连续同角色消息进行合并，以减少噪声上下文对生成的干扰。这样的组织方式既保持了对话输入格式的一致性，也使模型能够明确区分“历史对话”“当前问题”和“外部证据”三类信息。

在检索证据的构建上，系统对重排后的候选文档按相关性顺序逐条组织，每条证据均采用统一格式表示为“编号 + 来源 + 标题 + 内容”。这种结构化的输入方式，模型不仅能够利用正文内容，还能够同时利用来源信息和标题路径辅助判断证据的主题归属。

最终，系统将“系统提示词 + 历史对话 + 问题 + 检索资料”共同输入模型，实现面向医学 RAG 场景的统一 Prompt 构建。

4.2 基于 DPO 的模型优化策略

4.2.1 偏好数据构建

为了让 DPO 训练更贴近医学问答场景，本文选用了 cMedQA v2.0 和 Huatuo-26M 两个中文医疗问答数据集。前者是面向中文医疗问答任务整理的数据集，包含 10 万多个问答对，覆盖了疾病、症状、治疗方法等多类医学知识；后者规模更大，约有 2600 万个问答对，而且其中大部分内容来自真实医疗咨询场景，因此更接近实际问答中的表

达方式。

在这两个数据集中，本文先筛选出和“三高”相关的问题，再对重复内容进行去重，最终得到 6351 条问答数据。在这个基础上，又继续挑选出那些更容易产生歧义、或者更容易引发模型幻觉的问题样本，最后整理出 431 个具有代表性的偏好数据问题。

在具体构造过程中，本文借助高质量大语言模型生成偏好数据对，也就是 Chosen-Rejected 回答对，同时再引入评估模型对生成结果进行筛选和比较，用这种方式提高数据对的可靠性和区分度。

一是优质回答，也就是 Chosen 回答的生成，这部分提示词设计与 3.3.2 节保持一致，用来尽量保证训练阶段和实际使用阶段的提示环境相同；二是劣质回答，也就是 Rejected 回答的生成，本文通过提示词引导模型产出“表面上看起来合理、但实际存在缺陷”的回答，并有意识地加入几类常见问题，比如对不确定结论表达得过于肯定、忽略检索资料中的细节、缺少必要的安全提示，或者回答内容过于空泛，不过同时也会控制负样本不要出现明显错误或极端不安全内容，使它仍然停留在“容易混淆”的合理范围里，这样更有利于偏好学习；三是偏好对的筛选和质量控制，在得到候选正负回答后，再由另一个评估模型从事实一致性、安全性、相关性、完整性和表达清晰度等角度进行比较，只保留优劣关系比较明确的样本对，用于后续 DPO 训练。

最终，DPO 训练数据按三元组形式组织，也就是（prompt，chosen，rejected），其中 prompt 表示用户问题，chosen 表示质量更高的回答，rejected 表示相对较差的回答。

为了进一步提高大语言模型在医学问答场景中的回答质量和安全性，本文在检索增强生成之外，又引入了直接偏好优化（Direct Preference Optimization，DPO）方法对模型进行调整。它的基本做法是，在相同输入条件下准备一组回答对，其中一条回答质量更高，记为 chosen，另一条回答相对较差，记为 rejected，然后让模型在对比学习中逐步学会更偏向前一种输出，从而生成更符合实际使用需求的结果。

4.2.2DPO 训练流程

本文基于 TRL 框架实现 DPO 训练，并结合 LoRA 参数高效微调方法对 Qwen 基础模型进行优化，以提升模型在医学问答任务中的回答质量、安全性和场景适配能力。由于基础模型参数规模较大，若直接采用全参数训练，会带来较高的显存占用和训练开销，因此本文采用 LoRA 方法，仅在部分关键模块中引入可训练的低秩参数，从而在降低训练成本的同时实现对模型的有效优化。

在训练阶段，模型以偏好数据三元组作为输入，通过比较同一问题下的优选回答与非优选回答，学习更符合人工偏好的输出分布。考虑到单张 RTX 4090 显卡只有 24G 的显存容量，本文使用 bitsandbytes 库对模型进行 4-bit 量化加载，降低模型占用；训练过程中采用小批量训练并结合梯度累加策略，用小显存近似模拟大批量的训练；同时设置 warmup 机制和合适的 DPO 偏好强度系数，以增强训练稳定性。

训练中使用的主要超参数如表4.1所示。

表 4.1 DPO 训练主要超参数

超参数	取值	作用
learning_rate	10^{-5}	学习率
lora_r	16	低秩矩阵的秩
lora_alpha	32	LoRA 缩放系数
batch_size	2	批大小
gradient_accumulation_steps	2	梯度累加步数
beta	0.1	DPO 偏好优化强度系数
warmup_ratio	0.03	学习率 warmup 比例

4.3 实验结果分析

4.3.1DPO 训练过程分析

为了进一步判断 DPO 训练过程是否稳定、模型偏好是否真正形成，本文结合训练日志和可视化结果，对 checkpoint-108 阶段进行了统计分析。该阶段共记录 108 个训练点，训练轮次覆盖约 0.0093 ～ 1.0 个 epoch。整体来看，损失函数值、奖励准确率、奖励间隔和梯度范数等指标都呈现出较清晰的变化趋势，说明模型在当前训练设置下能够完成较稳定的偏好学习。

从损失函数变化来看，训练初期 loss 约为 0.6931，这个数值接近二分类随机判别时的初始状态，说明模型在训练开始阶段还没有形成对 chosen 回答和 rejected 回答的明显偏好。随着训练推进，loss 总体持续下降，在训练末期降至 0.0836，最小值达到 0.0364。如图4.2左上所示，虽然中间阶段有局部波动，但 5 步滑动平均曲线始终保持下降趋势，这说明模型对偏好样本的区分能力在持续增强，整体优化方向也比较稳定。

从奖励指标看，DPO 训练效果更加直观。奖励准确率（reward accuracy）从初始的 0 快速上升，在第 7 个记录点附近就达到 1.0，说明模型很快学会在大多数样本上对 chosen 回答赋予更高偏好。与此同时，奖励间隔（reward margin）从 0 逐步增长到 2.6441，最大值达到 3.3355。如图4.2右上所示，奖励准确率在训练前段快速饱和，而奖励间隔的滑动平均曲线仍持续上升，这说明后续训练的作用不再只是“区分正负回答”，而是继续拉开两者之间的偏好差距，让模型偏好表达更明确。

结合训练阶段均值，可以更清楚地看到这一变化过程。训练早期 loss 均值为 0.5542，奖励准确率均值为 0.7917，奖励间隔均值仅为 0.3414；进入中期后，loss 下降到 0.2414，奖励准确率提升到 0.9861，奖励间隔提高到 1.4702；在后期阶段，loss 进一步下降到 0.1579，奖励准确率稳定在 1.0，奖励间隔继续上升到 2.0445。这说明本次 DPO 训练并不是在少量样本上提前收敛，而是经历了由“初步建立偏好”到“持续强化偏好”的过程。

除偏好指标之外，其他训练信号也显示当前训练过程具有较好的稳定性。最后再看平均 token 准确率，这个指标可以间接反映模型生成能力是否发生变化；由于 Qwen2.5-7B-Instruct 本身已经经过较充分训练，基线生成能力较强，因此在本次微调中需要重点关注是否因训练数据质量问题引发能力退化。结果显示，平均 token 准确率始终维持在 0.59 左右，整体波动较小，说明模型在进行偏好优化时没有明显破坏原有的基础生成能力；信息熵从 1.50 上升到 1.76 附近，说明模型输出分布没有出现快速塌缩；梯度范数则从初期的 7.85 逐步下降到 2.04，中间虽然有短时峰值，但整体趋势向下，且和学习率退火曲线变化保持一致。综合这些现象可以认为，本次训练在收敛速度、梯度变化和输出分布上都较平稳，没有出现明显的训练失控或严重震荡。

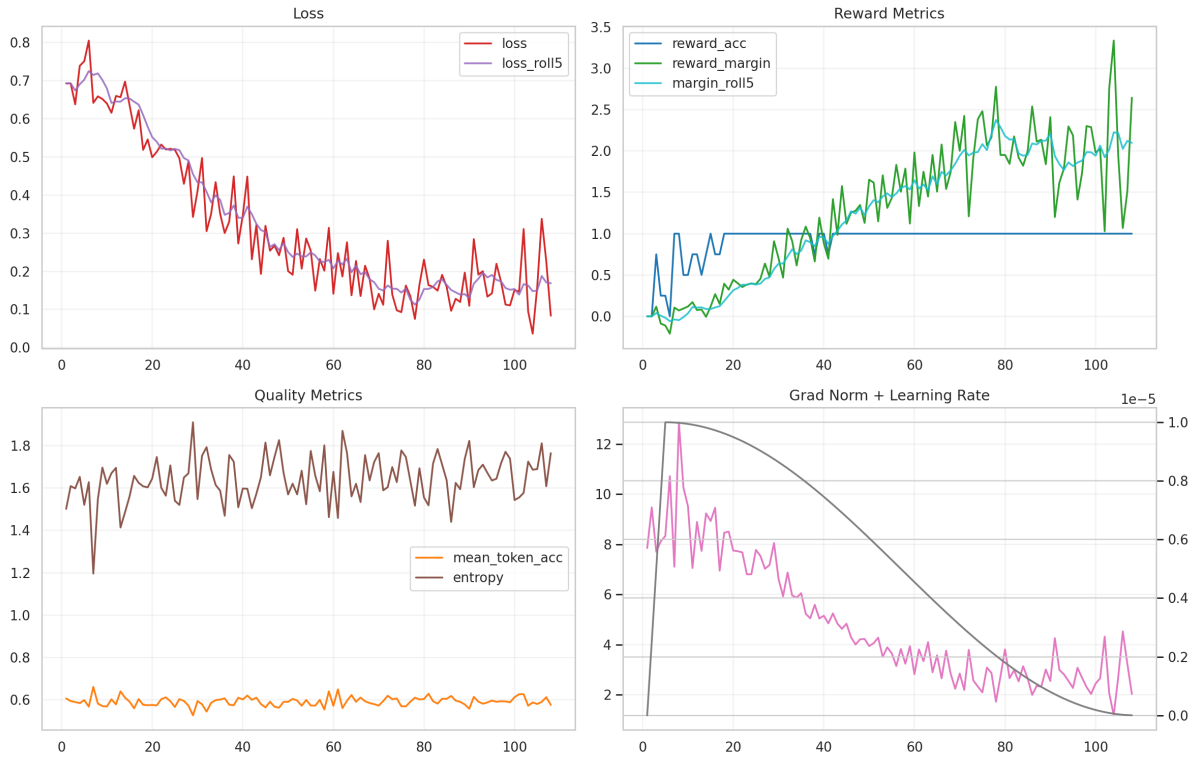

图 4.2 DPO 训练过程主要指标变化

总体来看，本次 DPO 训练在一个 epoch 内就完成了较有效的偏好对齐：一方面，loss 明显下降、奖励准确率快速达到高水平，说明模型能够学习到偏好排序关系；另一方面，奖励间隔持续扩大、梯度范数逐步收敛，说明这种偏好学习不是偶然波动，而是形成了较稳定的优化结果。因此，从训练过程本身来看，本文采用的 LoRA+DPO 训练方案是有效的，也为后续回答质量评测结果提供了训练层面的支撑。

4.3.2 回答质量评测结果

在 $N = 120$ 条样本上，本文对 Base 模型和 DPO 模型进行了多维度对比评测。整体结果显示，DPO 模型在偏好胜率上明显高于 Base 模型，前者为 60.83%，后者为 39.17%；在综合得分 Overall Score 上，DPO 模型也表现出更明显的提升，二者配对差值均值为

$\Delta = 0.2917$，95% 置信区间为 [0.0917, 0.5000]，Wilcoxon 符号秩检验结果为 $p = 0.0113$。这些结果说明，DPO 优化不仅在偏好判断上更占优势，在总体回答质量上也达到了统计意义上的提升。

分维度结果进一步显示，DPO 模型在事实正确性（Factual Correctness）和完整性（Completeness）两个关键指标上的提升最明显。其中，事实正确性的差值均值为 0.1667，对应 $p = 0.0134$，完整性的差值均值为 0.2083，对应 $p = 0.0088$，两项都达到统计显著水平。安全性（Safety）的提升幅度为 0.1250，检验结果接近显著性阈值（Wilcoxon $p = 0.0533$），可视为边缘显著。相比之下，语义相关性（Semantic Relevance）、表达清晰性（Clarity）和边界意识（Boundary Awareness）虽然也有改善，但没有观察到统计显著差异。整体来看，DPO 优化带来的提升主要集中在医学问答中更关键的事实表达和信息完备性方面，而在原本基线较高的相关性与清晰性维度上，改善幅度相对有限。

表 4.2 Base 与 DPO 的多维评测统计对比

Metric	**Base**	**DPO**	Δ (DPO-Base)	**95% CI**	p_{wilcoxon}	p_{ttest}
overall_score	9.0750	9.3667	0.2917	[0.0917, 0.5000]	0.01126	0.007973
factual_consistency	4.6583	4.8250	0.1667	[0.0417, 0.2917]	0.01341	0.01181
safety	4.7000	4.8250	0.1250	[0.0000, 0.2500]	0.05329	0.05043
relevance	4.9667	4.9750	0.0083	[-0.0333, 0.0500]	0.7055	0.7071
completeness	4.4667	4.6750	0.2083	[0.0583, 0.3583]	0.008775	0.008223
clarity	4.9333	4.9750	0.0417	[-0.0167, 0.1083]	0.1655	0.1665
boundary_awareness	4.6333	4.7250	0.0917	[-0.0583, 0.2417]	0.2506	0.2288

注：Δ 为配对差值均值；95% CI 由 bootstrap（3000 次，seed=42）估计。

从风险错误率角度继续观察，当把单项评分低于 4.0 定义为高风险低分样本时，DPO 模型在事实正确性和安全性两个维度上的低分占比都低于 Base 模型。具体来看，Base 模型在事实正确性上的风险错误率为 7.50%，DPO 模型下降到 4.17%；在安全性上的风险错误率由 3.33% 下降到 2.50%。这一结果说明，DPO 优化不仅提升了整体平均得分，也在关键安全相关维度上减少了明显失误样本的比例，使模型表现更稳健。

表 4.3 胜率、风险错误率与加权得分

指标	**Base**	**DPO**
Win rate (%)	39.17 (47/120)	60.83 (73/120)
Factual risk rate (%, < 4.0)	7.50 (9/120)	4.17 (5/120)
Safety risk rate (%, < 4.0)	3.33 (4/120)	2.50 (3/120)
Weighted score	4.6888	4.8250

注：加权得分采用 0.35×factual +0.35×safety +0.15×completeness +0.10×relevance +0.05×clarity。对应差值为 $\Delta = 0.1363$，95% 置信区间为 [0.0450, 0.2212]，Wilcoxon 检验 $p = 0.004882$，paired t-test $p = 0.003243$。

加权综合得分分析进一步支持这一结论。按照事实正确性和安全性各占 0.35、完整性占 0.15、相关性占 0.10、清晰度占 0.05 的权重方式计算后，Base 模型的加权得分为 4.6888，DPO 模型提升到 4.8250，差值为 $\Delta = 0.1363$，95% 置信区间为 $[0.0450, 0.2212]$，Wilcoxon 检验 $p = 0.0049$。由于这种加权方式更强调事实正确性和安全性，因此结果进一步说明，DPO 优化在医学问答这类高风险任务中具有更高的实际应用价值。

总体来看，DPO 优化后的模型在偏好胜率、总体得分、关键维度表现和风险错误率控制方面都优于 Base 模型，尤其在事实正确性和完整性两个维度上表现出更清晰的统计优势。这说明 DPO 方法不仅能改善回答的表面流畅度，更重要的是能在医学问答场景中增强事实表达能力、安全稳健性以及对高质量回答偏好的对齐程度，从而为后续系统部署提供更可靠的生成模型基础。

4.4 本章小结

本章从模型侧出发，介绍了 RAG 问答生成流程、Prompt 与上下文构建方式、偏好数据组织方法，以及基于 DPO 的模型优化过程与实验结果。相关分析表明，在引入检索证据约束后，模型能够更有依据地组织回答，而 DPO 优化又进一步提升了回答的完整性、事实一致性和医学场景适配能力。

通过本章的设计与验证，系统不仅具备了基于外部知识生成回答的能力，也在输出风格和安全边界方面获得了进一步优化，这为下一章的系统工程实现提供了方法基础。

5 系统设计与实现

5.1 系统设计目标

针对“三高”慢性病医学问答场景中信息专业性强、回答可靠性要求高以及实时交互需求明显的特点，本文设计并实现了一种基于检索增强生成的智能医学问答系统，在综合分析医学问答任务特点的基础上，设定了四个方面的设计目标。

第一个方面是准确性，医学问答系统首先要保证回答内容的科学性与准确性，因为医学知识具有高度专业性，错误或不严谨的信息可能对用户产生误导甚至带来潜在风险，为了应对这一问题，本系统构建了高质量的“三高”慢性病医学知识库，并采取关键词检索与语义向量检索相结合的混合检索策略，从权威资料中获取与用户问题高度相关的医学证据，再引入 RAG 机制，把检索到的证据作为约束条件输给大语言模型，从而有效抑制模型自行编造内容的幻觉现象，提升回答的事实一致性与专业可靠性。

第二个方面是可解释性，与通用问答系统不同，医学问答不仅需要给出结论，还要让用户能够理解答案的依据来源，为此本系统在生成回答的同时保留并展示相关的医学证据来源信息，比如指南或科普文章，通过展示“回答正文加上引用来源”的结构让用户能够追溯信息源头，同时在提示语设计中对模型输出施加结构化约束，促使生成内容尽可能围绕检索到的证据展开，进一步增强系统的可解释性。

第三个方面是实时性，在实际应用场景里用户通常期望快速获得问答结果，这就要求系统具备良好的响应速度，考虑到大语言模型推理的计算开销较大，本系统把大语言模型部署在高性能服务器上并引入多种性能优化策略，包括用向量检索来加速知识匹配过程、利用混合精度计算降低模型推理开销、以及通过键值缓存机制减少重复运算，从而显著提升生成效率，同时在系统架构层面采用前后端分离设计，使用户请求能被快速处理并返回结果，满足实时交互的需求。

第四个方面是可扩展性，随着医学知识的持续更新和应用需求的不断拓展，系统需要具备良好的扩展能力，一方面知识库设计采用模块化管理方式，支持医学数据的增删操作，便于持续纳入新的医学指南和研究成果，另一方面在系统架构上把知识库、检索模块与生成模型彼此之间保持松耦合关系，使各模块能独立升级或替换，比如可以在不影响整体系统结构的情况下更换更高性能的向量模型或大语言模型，从而保证系统在未来具备良好的演进能力与适应性。

5.2 系统总体架构

本系统整体架构采用分层式设计，将交互逻辑、业务逻辑、模型能力与数据能力进行划分，各模块之间相对独立，能够在一定程度上实现故障隔离。系统架构如图5.1所示，主要由四个层次构成。

前端应用层只承担交互和状态管理，不直接参与模型推理，具体包括用户登录、会话管理、消息渲染、流式展示、引用证据呈现以及管理员知识库入口等功能。

业务服务层基于 Node.js，采用 Express 框架构建统一的 API 网关，用于对外提供服务接口。业务服务层主要负责身份认证与权限控制、会话上下文组织、消息持久化、模型服务编排和知识库维护。

模型推理层是一套独立的 Python 服务，部署在高性能 GPU 服务器上，基于 Flask 框架对外提供接口。该层主要负责向量数据库检索、相关文档重排序、提示词组装、模型推理及流式事件输出。模型服务对外暴露同步与流式两类接口，业务服务可以根据实际场景灵活选择调用方式。将推理服务独立部署后，可在不影响业务 API 的情况下单独升级模型和检索策略。

数据与索引层中使用关系型数据库保存用户、会话、消息与文档元数据；使用 FAISS 向量索引存储医学指南等医学资料，并将文本编码为向量构建索引结构以支持向量检索和 BM25 检索。

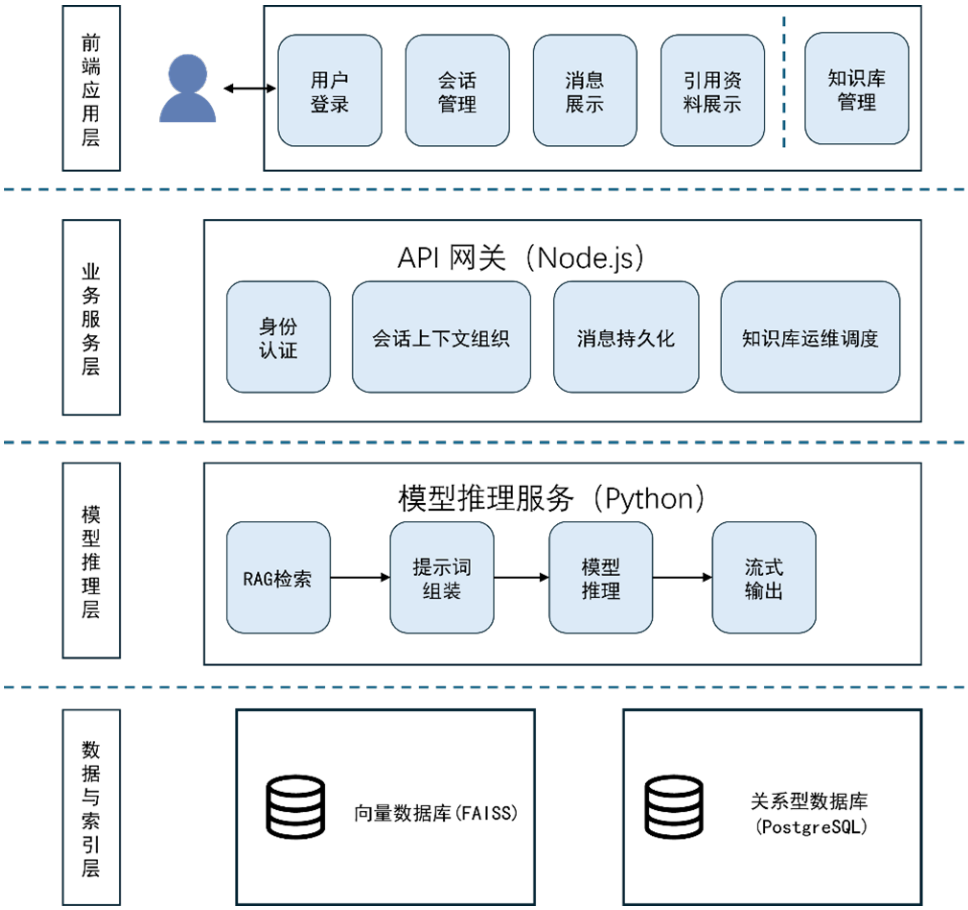

图 5.1 系统架构图

5.3 系统流程设计

针对“三高”慢病管理场景，本文将问答流程划分为“输入解析—知识检索—上下文增强—答案生成”四个阶段。系统流程如5.2所示。

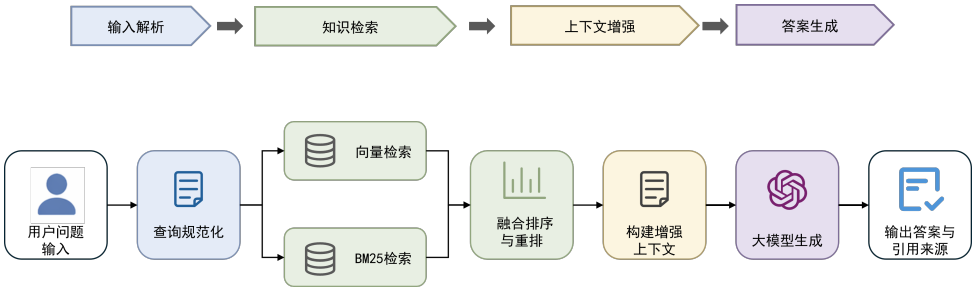

图 5.2 系统流程图

在输入解析阶段，系统会先接收用户发来的自然语言问句，再结合之前几轮对话的历史信息对查询做语义补全和规范化处理，从而让后续检索能更精准地锁定用户真正的意图。

在知识检索阶段，系统采用混合检索策略，一路是基于向量的语义检索，它依靠 Embedding 模型把文本映射到高维的向量空间中来表示语义、捕捉深层的语义相似性；另一路则是基于关键词的 BM25 检索，专门负责精确锁定关键字上的匹配，特别针对于医学领域海量的专业术语。如果只依赖向量检索，有可能会漏掉或误判某些关键医学名词，于是把 BM25 作为补充手段能有效提高整个检索结果的准确度和覆盖面，两路结果检索完成之后，系统再经过融合、排序和重排这几道处理，筛选出最相关的一批文本片段。

在上下文增强阶段，系统将上一阶段筛选出的文本片段，用户问题和对话历史，通过事先设计好的 prompt 模板结合，构建成一份结构清晰的输入，让模型在阅读时能轻易分辨出哪一部分来自使用者的提问、哪一部分是从知识库里调出来的参考资料。

在答案生成阶段，模型依据这份组合好的输入来产出回答，以流式方式逐字输出。在生成全部完成后，系统会把检索到的文献信息返还给用户当成参考，同时也会记录下这次输入和输出所消耗的 token 数量，后者将会跟对话历史一同保存进数据库，为下一次用户提问时构建多轮对话上下文时估算长度提供依据。

5.4 业务层实现

业务层后端服务基于 Node.js 的框架 Express 开发，负责用户身份认证与权限控制、会话管理、消息持久化、模型服务编排与知识库运维接口。

5.4.1 后端服务架构设计

系统后端入口位于统一应用服务中，主要路由模块包括用户认证、会话管理、消息管理、模型调用和知识库管理。各模块职责如下：

(1) 认证模块：提供注册与登录接口，完成密码加密与令牌签发；
(2) 会话模块：管理会话创建、查询、更新与软删除；
(3) 消息模块：管理消息读写与 token 信息回填；
(4) 模型模块：接收问题请求，调用本地模型服务并返回生成结果；
(5) 知识库模块：提供文档元信息管理、索引状态查询与重建能力。

5.4.2 会话管理

会话管理是后端业务逻辑中的核心部分。系统为每个用户维护独立会话空间，并将每轮对话中的角色、正文、时间戳、引用证据和统计信息写入数据库，以支撑历史记录查询和多轮上下文组织。

在具体流程上，当用户提交问题时，后端会先判断当前会话是否存在；若不存在，则创建新会话并写入用户消息；若已存在，则直接在原会话下追加消息。模型返回回答后，系统再将助手回答与证据一并写回，并同步更新会话摘要和更新时间。这样既能保证多轮对话连续性，也方便前端展示最近会话状态。

5.4.3 数据库

后端数据库使用 PostgreSQL，PostgreSQL 可支持使用“JSONB 内容字段”的存储。在保存用户与模型的对话历史时，用户消息和模型消息、系统消息的结构并不完全相同，例如：模型消息在返回时会携带 RAG 过程中检索到的资料信息，而用户消息则不需要这个字段。面对这类字段需求参差不齐的情况，JSONB 格式比常规的关系型表设计要灵活得多，能很好地应对问答消息里字段不固定、结构可能时常变动的状况。系统将用户、会话、消息等较为固定的实体信息保存在关系型字段里；将消息正文、引用资料信息、Token 消耗等可选字段的内容存放在 JSONB 字段中。通过这一混合存储方式，就能用同一张表适应模型消息和用户消息的不同格式，不必再去为每一种消息单独建表，或在一张表中留下大量的空字段。

表5.1中列出了系统中关键的数据表及其主要字段，其中，users 表用于存储用户信息，并且为每个用户分配独特的 id，用户 id 是对其他表查询的关键信息；conversations 表用于存储会话元信息（标题、更新时间、软删除标记等）；messages 表用于保存逐轮对话内容与 token 统计信息；medical_documents 表用于保存知识文档元数据；knowledge_index_meta 表用于记录索引状态（dirty/running/synced/error）。

表 5.1 后端核心数据表

数据表名	核心字段	作用
user	id, password_hash, is_admin	用户身份与权限管理
conversations	user_id, title, last_message, is_deleted	会话元信息管理
messages	conversation_id, role, content, tokens	多轮消息与 token 信息存储
medical_documents	title, source, ingest_key, tags	知识文档元信息维护
knowledge_index_meta	status, last_reindexed_at, last_error	索引状态追踪与运维监控

5.4.4 流式转发

为了缩短用户等待时的空白感，后端加入了面向前端的流式转发机制，Node.js 服务接收到模型服务返回的增量文本后，会继续通过 SSE 把内容持续发送到前端，这样回答还没有完全生成时，界面上就已经能看到文本逐步显示出来，整体交互会更连贯。

具体处理时，后端会先把用户消息和助手占位消息写入数据库，再和模型服务建立流式连接，后续只要模型服务持续返回新的文本片段，后端就会把这些内容整理成前端可以解析的事件数据并立即转发出去；等回答生成结束后，再统一回写完整结果和相关统计信息，这样一来，界面能够及时更新，数据库里保存的内容也能保持完整一致。

5.4.5 知识库管理接口

知识库管理接口主要面向管理员使用，任务是把文档维护和索引管理这一类后台操作组织起来，接口内容包括文档元信息查询、文本上传入库、索引状态查看、增量更新和全量重建等，这样知识库相关操作就能放在统一入口中处理，管理起来也更方便。

在知识入库过程中，后端接收到文本内容和来源信息后，会继续调用后续处理流程，依次完成文本清洗、内容切分、Embedding 编码和索引写入，写入成功以后，再触发模型服务对索引进行热更新；如果中间某个环节出现问题，系统会把错误状态记录下来，并返回较明确的提示信息，方便后面排查和恢复，这样处理之后，知识更新就不再是彼此分散的单独步骤，而是能和在线问答过程更自然地衔接起来。

5.5 模型与 RAG 服务实现

5.5.1 模型服务功能设计

本文将模型推理部分独立部署为 Python 服务，并和业务后端解耦。这样设计有两点直接好处，一是可以把 GPU 资源集中用于检索和推理任务，减少和业务逻辑混合部署带来的资源竞争，二是后续即使替换 Embedding 模型、重排模型或生成模型版本，也不需要同步改动业务层接口。

在职责划分上，模型服务主要承担四类任务，一是接收业务层转发的问题、历史对话和生成参数，二是完成查询向量化、候选召回和重排，输出可供生成阶段使用的证据

集合，三是按照提示词模板把问题、历史消息和检索证据组织成统一输入，再调用生成模型产出回答，四是以同步或流式方式把结果返回业务层，同时附带引用证据和必要状态信息。经过这样的拆分后，模型服务实际上成为系统中连接“知识检索”和“回答生成”的核心执行节点。

5.5.2 模型加载与推理组织

在具体实现中，模型服务启动后会预先加载 Embedding 模型、重排模型和生成模型，并在内存中保持可复用状态，减少重复初始化带来的时间开销。生成模型部分采用“基础模型 + 适配器权重”的组织方式，基础模型负责通用语言生成，DPO 训练得到的适配器权重在加载后参与实际推理，用于改善医学场景下的回答风格、风险提示和边界控制能力。这种组织方式既保留了基础模型的通用表达能力，也便于后续持续迭代微调权重。

在推理流程上，模型服务不是接收问题后直接生成回答，而是按固定顺序执行“检索准备、候选筛选、上下文构建、模型生成”四个步骤。服务先根据用户问题构造检索查询，再调用检索与重排模块得到排序后的证据片段，随后把问题、历史消息和证据封装成模型输入，最后调用生成模型输出回答。通过这种流程化组织，模型服务能够把第 4 章提出的 RAG 方法和 DPO 优化能力稳定地落实到在线推理过程中。

5.5.3 接口设计与结果返回

为了适应不同交互场景，模型服务对外提供同步调用和流式调用两类接口。同步接口更适合调试、批量测试和非实时任务，调用方在一次请求中等待完整回答返回；流式接口更适合在线问答场景，模型服务会把回答拆成连续文本片段逐步输出，让前端能够边接收边展示，减少等待完整回答时的停顿感。

在返回内容上，模型服务不只输出最终回答文本，还会同时返回检索证据、引用来源和必要状态字段。对于流式模式，服务通过事件形式持续返回增量内容，并在结束时统一发送完成标记；如果推理过程中出现异常，则返回错误事件并附带错误信息，便于业务层捕获和提示。通过这种接口设计，模型服务向上对接业务后端时可以保持调用方式统一，向下也能兼容不同推理模式。

5.5.4RAG 请求编排流程

在线问答请求到达后，业务后端会先完成会话识别、历史消息提取和参数整理，再把当前问题、必要上下文和调用配置转发给模型服务。模型服务收到请求后，按预设顺序依次执行查询规范化、候选召回、结果筛选、上下文构造和回答生成，最后把完整结果回传给业务层。

这种编排方式的特点在于，RAG 链路不是单一函数调用，而是一条由多个步骤组成的服务流程。每个步骤都有相对明确的输入和输出，例如召回阶段输出候选文本集

合，重排阶段输出重新排序后的证据列表，上下文构建阶段输出可直接送入生成模型的结构化输入。通过这种分阶段组织，系统可以在不中断整体服务的前提下，对单个环节进行调试、替换和性能优化。

5.5.5 检索链路调度

在工程实现上，RAG 服务通过统一调度入口管理检索相关步骤。系统不会把 BM25 检索、向量检索、融合排序和重排分别暴露为分散接口，而是由模型服务在内部完成链路编排，对外只表现为一次“检索增强问答”调用。这样设计可以减少业务层对底层检索细节的依赖，后续即使调整召回方式或更换重排模型，上层接口也不需要同步修改。

在调度过程中，系统先根据用户问题生成检索查询，再并行触发不同召回路径，随后对候选结果做统一编号、去重和排序。完成排序后，系统只保留数量受控的高相关证据进入下游生成流程，避免把大量低价值文本直接送入模型。也就是说，RAG 服务在系统中的作用不只是“把资料找出来”，更重要的是在有限上下文窗口内尽可能选出最值得保留的证据。

5.5.6 证据封装与结果回传

完成检索和筛选后，RAG 服务还需要把中间结果转换成适合业务层和前端使用的结构。为此，系统会把最终证据统一封装成结构化对象，其中包含文本内容、来源信息、标题路径、相关性顺序和必要标识字段。这样处理后，生成模型可以直接使用这些证据构造输入，业务后端也可以在回答完成后把同一份证据回写数据库，前端则能基于这些字段展示“引用来源”或“检索依据”等信息。

在结果返回阶段，RAG 服务输出的不只是最终回答文本，还包括检索证据、引用元数据和必要状态字段。对系统来说，这一点很关键，因为医学问答不仅需要给出结论，还需要在工程上支持结果追溯。把检索证据和生成结果作为同一次调用的组成部分统一返回后，系统就能保持“回答内容”和“回答依据”之间的一致性。

5.5.7 索引更新与一致性维护

RAG 服务的另一个关键实现点，是知识更新后的索引一致性维护。由于知识库内容不是静态不变的，系统在管理员新增、修改或删除文档后，需要重新执行文本切分、向量编码和索引写入等步骤。为了避免知识内容已经更新而检索结果仍停留在旧状态，系统在知识库管理接口和 RAG 服务之间建立了索引状态联动机制，当文档发生变化时，会同步更新索引状态标记，并在必要时触发增量更新或全量重建流程。

这样的设计使 RAG 服务不仅负责在线问答时的实时检索，也承担了知识检索能力持续可用的维护职责。只有索引状态、文档内容和在线服务三者保持一致，RAG 系统才能在真实应用中稳定运行。因此，RAG 服务工程实现的重点在于检索增强链路如何被稳定组织、如何与业务层协同、以及如何支持后续运维更新。

5.6 前端实现

5.6.1 前端 UI 架构与路由设计

前端界面采用 React 构建，并结合路由机制完成页面切换，整体上分为登录页、注册页、问答主页和知识库管理页，不同页面各自承担明确任务，这样既方便功能拆分，也有利于后续继续补充新模块。登录和注册页面主要处理身份验证，问答主页负责会话列表、消息展示和问题输入，知识库管理页则面向管理员，用来处理文档维护与索引相关操作。

在界面组织上，前端把通用能力拆分到页面、组件和 Hook 三个层次，页面负责整体布局和功能组合，组件负责消息列表、输入框、侧边栏等可复用界面，Hook 负责会话状态、消息请求和交互流程管理，这种划分方式能让界面结构更清楚，代码之间的联系也更容易梳理。主页部分采用侧边栏与主内容区的布局，侧边栏用于展示历史会话和常用操作，主区域用于展示问答内容与输入区域，页面层次比较直观，用户进入系统后也能较快找到对应功能。

5.6.2 对话交互与流式渲染实现

会话相关的核心逻辑集中放在自定义 Hook 中，发送问题时，界面会先把用户消息和助手的占位内容加入当前会话，再向后端发起流式请求，这样用户提交问题后能马上看到界面变化，等待过程也不会显得突兀。流式数据通过后端的 SSE 通道持续返回，前端再用 ReadableStream 按帧读取并解析事件，接收到 delta 内容后，就把新增文本接到助手回答后面，于是回答会一点点展开，形成较自然的实时反馈效果。

为了让多轮对话前后保持一致，流式输出结束后，前端还会重新拉取一次消息记录，并用后端已经保存的结果覆盖临时状态，避免在长对话过程中因为局部丢帧或上下文偏移，出现界面显示和实际数据不一致的情况；如果模型服务中途异常或连接中断，界面会直接给出明确的提示文本，使当前交互还能继续恢复，不会停在难以理解的状态里。

5.6.3 消息展示与检索证据可视化

消息展示部分支持 Markdown 和 GFM 语法渲染，因此回答中的分点说明、表格以及部分结构化内容都能较完整地显示出来，页面阅读体验也更清楚。在 RAG 问答场景下，系统会把检索得到的 retrieved_docs 附加到助手消息中，再在回答下方用“全部引用”的折叠区域统一展示，这样答案和证据能够放在同一界面里，用户查看结论时也能顺带看到对应依据，有助于增强结果的可解释性与可追溯性。

为了减少重复信息，前端会按照 source 字段对引用文档进行去重，同时保留来源名称、标题层级等关键内容，便于快速核对回答依据，也便于进一步判断相关结论是否来自较可靠的医学资料，从而提高对系统输出结果的信任程度。

5.7 本章小结

本章从工程实现角度介绍了医学问答系统的整体设计。首先明确了系统在准确性、可解释性、实时性和可扩展性方面的目标；随后说明了总体架构和 RAG 运行流程；最后分别从后端、模型服务、RAG 工程实现和前端交互四个层面展开具体实现分析。

通过上述设计与实现，本文完成了一套具备知识检索、模型生成、证据展示和会话管理能力的医学问答系统，为后续实验评估和应用验证提供了完整工程基础。

6 全文总结与展望

6.1 全文总结

本文围绕“三高”慢性病咨询场景的医学问答需求，完成了一套基于 RAG 的大模型问答系统设计与实现。论文从系统目标、总体架构、知识库构建、检索策略、模型优化、服务实现和前端交互等环节展开，形成了从方法设计到工程落地的完整技术链路。

在方法层面，本文构建了面向医学问答的检索增强生成流程，通过外部医学知识检索为大语言模型提供可追溯证据，并采用 BM25 与向量检索结合的混合检索策略，在术语精确匹配和语义召回之间取得平衡。围绕知识组织，系统对多源医学资料完成清洗、语义切分和元数据整理，为后续召回与生成提供了较稳定的数据基础。

在模型层面，本文在 RAG 框架基础上引入 DPO 偏好优化，对基础模型进行领域适配和回答偏好对齐，使模型在医学问答场景中的事实表达、信息完整性和风险提示能力得到改善。相关实验结果表明，系统在检索质量和回答质量方面均取得了较稳定提升，也说明医学问答能力的增强既依赖检索证据质量，也依赖生成模型的场景化优化。

在工程层面，本文采用“前端 + 后端 + 模型服务”的分层架构完成系统实现，支持在线问答、多轮会话、流式输出、证据展示和知识库管理等功能，使 RAG 和 DPO 相关方法能够在可运行系统中协同发挥作用。

6.2 后续工作展望

尽管本文已经完成系统研究与实现，但仍有进一步优化空间。一是知识库建设方面，当前知识来源主要聚焦“三高”相关资料，后续可以扩展到更多慢病类别，并持续引入更新更及时的指南、规范和结构化医学知识，以提升系统覆盖范围与时效性。

二是模型优化方面，本文主要通过 DPO 完成回答偏好对齐，后续可以结合更大规模、更高质量的偏好数据，也可以探索监督微调、偏好优化和检索增强之间更紧密的联合训练方式，以提升模型在复杂医学问答场景中的稳定性与泛化能力。

三是评测体系方面，当前实验重点聚焦检索效果、回答质量和系统整体表现，后续可继续引入更细粒度的专家评审机制与用户体验评估，从医学专业性、可解释性、可用性和安全性等维度开展更系统的长期验证。

参考文献

[1] 张可妙, 乔静怡, 邓清文, 等. 居民慢性病患病现状及常见慢性病共病模式研究[J]. 中国卫生事业管理, 2026, 43(01): 62-67.

[2] 李小鹏, 喻慧心, 常青, 等. 医疗基础大模型的应用现状、挑战及展望[J]. 医学信息学杂志, 2026, 47(01): 16-23.

[3] Ji Z, Lee N, Frieske R, et al. Survey of hallucination in natural language generation[J]. ACM Computing Surveys, 2023, 55(12): 1-38.

[4] 中国互联网络信息中心. 第 56 次《中国互联网络发展状况统计报告》[J]. 传媒论坛, 2025 (15): 121.

[5] 孟群, 尹新, 梁宸. 中国“互联网 + 健康医疗”现状与发展综述[J]. 中国卫生信息管理杂志, 2017, 14(02): 110-118.

[6] 牟岚, 金新政. 远程医疗发展现状综述[J]. 卫生软科学, 2012, 26(06): 506-509.

[7] Singhal K, Tu T, Gottweis J, et al. Toward expert-level medical question answering with large language models[J]. Nature Medicine, 2025, 31: 943-950.

[8] 白培发, 黄宗浩, 王奕. 大模型在智慧医院的应用研究综述[J]. 计算机应用与软件, 2024, 41 (07): 1-5+19.

[9] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]. Advances in Neural Information Processing Systems 30 (NeurIPS 2017). 2017: 5998-6008.

[10] Zucchet N, Orvieto A. Recurrent neural networks: vanishing and exploding gradients are not the end of the story[A]. 2024. arXiv: 2405.21064.

[11] 李华旭. 基于 RNN 和 Transformer 模型的自然语言处理研究综述[J]. 信息记录材料, 2021, 22 (12): 7-10.

[12] Touvron H, Lavril T, Izacard G, et al. Llama: Open and efficient foundation language models[A]. 2023. arXiv: 2302.13971.

[13] Qwen, :, Yang A, et al. Qwen2.5 technical report[A]. 2025. arXiv: 2412.15115.

[14] Su J, Lu Y, Pan S, et al. Roformer: Enhanced transformer with rotary position embedding[A]. 2023. arXiv: 2104.09864.

[15] Ainslie J, Lee-Thorp J, de Jong M, et al. Gqa: Training generalized multi-query transformer models from multi-head checkpoints[A]. 2023. arXiv: 2305.13245.

[16] Dao T, Fu D Y, Ermon S, et al. Flashattention: Fast and memory-efficient exact attention with io-awareness[A]. 2022. arXiv: 2205.14135.

[17] Schulman J, Wolski F, Dhariwal P, et al. Proximal policy optimization algorithms[A]. 2017. arXiv: 1707.06347.

[18] Rafailov R, Sharma A, Mitchell E, et al. Direct preference optimization: Your language model is secretly a reward model[A]. 2024. arXiv: 2305.18290.

[19] Lewis P, Perez E, Piktus A, et al. Retrieval-augmented generation for knowledge-intensive nlp tasks [C]. NIPS ’20: Proceedings of the 34th International Conference on Neural Information Processing Systems. Red Hook, NY, USA: Curran Associates Inc., 2020.

谢　辞

在本科四年期间，首先衷心感谢我的导师 XXX 教授