桂林電子科技大学
GUILIN UNIVERSITY OF ELECTRONIC TECHNOLOGY

本科毕业设计（论文）

题目： 基于 RAG 的“三高”慢性病医学问答系统设计与实现

学　　号： 2200820924

姓　　名： 牛嘉贺

学　　院： 计算机与信息安全学院

专　　业： 计算机科学与技术

指 导 教 师： 李优

指导教师职称： 教授

2026 年 4 月 28 日

本科生毕业设计（论文）独创性声明

本人声明所呈交的毕业设计（论文）是我个人在指导老师指导下进行的工作及取得的成果。尽我所知，除了文中特别加以标注和致谢中所罗列的内容以外，文中不包含其他人或其它机构已经发表或撰写过的成果；也不包含为获得桂林电子科技大学或其他教育机构的学位或证书而使用过的材料。其他同志对本工作的启发和所做的任何贡献均已在毕业设计（论文）中做了明确的说明并表示了谢意。

毕业设计（论文）若有不实之处，本人承担一切相关责任。

本人签名：　　日期：

本科生毕业设计（论文）使用授权说明

桂林电子科技大学有权保留并向国家有关部门或机构送交毕业设计说明书（论文）的复印件，允许毕业设计（论文）被查阅和借阅。本人授权桂林电子科技大学可以公布毕业设计（论文）的全部或部分内容，可以采用影印、缩印或其它复制手段保存、汇编毕业设计（论文）。

作者签名：　　日期：

导师签名：　　日期：

摘 要

随着大语言模型技术的发展，智能问答系统在医疗健康领域展现出良好的应用前景。然而，医学问答任务具有知识专业性强、事实准确性要求高、回答过程需要可追溯等特点，传统仅依赖参数记忆的生成方式容易产生知识幻觉和依据不明确等问题。针对高血压、高血糖和高血脂等“三高”慢性病场景中的问答需求，本文设计并实现了一种基于检索增强生成（Retrieval-Augmented Generation, RAG）的医学问答系统。

本文围绕医学知识库构建、文本检索与系统实现三个方面展开研究。首先，对多源医学文本进行清洗、格式统一、语义切分与元数据组织，构建面向“三高”慢性病的医学知识库；其次，针对医学文本中术语密集、表达多样的特点，设计结合 BM25 关键词检索与向量检索的混合检索方法，并引入重排机制提升证据召回质量；最后，完成前后端分离的系统实现，构建业务服务、模型服务与知识库管理模块，实现多轮问答、流式输出、引用展示与知识更新等功能。

研究结果表明，所设计系统能够较好地将外部医学知识引入生成过程，在保证交互效率的同时提高问答结果的准确性、稳定性与可解释性。本文的研究为检索增强生成技术在垂直医学问答场景中的应用提供了可行的实现方案，也为慢性病健康问答系统的设计与开发提供了参考。

关键词：慢性病医学问答；检索增强生成；混合检索；大语言模型；系统设计与实现

Abstract

With the rapid development of large language models, intelligent question answering systems have shown broad application potential in the healthcare domain. However, medical question answering requires high factual accuracy, domain-specific knowledge, and traceable evidence. Traditional generation methods relying only on parametric memory are prone to hallucination and lack sufficient explainability. To address these issues in the scenario of chronic diseases known as the "three highs" including hypertension, hyperglycemia, and hyperlipidemia, this thesis designs and implements a medical question answering system based on Retrieval-Augmented Generation (RAG).

This work focuses on three aspects: medical knowledge base construction, text retrieval, and system implementation. First, multi-source medical documents are processed through data cleaning, format unification, semantic chunking, and metadata organization to build a domain-specific knowledge base. Second, a hybrid retrieval method combining BM25 keyword retrieval and dense vector retrieval is designed, and a reranking mechanism is introduced to improve the quality of retrieved evidence. Third, a decoupled front-end and back-end system is implemented to support multi-turn dialogue, streaming response, citation presentation, and knowledge base update.

The results show that the proposed system can effectively incorporate external medical knowledge into the generation process and improve the accuracy, stability, and interpretability of answers while maintaining interactive efficiency. This study provides a feasible solution for applying RAG technology to vertical medical question answering scenarios and offers practical reference for the design and development of chronic disease QA systems.

Keywords: Chronic Disease Medical QA; Retrieval-Augmented Generation; Hybrid Retrieval; Large Language Model; System Design and Implementation

目 录

引言 1
1 绪论 2
1.1 课题的研究背景与意义 2
1.2 国内外研究现状 2
1.2.1 互联网问诊的发展现状 2
1.2.2 传统医学问答模型的发展现状 3
1.3 本文研究内容 4
2 相关理论和技术介绍 5
2.1 大语言模型概述 5
2.1.1 Transformer 模型 5
2.1.2 现代大模型 6
2.1.3 模型训练技术 7
2.2 检索增强生成（RAG）技术 8
2.3 向量检索与 Embedding 技术 8
3 基于 RAG 与 DPO 的医学问答模型研究与实现 9
3.1 医学知识库构建方法 9
3.1.1 数据来源 9
3.1.2 数据预处理 9
3.1.3 文本语义切分 9
3.1.4 Embedding 向量化表示 10
3.1.5 向量数据库构建 11
3.2 医学文本检索方法 11
3.2.1 BM25 关键词检索原理 11
3.2.2 向量检索原理 11
3.2.3 混合检索策略 12
3.2.4 实验与结果分析 12
3.3 RAG 问答生成方法 14
3.3.1 检索—增强—生成流程 14
3.3.2 Prompt 与上下文构建 14

3.4 基于 DPO 的模型优化方法 14
3.4.1 偏好数据构建 14
3.5 基于 DPO 的模型优化策略 16
3.5.1 偏好数据构建 16
3.5.2 DPO 训练流程 16
3.5.3 实验结果分析 17
4 系统设计与实现 19
4.1 系统设计目标 19
4.2 系统总体架构 19
4.3 系统流程设计 20
4.4 业务层实现 21
4.4.1 后端服务架构设计 21
4.4.2 会话管理 21
4.4.3 数据库 22
4.4.4 流式转发 22
4.4.5 知识库管理接口 23
4.5 模型服务实现 23
4.5.1 Qwen 推理服务 23
4.5.2 bge Embedding 服务 23
4.5.3 DPO 模型加载与推理 23
4.5.4 流式输出 24
4.6 RAG 服务工程实现 24
4.6.1 检索调用流程 24
4.6.2 BM25 + 向量融合实现 24
4.6.3 Rerank 实现 24
4.6.4 上下文拼接 24
4.7 前端实现 25
4.7.1 前端 UI 架构与路由设计 25
4.7.2 对话交互与流式渲染实现 25
4.7.3 消息展示与检索证据可视化 25
4.8 本章小结 26
5 实验与结果分析 27

5.1 实验环境 27
5.2 评价指标 27
5.3 RAG 检索效果实验 27
5.4 DPO 优化效果实验 28
5.4.1 Before vs After 对比 28
5.4.2 幻觉对比 28
5.4.3 医学准确性提升 29
5.5 系统整体效果 29
参考文献 30
谢辞 31

引言

1 绪论

1.1 课题的研究背景与意义

随着人口老龄化不断加深，慢性病管理已成为公共健康领域的长期议题。在常见慢性病中，高血压、高血糖和高血脂患者数量大、管理周期长、复发风险高，患者往往不能只依赖少数几次门诊完成健康管理。与急性疾病不同，“三高”管理更强调日常监测和持续干预，患者在真实生活中会频繁遇到诸如指标是否异常、饮食如何调整、药物需不需要复查、症状是否需要就医等具体问题。这类问题看似琐碎，却直接影响治疗依从性和病情控制效果。

传统医疗服务以线下诊疗为主，患者通常只有感到身体不适或按固定的时间安排才会选择就医，患者难以获得持续、及时的健康指导。同时，由于医疗资源分布不均以及医生数量相对有限，患者在非就诊期间获取专业医疗建议的渠道较为有限。所以很多患者选择去互联网搜索相关健康信息，但互联网上信息来源复杂、质量参差不齐，用户很难从中获得可靠的医学建议。

近年来，大语言模型（Large Language Model，LLM）发展很快，在理解和生成文本方面都有明显提升，通过大语言模型构建智能医疗问答系统成为可能。基于 LLM 的问答系统能够理解用户提出的问题，并生成相对流畅的回答，在医疗咨询等场景中展现出一定应用潜力。但是将通用 LLM 直接应用在医学领域时，会面临知识更新滞后、事实错误（幻觉）以及缺乏依据等问题。

基于这一背景，本文引入检索增强生成（Retrieval-Augmented Generation，RAG）技术，将外部医学知识库与大语言模型结合起来。其核心思路不是让模型“凭记忆作答”，而是在生成前先检索相关医学资料，再据此组织回答。这样做的价值主要体现在三个方面：第一，可以降低医学问答中的幻觉风险；第二，可以让回答建立在可追溯的证据基础上；第三，更便于系统随知识更新而持续维护。因而，围绕“三高”慢病场景研究并实现一套基于 RAG 的医学问答系统，既具有现实应用意义，也具有一定的技术研究价值。

1.2 国内外研究现状

1.2.1 互联网问诊的发展现状

随着互联网技术和智能手机的普及，互联网问诊模式出现并迅速发展。根据中国互联网络信息中心第 57 次《中国互联网络发展状况统计报告》显示，截至 2025 年底，中国网民规模达 11.25 亿，互联网普及率突破 80

国外的医疗平台则更注重于远程医疗。例如，瑞典的 KRY 和美国 Teladoc Health、Doctor on Demand 等平台实行线上预约并利用会议视频实时问诊，让患者在家里即可享受到专业的医疗问诊。但这类服务仍有很多不足，首先是患者可能需要支出额外的费

用，以享受远程问诊的服务；而且平台签约医生数量相对固定，高峰时段还需预约排队；如果涉及身体检查的情况，仍需要去线下医院就诊。

总体来看，互联网问诊的发展说明医疗服务正在不断向线上延伸，患者获取健康咨询的方式也由传统门诊逐步扩展到网络平台与远程服务。然而，现阶段互联网问诊仍主要依赖人工医生答复，其服务能力、响应效率和服务成本都受到现实医疗资源的制约。在这一背景下，如何借助自然语言处理与智能问答技术，为用户提供更及时、更稳定的医学信息支持，逐渐成为医学人工智能研究的重要问题，因此也推动了医学问答模型的持续发展。

1.2.2 传统医学问答模型的发展现状

早期医学自然语言处理模型主要集中在医学术语识别、实体抽取和文献理解等任务上，代表性工作包括 BioBERT、BlueBERT、ClinicalBERT 和 PubMedBERT 等。这类模型大多建立在 BERT 框架之上，通过 PubMed 文献、临床记录或生物医学语料继续预训练，使模型在医学词汇和专业语义建模方面明显优于通用语言模型。其主要价值在于提升医学文本表示能力，为后续问答、分类和关系抽取等任务提供基础，但这类模型主要是以理解任务为主。

随着大模型技术的发展，医学问答研究进一步转向生成式模型。例如，由 Google 提出的 Med-PaLM 和 Med-PaLM 2 模型，Med-PaLM 系列模型是专门针对于医学领域的大语言模型，Med-PaLM 通过医学领域微调和人工评估，使其在医学考试题、患者咨询和临床推理任务中相较于通用大语言模型有更好的表现，Med-PaLM 也是第一个在美国医师执照考试样例问题中获得“合格”的模型。国内的科研机构也在积极推进大模型在医学领域的应用，也推出了许多针对于医学领域的大模型，例如：DoctorGLM、华佗 GPT 等。DoctorGLM 是基于 ChatGLM 的中文问诊模型，其对通用大语言做了针对医疗领域进行微调与优化工作；香港中文大学和深圳大数据研究院的研究团队推出的华佗 GPT-o1，首次将推理能力融入到了医学大模型。

医学问答模型虽然已经从 BioBERT、PubMedBERT 一类的领域预训练模型发展到 Med-PaLM、HuatuoGPT、DISC-MedLLM、MedFound 等生成式医学模型，但在真实应用场景中仍存在明显不足。其一，很多模型在考试题或标准问答集上表现较好，但面对日常慢病咨询中的口语化表达、连续追问和个体化问题时，稳定性仍然不足。其二，纯生成式模型往往难以同时满足“回答自然”和“证据清晰”这两个要求，尤其在治疗建议、药物说明和风险判断等问题上更容易暴露安全边界问题。其三，现有研究更多关注模型能力本身，而对知识更新、检索链路、证据展示和系统落地闭环关注不足。

1.3 本文研究内容

本文面向“三高”慢病健康咨询场景，围绕基于 RAG 的医学问答系统展开研究与实现，重点解决回答准确性不足、证据不可追溯以及系统难以落地等问题。整体上，本文既关注关键技术设计，也关注面向真实使用场景的工程实现，力求形成从知识构建到在线问答服务的完整链路。

首先，在知识侧，本文围绕高血压、高血糖和高血脂相关主题构建医学知识库。数据来源涵盖政策文件、诊疗指南、医学科普和互联网医学文本等多类资料，并对原始文本完成清洗、切分和元信息组织。考虑到医学文本术语密集、信息压缩度高、上下文依赖明显，本文重点分析知识组织方式对后续检索效果和回答质量的影响。

其次，在检索与生成方法侧，本文设计面向医学问答场景的混合检索与证据化生成流程。针对单一检索策略难以同时满足术语精确匹配和语义召回需求的问题，本文将关键词检索与向量检索结合，并引入重排序和结果筛选机制，提高候选证据的相关性与可用性。在此基础上，将检索结果融入大语言模型生成流程，使模型回答尽可能建立在外部证据之上。

最后，在系统实现侧，本文完成了一套可运行的医学问答系统。系统围绕用户交互、知识检索、模型调用和结果展示等核心环节进行设计，实现了知识导入、索引构建、在线问答、多轮对话、证据展示和知识库管理等功能。通过这一实现，本文不仅验证了方法的可行性，也为后续实验评估和场景应用提供了工程基础。

2 相关理论和技术介绍

2.1 大语言模型概述

大语言模型（Large Language Models，LLM）是近年来自然语言处理领域最具代表性的技术进展之一。其基本思路是通过大规模文本训练，让模型学习语言中的语法规律、语义关系和上下文依赖。与传统模型相比，大语言模型参数规模更大，能够处理更复杂的语言现象，也因此在问答、对话、摘要和内容生成等任务中表现出更强的泛化能力。当前主流大语言模型大多建立在 Transformer 框架之上，因此理解 Transformer 的基本原理，是分析后续 RAG 系统与模型优化方法的前提。

2.1.1Transformer 模型

Transformer 由 Vaswani 等人在 2017 年提出[1]，其关键突破在于用自注意力机制替代传统循环结构建模序列关系。与 RNN 和 LSTM 相比，Transformer 不需要按时间步逐次处理输入，因此训练并行度更高，也更容易捕捉长距离依赖关系。这两个特点直接推动了其在大规模预训练中的广泛应用。

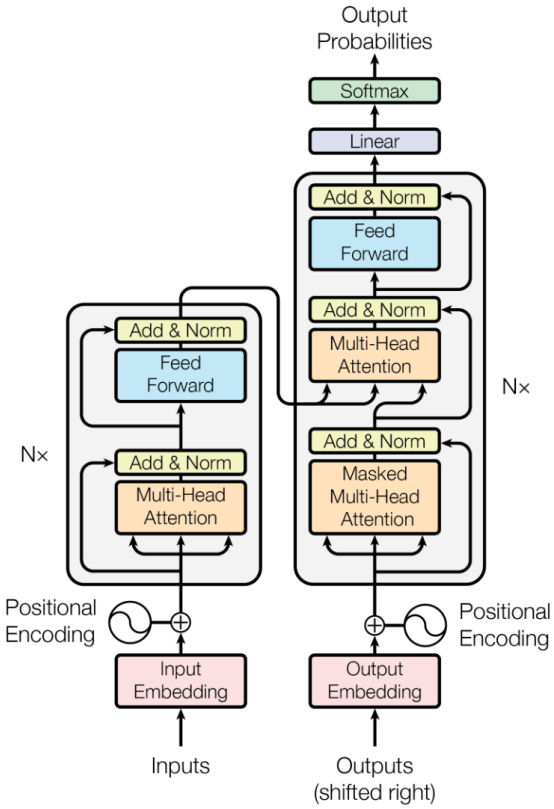

图 2.1 Transformer 结构图

如图2.1所示，Transformer 由编码器和解码器两部分组成。编码器负责将输入序列转换为高维语义表示，解码器则依据这些表示逐步生成输出。编码器和解码器都由多层

重复堆叠构成，其中最核心的模块是多头自注意力和前馈神经网络。为了提升训练稳定性，模型还在各子层后加入残差连接和归一化操作。解码器与编码器相比，多了掩码自注意力和编码器-解码器注意力，用于保证生成过程满足自回归约束，并充分利用输入语义信息。

自注意力机制是 Transformer 的核心。它的作用不是简单地“看上下文”，而是根据当前词与序列中其他词之间的相关性，动态分配信息权重。具体来说，输入向量会被映射为查询（Query）、键（Key）和值（Value）三个表示，再通过 Query 与 Key 的相似度计算注意力分数，并对 Value 加权求和，形成新的上下文表示。其标准形式为：

$$Attention(Q,K,V) = softmax(\frac{QK^T}{\sqrt{d_k}})V \qquad \text{(公式 2.1)}$$

其中，Q、K、V 分别表示查询、键和值矩阵，d_k 表示键向量维度。分母中的缩放项用于避免点积过大，减轻 softmax 进入梯度饱和区的问题。进一步地，多头注意力将这一过程并行执行多次，使模型能够从不同表示子空间观察同一段文本，从而提高特征表达能力。

2.1.2 现代大模型

现代大语言模型虽然沿用了 Transformer 的基本思想，但在结构设计上已经不再照搬最初的 Encoder-Decoder 框架。当前主流模型，如 GPT、LLaMA 和 Qwen，大多采用仅解码器（Decoder-only）结构。这种结构更适合自回归生成任务，因为模型训练目标与实际生成方式一致，都是根据已有上下文预测下一个词元。

在具体实现上，现代大模型围绕训练稳定性、长上下文建模和推理效率做了大量改进。首先，在归一化方式上，很多模型由 Post-Norm 转向 Pre-Norm，即先归一化再进入注意力和前馈层，这有助于缓解深层网络中的梯度传播问题。部分模型还采用 RMSNorm 替代 LayerNorm，以降低计算开销。其次，在位置编码方面，旋转位置编码（RoPE）已成为主流选择。与绝对位置编码相比，RoPE 更适合处理长距离依赖，在长文本理解和多轮对话中表现更稳定。

此外，现代大模型也对前馈网络和注意力实现进行了针对性优化。例如，在前馈层中引入 SwiGLU 等门控结构，可以在相近参数规模下提升非线性表达能力；在注意力机制中，采用多查询注意力（MQA）或分组查询注意力（GQA）可以减少 KV Cache 占用，降低推理阶段显存压力。对于长上下文推理，更高效的 FlashAttention 则从实现层面减少了显存读写开销。它并不显式存储完整的注意力矩阵，而是将 Q、K、V 按块处理，在片上缓存中完成局部计算与在线归一化，从而在保持结果等价的同时显著提升效率。其等价形式可写为：

$$y_i = \sum_j \frac{\exp\left(q_i \cdot \frac{k_j}{\sqrt{d}}\right)}{\sum_l \exp\left(q_i \cdot \frac{k_l}{\sqrt{d}}\right)} v_j \qquad \text{(公式 2.2)}$$

总体来看，现代大模型的这些改进并不是零散堆叠，而是围绕“大规模训练可行”和“长上下文推理高效”两个目标逐步形成的技术路线。这也为后续 RAG 系统在复杂问答场景中的应用提供了模型基础。

2.1.3 模型训练技术

大语言模型的能力形成通常经历预训练、监督微调和偏好优化等阶段。预训练阶段依赖海量无标注文本，通过下一词预测等自监督目标学习通用语言规律；这一阶段决定了模型的基础理解和生成能力。对于通用任务而言，预训练模型已经具备较强能力，但在医学问答等垂直场景中，仅靠通用能力往往不够，因为领域术语理解、回答风格控制和安全边界把握都需要更有针对性的训练。

监督微调（Supervised Fine-Tuning，SFT）是最常见的任务适配方式。它利用“输入-输出”标注样本，让模型学习特定任务的回答形式和表达方式。对于医学问答来说，SFT 的价值不只是提升答题正确率，更在于帮助模型习得更符合医学场景的组织结构，例如先回答核心问题，再给出解释和风险提示。

但随着模型规模不断扩大，全参数微调的成本也越来越高。为此，参数高效微调（PEFT）方法被广泛采用，其中 LoRA 是最常见的一类。LoRA 通过在原有权重矩阵上引入低秩增量参数，实现“少量参数更新、主体权重基本冻结”的训练方式。这种做法能够明显降低显存开销和部署成本，也更适合论文系统实现中的有限算力条件。

在监督微调之后，模型虽然已经学会“按要求作答”，但未必知道“怎样的回答更好”。为进一步优化输出质量，研究者提出了基于人类反馈的强化学习（RLHF）方法。RLHF 通常先用人工偏好数据训练奖励模型，再借助强化学习算法优化生成模型，使其输出更贴近人类偏好。不过，这一流程涉及奖励建模、策略优化和稳定性控制，训练链路较长，实现复杂度较高。

为简化偏好学习过程，2023 年提出的直接偏好优化（Direct Preference Optimization，DPO）提供了更直接的实现路径。DPO 不再单独训练奖励模型，而是直接利用“优选回答-非优选回答”成对数据优化模型偏好。其目标函数可表示为：

$$\mathcal{L}_{DPO}(\theta) = -\mathbb{E}_{(x,y_w,y_l)\sim\mathcal{D}}\left[\log\sigma\left(\beta\log\frac{\pi_\theta(y_w|x)}{\pi_{ref}(y_w|x)} - \beta\log\frac{\pi_\theta(y_l|x)}{\pi_{ref}(y_l|x)}\right)\right] \qquad \text{(公式 2.3)}$$

其中，x 表示输入问题，y_w 表示优选回答，y_l 表示非优选回答，π_θ 表示待优化模型，π_{ref} 表示参考模型，β 为偏好强度参数。该目标的含义很明确：在同一个输入下，提高模型生成优选回答的相对概率，压低生成非优选回答的相对概率。对于医学问答场景，这种方法尤其适合用来强化审慎表达、结构清晰和安全提示等输出偏好。

2.2 检索增强生成（RAG）技术

检索增强生成（Retrieval-Augmented Generation，RAG）是一种将信息检索与文本生成结合起来的方法。它的出发点并不复杂：大语言模型虽然具备很强的语言组织能力，但其知识主要固化在训练参数中，面对专业问题或新近知识时，仍可能出现遗漏和误答。RAG 的作用，就是在模型生成前先从外部知识库中检索相关内容，再把这些内容作为上下文交给模型使用。

从流程上看，RAG 通常包含“检索”和“生成”两个核心环节。系统先根据用户问题构造查询，从知识库中召回相关文本片段；再将这些片段与原始问题一起输入大语言模型，完成回答生成。与纯生成式问答相比，RAG 最大的不同在于回答不再完全依赖模型记忆，而是建立在外部证据基础上。这一变化直接提升了系统在知识密集型任务中的准确性和可解释性。

对于医学问答而言，RAG 的意义尤其突出。医学场景对事实准确性要求高，且用户往往希望知道“为什么这么回答”。RAG 一方面能缓解模型幻觉，另一方面也为回答提供了证据来源，使系统更适合部署在需要追溯依据的专业领域中。因此，RAG 已经成为构建垂直领域问答系统的重要技术路径。

2.3 向量检索与 Embedding 技术

在 RAG 框架中，检索效果往往决定了最终回答质量，而向量检索是当前最常见的语义检索方案。其核心思想是：将文本表示为高维向量，并通过向量之间的距离或相似度衡量语义接近程度。这样，系统不必只依赖词面匹配，也可以识别同义表达、口语化描述和隐含语义关系。

实现这一能力的关键在于 Embedding 模型。Embedding 模型通过预训练学习文本表示，把自然语言映射到连续向量空间，使语义相近的文本在空间中彼此更靠近。与传统词袋模型或关键词匹配方法相比，Embedding 能够保留更多上下文信息，因此更适合处理自然语言问答中的表达多样性问题。

在具体使用中，系统首先对知识库中的文本块进行向量化，并构建向量索引；用户提问时，再将问题编码为向量，与知识库向量进行相似度匹配，选出最相关的若干文本片段。本文采用基于 Transformer 的 bge 嵌入模型完成这一过程。选择该模型的原因在于其中文语义表示能力较强，能够较好适应医学问答中常见的术语、症状描述和生活化提问方式。

需要指出的是，向量检索并不是对关键词检索的完全替代。它更擅长“语义相近”的匹配，但对某些关键实体的精确约束相对较弱。因此，在医学场景中，向量检索通常需要与其他检索手段配合使用，才能同时兼顾召回范围和命中准确性。

3 基于 RAG 与 DPO 的医学问答模型研究与实现

本章围绕医学问答系统中的核心算法展开，重点讨论知识侧的 RAG 流程和模型侧的 DPO 优化。前者解决“模型回答依据从哪里来”的问题，后者解决“模型在有依据时如何更稳妥地表达”的问题。二者结合后，系统不仅能够检索到相关医学知识，也更容易输出结构清晰、边界明确的回答。

3.1 医学知识库构建方法

3.1.1 数据来源

医学知识库的数据来源直接关系到系统问答的准确性与可靠性。针对“三高”（高血压、高血糖、高血脂）相关内容，本系统主要选取公开且具有一定权威性的医学资料，以保证知识内容的科学性与可信度。数据主要来源于以下三个方面：

(1) 权威医学指南与报告：主要包括国家卫生健康委员会等官方的政策文件、指南与规范和健康报告。
(2) 医疗机构与专业平台内容：主要包括丁香园、医知源等平台发布的疾病科普文章和健康建议。
(3) 医学科普网站与百科类资源：主要包括维基百科等平台中“三高”相关词条。

3.1.2 数据预处理

本系统的医学知识库由多种格式的原始文档构成，主要格式为 PDF 文档与 HTML 网页内容。由于不同来源的数据结构差异较大，因此系统针对不同数据类型分别设计了预处理策略，将文档转换为文本格式，以便后续的文本分段和向量化处理。

(1) PDF 文档处理：对于 PDF 格式的医学资料，使用 MinerU 工具进行解析。MinerU 基于多模态大模型，能够正确识别不同排版结构的 PDF 文档，最后将其转换为结构化的 Markdown（.md）格式。
(2) 对于 HTML 网页数据，通过解析网页内容使用 document.body.innerText 指令提取，将其转换为纯文本（.txt）格式，以提取其中的核心文本信息。

3.1.3 文本语义切分

在 RAG 系统中，模型通常不需要把整篇文档原封不动地作为生成时的输入，而且过长的文档还会导致向量化表示和检索的难度增加。这就要求必须对文本进行合理的切分，在尽可能保留原始医学文本语义结构的前提下，将长文档划分为适合检索与生成使用的文本块。如果切分后 chunk 过长，单个文本块中会包含过多无关信息，影响检索精度；若切分后 chunk 过短，则容易破坏上下文完整性，导致关键知识被割裂。因此，本

系统切分策略并不是简单的按固定长度截断，而是要按照标题和段落结构来切分文档。

对于 PDF 解析得到的 Markdown 文本，系统会先去除文末的参考文献、页脚等与问答无关的内容，之后则按照 Markdown 语法识别标题与正文块。系统会创建一个标题栈，通过维护标题栈记录当前文本所在的层级路径，当遇到新的标题时，先把之前缓存的内容输出，再更新标题路径；当遇到普通段落时，则将其合并到当前标题对应的缓冲区中。如果缓冲区内容超过长度阈值，系统会优先按照句号、问号、感叹号等语句结束标点进行切分，并将上一个文本块末尾的 120 字符作为下一文本块的开头，从而形成带重叠的连续片段，尽量避免关键信息被分割。经过这样的处理，Markdown 文本最终被切分为“标题路径 + 正文内容”的结构化片段。

对于网页提取得到的 TXT 文本，由于其与 Markdown 不同，并不具有“标题”和“正文”的标识，系统采用启发式规则进行语义切分，但总体的切分思路相同。程序首先按连续空行划分自然段，再对单行或多行段落进行标题识别。标题识别主要依据中文医学资料中常见的编号形式，如“一、”“（一）”“1.”“（1）”等，同时对长度较短且不以句末标点结束的行引入隐式标题判定规则，以适应网页文本中未显式标注层级但具备标题特征的内容。与 Markdown 文档处理方式相同的是，系统仍会创建一个标题栈用于记录段落所属的层级关系。在具体合并策略上，若新标题属于同级或更高层级，则输出当前缓存内容并开始新的文本块；若仅为更深层级的子标题，则不立即切分，而是继续在父级主题下聚合内容。这样可以将同一主题下若干较短的小节内容合并为一个较完整的语义单元，避免切分过碎。当缓冲区长度超出阈值时，采用和之前同样的策略，按照语句结束标点切分，并且使两段又一部分重叠的片段，保留上下文的信息。

完成处理后，所有文档都统一保存为 JSON 格式，每个文本块包含 chunk_id、source、category、headings 和 content 等字段，方便后续对检索结果的溯源。

3.1.4Embedding 向量化表示

文本切分完成之后，知识库里的每个文本块都还需要经过一步转换，变成能够支持语义检索的向量表示。Embedding 模型会把离散文本映射到一个统一的高维语义空间中，使语义相近的文本在向量空间中的距离更近，从而支持后续基于相似度的向量检索。

本系统采用 BGE 系列 Embedding 模型对医学文本块进行向量化处理。BGE 模型具有较好的中文语义表示能力，能够较好地适应医学问答场景中常见的疾病名称、症状描述、用药建议以及生活化表达等多种文本形式。在知识库构建阶段，系统使用 BGE 模型对切分后的 chunk 逐条编码，生成对应的稠密向量；在在线检索阶段，则对用户问题执行相同的编码操作，并通过计算问题向量与知识块向量之间的相似度来完成召回。

Embedding 向量化的意义在于，它把知识库的检索方式从单一依赖关键词匹配，转变成了兼具基于语义理解进行检索的能力；针对医学问答中大量存在的同义表达、口语化描述和隐含问题，这种向量化表示正是扩大召回覆盖面、增强检索稳健性的关键基

础。

3.1.5 向量数据库构建

在获得文本块的向量表示后，还需要构建能够支持高效近邻检索的向量数据库或向量索引结构。若仅对全部向量进行线性遍历比对，在知识规模增长后会显著增加检索开销，难以满足在线问答场景对响应速度的要求。因此，知识库构建不仅包括文本组织和向量生成，也包括向量检索结构的建立。

本系统采用 FAISS 构建医学知识库的向量索引，把每个文本块向量与它对应的原文内容、标题路径和来源信息建立起映射关系，这样在向量检索时系统既能快速获得与查询最相近的文本块，又能把结果回溯到原始文本内容和来源元数据，为后续的证据展示与可解释性分析提供支撑。

3.2 医学文本检索方法

3.2.1BM25 关键词检索原理

BM25 是一种比较经典的关键词检索模型，主要根据查询词在文档中的出现情况来计算相关性，因此更适合处理以词面匹配为主的检索任务。对于查询 q 和文档 d，它的得分公式可以写作

$$\mathrm{score}(q,d)=\sum_{t\in q}\mathrm{idf}(t)\cdot\frac{f(t,d)\cdot(k_1+1)}{f(t,d)+k_1\cdot(1-b+b\cdot\frac{|d|}{\mathrm{avgdl}})} \qquad \text{(公式 3.1)}$$

式中，$f(t,d)$ 表示词项 t 在文档 d 中的出现次数，$\mathrm{idf}(t)$ 表示逆文档频率，$|d|$ 表示文档长度，avgdl 表示平均文档长度，k_1 和 b 则用来控制词频影响和长度归一化程度。

在医学问答场景里，疾病名称、药物名称、检查指标和各类专业术语往往具有很强的区分作用，而 BM25 正好比较擅长保留这类关键词信息，所以在精确匹配方面表现比较稳定。它的不足也很明显，就是对同义表达、口语化提问和更深一层的语义关系不够敏感，因此只依赖 BM25 时，系统容易漏掉一些意思接近但表述不同的内容。

3.2.2 向量检索原理

向量检索的思路和关键词检索不同，它不是直接看词是否匹配，而是先借助嵌入模型把用户问题和文档内容都表示成向量，再放到同一个语义空间中进行比较，语义越接近，向量之间通常也越接近，系统就更容易把对应文本检索出来。本文选用 BGE-M3 作为嵌入模型，并把知识库中的每个文本块编码成稠密向量，再写入 FAISS 索引中保存。

在相似度计算方面，常见方法主要有余弦相似度和内积两种形式，当向量完成归一化以后，这两种做法在效果上可以看作基本一致。结合工程实现需求，本文在 FAISS 中采用内积检索方式，也就是 `IndexFlatIP`，这样既能保持较高的检索效率，也能较好反映语义层面的接近程度。

和关键词检索相比，向量检索更擅长处理同义表达、上下位概念以及长句语义理解这类问题，比如提问方式发生变化以后，它仍然有可能找到意思接近的文本。不过，它对局部关键词的约束相对较弱，有时会召回语义上看起来相关、但关键实体并不一致的文本片段。医学问答对术语准确性要求较高，所以只依靠向量检索也很难保证结果始终稳定，通常还需要和关键词检索配合使用。

3.2.3 混合检索策略

为兼顾“术语精确匹配”与“语义泛化召回”两个目标，本文采用 BM25 与向量检索的混合策略，并设计了一条“双路召回到融合排序再到重排精筛”的处理流程：

第一步，系统让两种检索逻辑各自独立地从知识库中检索出各自认为最相关的候选文档列表，形成两路结果；第二步，对这双路结果执行融合排序，采用的算法是倒数排序融合，它的计算形式可以写作：

$$RRF(d) = \sum_{r \in R} \frac{1}{k + r(d)} \qquad \text{(公式 3.2)}$$

其中 R 代表参与融合的各路排序列表的集合，r(d) 表示某篇文档 d 在对应列表中的排列位次，k 是一个用来平滑结果的常数，本系统取 k=60，这个公式综合了一篇文档在不同排序列表中的名次信息，名次越靠前最终得分越高；第三步，融合出统一的候选列表后，再引入 BGE-Reranker-v2-M3 的专门重排模型，对候选文档进行交叉编码式的高精度重排，最终截取出靠前的 Top-K 份证据。

与单用一种检索方式相比，混合策略有几方面的好处：第一，BM25 防止了关键专业术语不会因为语义而无法被准确检索；第二，向量检索弥补了同义改写和口语表达的语义召回盲区；第三，重排模型进一步提升了最终送去给生成模型用的证据的相关性，有效滤掉那些“初看沾边但不支持直接做答”的噪声片段；这样的组合策略，在同一套检索链路里同时回应了医学问答对“高召回”和“高精度”的双重严苛要求。

3.2.4 实验与结果分析

为了验证不同检索方法在医学知识库中的实际召回效果，本文围绕已经构建完成的 FAISS 索引开展了检索实验。实验中，先从知识库里随机抽取 60 个文本段，再根据这些文本段的内容人工设计相关问题，每个问题都对应一个预期命中的目标文本块，只要这个目标文本块出现在前 K 个检索结果中，就记作一次命中。本文选用 Recall@1、Recall@5 和 Recall@10 作为评价指标，用来衡量系统在只返回 1 条、前 5 条和前 10 条候选结果时的召回能力。

实验共比较了三种检索方式，一种是基于 BM25 的关键词检索，一种是基于 BGE 向量表示和 FAISS 索引的向量检索，另一种是本文采用的混合检索策略，也就是先结合

BM25 和向量检索进行双路召回，再通过 Reranker 完成重排，最后给出排序结果。三种方法的实验结果如表 3.1 所示。

表 3.1 RAG 检索方法 Recall@*K* 对比结果

检索方法	Recall@1	Recall@5	Recall@10
BM25 检索	0.26	0.81	0.92
向量检索	0.48	0.81	0.85
混合检索 + Rerank 重排	0.59	0.89	0.96

从实验结果来看，三种检索方法在不同 *K* 值下表现出比较明显的差异。先看 Recall@1，BM25 检索为 0.26，说明如果系统只返回首条结果，只依靠关键词匹配很难稳定命中目标文本；向量检索的 Recall@1 提升到 0.48，说明语义检索对口语化表达、近义改写和不完全词面匹配的问题有更好的适应能力；混合检索结合 Rerank 重排以后，Recall@1 进一步提升到 0.59，是三种方法中最高的。这说明在最靠前的排序位置上，混合检索策略更容易把真正相关的证据提前放出来。

再看 Recall@5，BM25 检索和向量检索都达到 0.81，混合检索则提升到 0.89。这说明当候选范围扩大到前 5 条时，单一检索方法已经能够召回大部分相关文本，但仍然会出现一定程度的漏召回；相比之下，混合检索同时利用了关键词匹配和语义匹配两类信息，又经过重排模型进一步筛选，因此在前 5 条结果里保留了更多有效证据。对 RAG 系统来说，这一点很重要，因为生成模型通常不会使用过多检索结果，如果前几条证据质量不够高，最终回答质量也会直接受到影响。

最后看 Recall@10，BM25 检索达到 0.92，高于向量检索的 0.85，这说明当候选集合进一步放宽以后，BM25 在专业术语、数字指标这类关键词层面的覆盖能力会更明显，更容易把目标文本放进较长的候选列表里。不过，混合检索加 Rerank 重排的 Recall@10 仍然达到 0.96，依然是三种方法中最好的结果。这说明混合检索并不是简单把两种方法拼在一起，而是在不同检索机制之间形成了比较明显的互补关系，BM25 负责尽量保住专业术语、药物名称和指标数值这类关键信息不被漏掉，向量检索负责补足语义层面的相似表达，重排模型再进一步减少“看起来相关、但并不是最佳证据”的干扰。

综合来看，单独使用 BM25 更适合术语比较明确的问题，但对自然语言表达变化会更敏感；单独使用向量检索在语义匹配上更有优势，不过在一些依赖精确术语和细粒度实体区分的问题上，仍然可能出现误召回。相比之下，混合检索结合重排策略在 Recall@1、Recall@5 和 Recall@10 三个指标上都取得了最好结果，说明这种方法更适合医学问答场景中“专业术语精确匹配”和“自然语言语义召回”同时存在的需求。因此，本文最终选择混合检索加 Rerank 重排作为 RAG 问答系统的默认检索方案。

3.3 RAG 问答生成方法

3.3.1 检索—增强—生成流程

RAG 问答生成的核心流程可以概括为“检索—增强—生成”三个环节：先从用户输入的问题出发构造检索查询，在医学知识库里把与之相关的候选文本召回来，这一步解决的是回答依据从哪里来的问题；接着对召回的一批候选文本做去重、排序和筛选，挑出最有价值的证据组合成增强上下文，这一步处理的是哪些证据最值得交给模型去参考的问题；最后把用户问题和增强后的证据上下文一起交给大语言模型，由模型将这些证据转化为用户可以理解的自然语言回答。通过这样一条链路，模型的输出就不再单纯依赖存留在参数里的记忆，而是建立在外部知识的支撑之上，从而让回答的准确程度与内容可追溯程度都得到提升。

3.3.2Prompt 与上下文构建

为了让模型生成的回答更符合医学问答场景的要求，本文把 Prompt 设计和上下文构建放在同一个流程里统一处理，而不是把两者分开。系统送入大语言模型的内容主要包括三部分，一部分是系统提示词，用来明确模型的角色定位和回答原则，一部分是必要的历史对话信息，用来支持多轮问答中的语义衔接，另一部分是当前用户问题和检索得到的外部证据，用来约束模型在生成时优先依据可以核对的资料作答。这样组织输入内容，主要是为了减少没有依据的扩展，让模型输出尽量建立在检索证据和医学常识的共同基础上。

如图 3.1 所示，系统提示词先把模型设定为“严谨、审慎的医疗问答助手”，并明确要求它优先依据检索资料回答问题。在回答规则上，提示词进一步限制模型不能编造和资料内容或医学共识相矛盾的信息，还要求模型先判断检索资料和问题之间的相关程度，再决定是以资料为主进行回答，还是结合通用医学知识作适当补充；如果问题本身比较宽泛，就先给出简要概述，再围绕检索证据展开重点说明，回答形式也要尽量清楚、具体、容易理解。对于治疗和用药这类更敏感的问题，系统还要求模型避免给出过于绝对的建议，如果缺少年龄、体重、肝肾功能、合并用药和过敏史等关键信息，就要主动提示补充；如果问题中出现胸痛、呼吸困难、意识改变、持续高热或明显出血等急危重症信号，则应优先建议立即线下就医或进行急诊处理。这样设计 Prompt，不只是告诉模型要回答什么，更重要的是限制模型该怎样回答，以及回答应当控制在什么边界内。

3.4 基于 DPO 的模型优化方法

3.4.1 偏好数据构建

为了让模型在医学问答场景中输出更稳健的回答，本文构建了用于 DPO 训练的偏好数据。偏好数据的核心不是单条“标准答案”，而是同一问题下的“较优回答”和“较差回答”对比。这样，模型学习的不只是内容对错，还包括表达方式是否审慎、结构是

```
DEFAULT_SYSTEM_PROMPT = (
    "你是一名严谨、审慎的医疗问答助手。\n\n"
    "请优先基于“检索资料”回答问题，并结合必要的医学常识进行补充说明，以确保回答完整、准确。\n\n"
    "要求：\n"
    "1. 不得编造与资料或医学共识相矛盾的内容。\n\n"
    "2. 请判断检索资料与问题的相关性：\n"
    "- 若高度相关：以资料为主回答。\n"
    "- 若部分相关：结合资料与医学常识补充。\n"
    "- 若相关性较低：以通用医学知识为主，并说明“检索资料未充分覆盖该问题”。\n\n"
    "3. 若问题较宽泛（如疾病名称）：\n"
    "- 先进行简要概述（定义/常见表现）。\n"
    "- 再结合检索资料重点展开。\n\n"
    "4. 回答使用markdown格式，内容应清晰、具体、通俗易懂。\n\n"
    "5. 涉及治疗或用药时：\n"
    "- 避免给出绝对化或个体化用药方案。\n"
    "- 若缺少年龄、体重、肝肾功能、合并用药、过敏史等关键信息，应先提示补充。\n\n"
    "6. 若出现急危重症信号（如胸痛、呼吸困难、意识改变、持续高热、明显出血等），应优先建议立即线下就医或急诊。\n\n"
    "7. 当检索资料不足以完整回答问题时：\n"
    "- 可以基于通用医学知识进行补充。\n"
    "- 并适当说明信息来源类型（如“通用医学知识”）。"
)
```

图 3.1 系统提示词

否清晰、风险提示是否充分。

在具体构建中，优选回答通常具备以下特征：能够围绕问题核心作答，尽量依据医学常识或检索证据展开，表达清楚且不过度推断；非优选回答则保留一些常见缺陷，例如结论泛化、依据不足、忽视风险提示或语言组织较弱。通过这种成对设计，偏好数据更接近医学问答中的真实评价标准。

在用户输入侧，系统采用较为固定的组织格式，将当前问题和检索证据封装为统一文本。其中，用户问题以“问题：”字段引出；若存在检索结果，则继续追加“检索资料：”字段，并将检索证据整体附在其后。对于多轮对话场景，系统会在当前用户输入之前插入经过清洗后的历史消息序列，仅保留角色合法且内容有效的最近若干轮消息，并对连续同角色消息进行合并，以减少噪声上下文对生成的干扰。这样的组织方式既保持了对话输入格式的一致性，也使模型能够明确区分“历史对话”“当前问题”和“外部证据”三类信息。

在检索证据的构建上，系统对重排后的候选文档按相关性顺序逐条组织，每条证据均采用统一格式表示为“编号 + 来源 + 标题 + 内容”。这种结构化的输入方式，模型不仅能够利用正文内容，还能够同时利用来源信息和标题路径辅助判断证据的主题归属。

最终，系统将“系统提示词 + 历史对话 + 问题 + 检索资料”共同输入模型，实现面向医学 RAG 场景的统一 Prompt 构建。

3.5 基于 DPO 的模型优化策略

为了进一步提高大语言模型在医学问答场景中的回答质量和安全性，本文在检索增强生成之外，又引入了直接偏好优化（Direct Preference Optimization，DPO）方法对模型进行调整。它的基本做法是，在相同输入条件下准备一组回答对，其中一条回答质量更高，记为 chosen，另一条回答相对较差，记为 rejected，然后让模型在对比学习中逐步学会更偏向前一种输出，从而生成更符合实际使用需求的结果。

3.5.1 偏好数据构建

偏好数据的构建，是 DPO 训练能否发挥作用的重要基础。本文选用了 cMedQA v2.0 和 Huatuo-26M 两个中文医疗问答数据集，前者包含 10 万多个问答对，覆盖疾病、症状和治疗方法等多类医学知识，后者规模更大，约有 2600 万个问答对，而且其中大部分内容来自真实医疗咨询场景，因此和实际问答中的表达方式更接近。

在这两个数据集中，本文先筛选出和“三高”相关的问题，再对重复内容进行去重，最终得到 6351 条问答数据。在此基础上，又继续挑选出那些更容易产生歧义，或者更容易引发模型幻觉的问题样本，最后整理出 431 个具有代表性的偏好数据问题。

在具体构造过程中，本文借助高质量大语言模型生成偏好数据对，也就是 Chosen-Rejected 回答对，同时再引入评估模型对生成结果进行筛选和比较，用这种方式提高数据对的可靠性和区分度。

一是优质回答，也就是 Chosen 回答的生成，这部分提示词设计与 3.3.2 节保持一致，这样训练阶段和实际使用阶段的提示环境能够尽量统一；二是劣质回答，也就是 Rejected 回答的生成，本文通过提示词引导模型产出“表面上看起来合理、但实际存在缺陷”的回答，并有意识地加入几类常见问题，比如对不确定结论表达得过于肯定、忽略检索资料中的关键细节、缺少必要的安全提示，或者回答内容过于空泛，不过同时也会控制负样本不要出现明显错误或极端不安全内容，使它仍然停留在“容易混淆”的合理范围里，这样更有利于偏好学习；三是偏好对的筛选和质量控制，在得到候选正负回答后，再由另一个评估模型从事实一致性、安全性、相关性、完整性和表达清晰度等角度进行比较，只保留优劣关系比较明确的样本对，用于后续 DPO 训练。

最终，DPO 训练数据按三元组形式组织，也就是（prompt，chosen，rejected），其中 prompt 表示用户问题，chosen 表示质量更高的回答，rejected 表示相对较差的回答。

3.5.2DPO 训练流程

本文基于 TRL 框架完成 DPO 训练，并结合 LoRA 参数高效微调方法对 Qwen 基础模型进行优化，目标是进一步提升模型在医学问答任务中的回答质量、安全性和场景适配能力。由于基础模型参数规模较大，如果直接进行全参数训练，显存占用和训练成本都会明显增加，因此本文采用 LoRA，只在部分关键模块中加入可训练的低秩参数，这

样既能控制训练开销，也能完成较有效的模型调整。

训练时，模型以偏好数据三元组作为输入，通过比较同一个问题下的优选回答和非优选回答，逐步学习更符合人工偏好的输出分布。考虑到单张 RTX 4090 显卡只有 24G 显存，本文使用 bitsandbytes 库对模型进行 4-bit 量化加载，用来降低模型占用；训练过程中再配合小批量训练和梯度累加策略，在有限显存条件下尽量接近较大批量的训练效果；同时加入 warmup 机制，并设置合适的 DPO 偏好强度系数，以保持训练过程更稳定。

训练中使用的主要超参数如表 3.1 所示。

表 3.2 DPO 训练主要超参数

超参数	取值	作用
learning_rate	10^{-5}	学习率
lora_r	16	低秩矩阵的秩
lora_alpha	32	LoRA 缩放系数
batch_size	2	批大小
gradient_accumulation_steps	2	梯度累加步数
beta	0.1	DPO 偏好优化强度系数
warmup_ratio	0.03	学习率 warmup 比例

3.5.3 实验结果分析

为了验证 DPO 优化对医学问答质量带来的实际影响，本文采用盲测方式，对基础模型和 DPO 优化后的模型进行对比评估。评测样本共 138 组，评价维度包括 Factual Correctness、Safety、Semantic Relevance、Completeness、Clarity 和 Boundary Awareness，并在这些维度基础上给出 Overall Score。为了减少主观偏差，评测时隐藏了模型身份，只根据回答内容进行判断。

从整体结果来看，DPO 优化后的模型在 138 组样本中获胜 76 次，基础模型获胜 62 次，没有出现平局，DPO 模型在非平局条件下的胜率为 53.15%。这个结果说明，经过偏好优化后，模型的整体回答质量确实优于基础模型，不过这种优势并不是非常悬殊，而是更多体现在多数样本中的稳定小幅提升，具体结果如表 3.2 所示。

表 3.3 DPO 模型与基础模型总体对比结果

评测样本数	基础模型胜出	DPO 模型胜出	平局	DPO 胜率
138	62	76	0	53.15%

如果继续看多维指标的均值，可以发现 DPO 模型在综合得分 Overall Score 以及六个评价维度上都高于基础模型，这说明它的优化效果有一定一致性，并不是只在某一个指标上出现改善。为了更完整地展示实验结果，表 3.3 同时列出了基础模型均值、DPO 模型均值以及二者差值。其中，综合得分 Overall Score 由 9.188811 提升到

9.265734，增加了 0.076923；在各项指标中，信息完备性 Completeness 由 4.517483 提升到 4.615385，增加 0.097902，事实正确性 Factual Correctness 由 4.699301 提升到 4.762238，增加 0.062937，这两个指标的变化最明显。这个结果说明，DPO 训练在一定程度上增强了模型围绕问题中心组织回答的能力，也减少了回答内容缺漏和事实表述不够严谨的情况。相比之下，语义相关性 Semantic Relevance、表达清晰性 Clarity 和边界感知能力 Boundary Awareness 的提升幅度相对较小，这也说明基础模型在这些方面原本就有一定基础，而 DPO 优化更明显的作用，主要体现在对回答细节质量的修正和稳固上，完整结果如表 3.3 所示。

表 3.4 DPO 模型与基础模型多维评分完整统计结果

评价维度	基础模型均值	DPO 模型均值	差值（DPO-基础）
Overall Score	9.188811	9.265734	0.076923
Factual Correctness	4.699301	4.762238	0.062937
Safety	4.741259	4.769231	0.027972
Semantic Relevance	4.972028	4.979021	0.006993
Completeness	4.517483	4.615385	0.097902
Clarity	4.944056	4.958042	0.013986
Boundary Awareness	4.685315	4.699301	0.013986

结合具体评测样本来看，DPO 模型的优势主要表现在回答更完整、表达更审慎，而且在解释检查指标、并发症风险和生活方式干预时，更容易围绕核心问题展开。例如，在肾功能指标解读、糖化血红蛋白判断和代谢异常风险说明等问题上，DPO 模型通常能够补充更关键的判断依据，使回答更接近医学问答场景中“有结论、有限定、有解释”的表达要求。

不过也需要看到，DPO 优化并没有从根本上消除医学问答中的全部风险。在部分样本里，DPO 模型仍然会出现事实判断不够准确、关键风险提示不足，或者边界把握不够稳妥的问题，这说明偏好优化虽然能改善模型的输出倾向，但最终效果仍然会受到训练数据质量、偏好样本覆盖范围以及基础模型能力上限的共同影响。因此，DPO 更适合作为提升回答质量的重要手段，而不能替代医学知识检索、证据约束和人工安全规则等其他机制。

总体来看，本实验表明，在 RAG 框架基础上引入 DPO 优化后，模型在医学问答任务中的综合表现得到了一定提升，尤其是在 Completeness 和 Factual Correctness 两个方面改善更明显。这说明偏好优化确实能够帮助模型更好地学习医学问答场景中什么样的回答更合适，也为系统在真实应用中的稳定输出提供了进一步支持。

4 系统设计与实现

4.1 系统设计目标

针对“三高”慢性病医学问答场景中专业信息较多、回答可靠性要求较高、交互反馈也比较明显的特点，本文设计并实现了一套基于检索增强生成的智能医学问答系统，并结合医学问答任务本身的需求，提出了四个方面的系统设计目标。

一是准确性，医学问答系统首先要尽量保证回答内容科学、准确，因为医学知识本身专业性很强，一旦出现错误或表述不严谨，就可能误导用户，甚至带来潜在风险。为了解决这个问题，系统构建了较高质量的“三高”慢性病医学知识库，并采用关键词检索和语义向量检索结合的混合检索策略，从权威资料中找出和用户问题高度相关的医学证据，再借助 RAG 机制把这些证据送入大语言模型作为回答依据，从而减少模型凭空编造内容的情况，提高回答的事实一致性和专业可靠性。

二是可解释性，和通用问答系统相比，医学问答不只是给出结论，还要让使用者看清结论依据来自哪里。基于这一点，系统在生成回答时，会同时保留并展示相关医学证据的来源信息，比如指南、科普文章或其他参考资料，通过“回答正文加引用来源”的形式，让结论来源能够被进一步追溯；同时，系统也会在提示词设计中对模型输出加入结构化约束，引导生成内容尽量围绕检索到的证据展开，从而进一步增强结果的可解释性。

三是实时性，在实际使用过程中，用户通常希望较快得到问答结果，因此系统需要具备较好的响应速度。考虑到大语言模型推理本身计算开销较大，系统将模型部署在高性能服务器上，并加入多种性能优化方式，包括利用向量检索加快知识匹配过程、使用混合精度计算降低推理开销，以及通过键值缓存减少重复计算，从而提升整体生成效率；在系统架构上，系统还采用前后端分离设计，使用户请求能够更快完成处理和返回，以满足实时交互的需要。

四是可扩展性，医学知识会不断更新，应用需求也会持续变化，因此系统还需要保留较好的扩展能力。一方面，知识库采用模块化管理方式，支持医学数据的新增、修改和维护，便于后续持续纳入新的医学指南和研究成果；另一方面，系统在架构设计上让知识库、检索模块和生成模型之间保持相对松耦合的关系，使各部分能够独立升级或替换，比如可以在不影响整体结构的情况下更换性能更好的向量模型或大语言模型，这样也能为系统后续的演进和适应能力留出足够空间。

4.2 系统总体架构

本系统整体架构采用分层式设计，将交互逻辑、业务逻辑、模型能力与数据能力进行划分，各模块之间相对独立，能够在一定程度上实现故障隔离。系统架构如图 4.1 所

示，主要由四个层次构成。

前端应用层只承担交互和状态管理，不直接参与模型推理，具体包括用户登录、会话管理、消息渲染、流式展示、引用证据呈现以及管理员知识库入口等功能。

业务服务层基于 Node.js，采用 Express 框架构建统一的 API 网关，用于对外提供服务接口。业务服务层主要负责身份认证与权限控制、会话上下文组织、消息持久化、模型服务编排和知识库维护。

模型推理层是一套独立的 Python 服务，部署在高性能 GPU 服务器上，基于 Flask 框架对外提供接口。该层主要负责向量数据库检索、相关文档重排序、提示词组装、模型推理及流式事件输出。模型服务对外暴露同步与流式两类接口，业务服务可以根据实际场景灵活选择调用方式。将推理服务独立部署后，可在不影响业务 API 的情况下单独升级模型和检索策略。

数据与索引层中使用关系型数据库保存用户、会话、消息与文档元数据；使用 FAISS 向量索引存储医学指南等医学资料，并将文本编码为向量构建索引结构以支持向量检索和 BM25 检索。

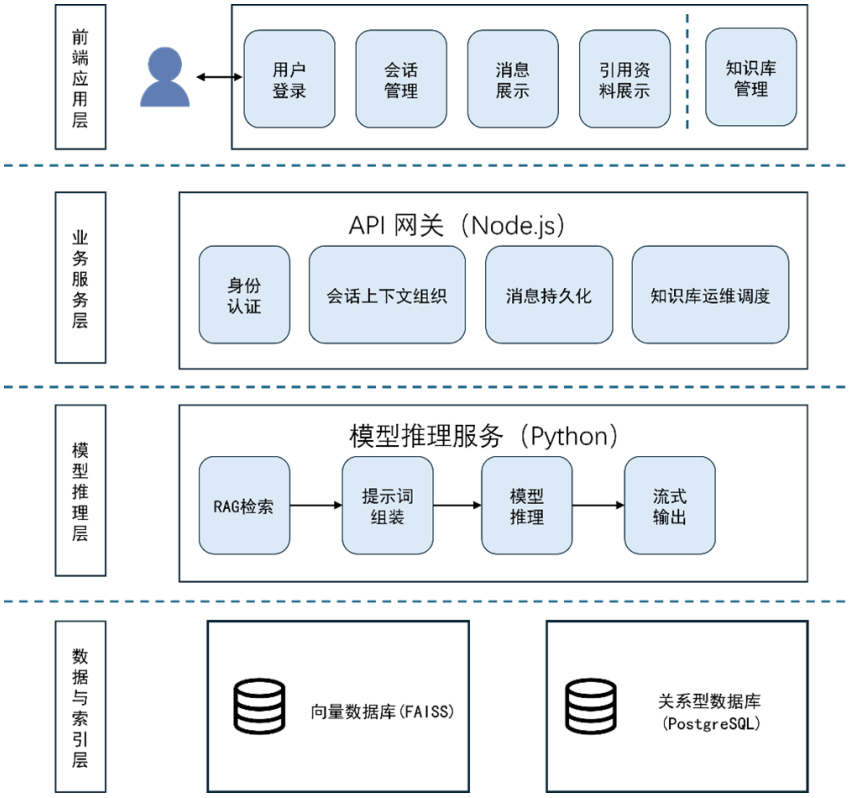

图 4.1 系统架构图

4.3 系统流程设计

在输入解析阶段，系统会先接收用户发来的自然语言问句，再结合之前几轮对话的历史信息对查询做语义补全和规范化处理，从而让后续检索能更精准地锁定用户真正的

意图。

在知识检索阶段，系统采用混合检索策略，一路是基于向量的语义检索，它依靠 Embedding 模型把文本映射到高维的向量空间中来表示语义、捕捉深层的语义相似性；另一路则是基于关键词的 BM25 检索，专门负责精确锁定关键字上的匹配，特别针对于医学领域海量的专业术语。如果只依赖向量检索，有可能会漏掉或误判某些关键医学名词，于是把 BM25 作为补充手段能有效提高整个检索结果的准确度和覆盖面，两路结果检索完成之后，系统再经过融合、排序和重排这几道处理，筛选出最相关的一批文本片段。

在上下文增强阶段，系统将上一阶段筛选出的文本片段，用户问题和对话历史，通过事先设计好的 prompt 模板结合，构建成一份结构清晰的输入，让模型在阅读时能轻易分辨出哪一部分来自使用者的提问、哪一部分是从知识库里调出来的参考资料。

在答案生成阶段，模型依据这份组合好的输入来产出回答，以流式方式逐字输出。在生成全部完成后，系统会把检索到的文献信息返还给用户当成参考，同时也会记录下这次输入和输出所消耗的 token 数量，后者将会跟对话历史一同保存进数据库，为下一次用户提问时构建多轮对话上下文时估算长度提供依据。

4.4 业务层实现

业务层后端服务基于 Node.js 的框架 Express 开发，负责用户身份认证与权限控制、会话管理、消息持久化、模型服务编排与知识库运维接口。

4.4.1 后端服务架构设计

系统后端入口位于统一应用服务中，主要路由模块包括用户认证、会话管理、消息管理、模型调用和知识库管理。各模块职责如下：

(1) 认证模块：提供注册与登录接口，完成密码加密与令牌签发；
(2) 会话模块：管理会话创建、查询、更新与软删除；
(3) 消息模块：管理消息读写与 token 信息回填；
(4) 模型模块：接收问题请求，调用本地模型服务并返回生成结果；
(5) 知识库模块：提供文档元信息管理、索引状态查询与重建能力。

4.4.2 会话管理

会话管理是后端业务逻辑中的核心部分。系统为每个用户维护独立会话空间，并将每轮对话中的角色、正文、时间戳、引用证据和统计信息写入数据库，以支撑历史记录查询和多轮上下文组织。

在具体流程上，当用户提交问题时，后端会先判断当前会话是否存在；若不存在，则创建新会话并写入用户消息；若已存在，则直接在原会话下追加消息。模型返回回答

后，系统再将助手回答与证据一并写回，并同步更新会话摘要和更新时间。这样既能保证多轮对话连续性，也方便前端展示最近会话状态。

4.4.3 数据库

后端数据库使用 PostgreSQL，PostgreSQL 可支持使用“JSONB 内容字段”的存储。在保存用户与模型的对话历史时，用户消息和模型消息、系统消息的结构并不完全相同，例如：模型消息在返回时会携带 RAG 过程中检索到的资料信息，而用户消息则不需要这个字段。面对这类字段需求参差不齐的情况，JSONB 格式比常规的关系型表设计要灵活得多，能很好地应对问答消息里字段不固定、结构可能时常变动的状况。系统将用户、会话、消息等较为固定的实体信息保存在关系型字段里；将消息正文、引用资料信息、Token 消耗等可选字段的内容存放在 JSONB 字段中。通过这一混合存储方式，就能用同一张表适应模型消息和用户消息的不同格式，不必再去为每一种消息单独建表。

表 4.1 中列出了系统中关键的数据表及其主要字段，其中，users 表用于存储用户信息，并且为每个用户分配独特的 id，用户 id 是对其他表查询的关键信息；conversations 表用于存储会话元信息（标题、更新时间、软删除标记等）；messages 表用于保存逐轮对话内容与 token 统计信息；medical_documents 表用于保存知识文档元数据；knowledge_index_meta 表用于记录索引状态（dirty/running/synced/error）。

表 4.1 后端核心数据表

数据表名	核心字段	作用
user	id, password_hash, is_admin	用户身份与权限管理
conversations	user_id, title, last_message, is_deleted	会话元信息管理
messages	conversation_id, role, content, tokens	多轮消息与 token 信息存储
medical_documents	title, source, ingest_key, tags	知识文档元信息维护
knowledge_index_meta	status, last_reindexed_at, last_error	索引状态追踪与运维监控

4.4.4 流式转发

为了缩短用户等待时的空白感，后端加入了面向前端的流式转发机制，Node.js 服务接收到模型服务返回的增量文本后，会继续通过 SSE 把内容持续发送到前端，这样回答还没有完全生成时，界面上就已经能看到文本逐步显示出来，整体交互会更连贯。

具体处理时，后端会先把用户消息和助手占位消息写入数据库，再和模型服务建立流式连接，后续只要模型服务持续返回新的文本片段，后端就会把这些内容整理成前端可以解析的事件数据并立即转发出去；等回答生成结束后，再统一回写完整结果和相关统计信息，这样一来，界面能够及时更新，数据库里保存的内容也能保持完整一致。

4.4.5 知识库管理接口

知识库管理接口主要面向管理员使用，任务是把文档维护和索引管理这一类后台操作组织起来，接口内容包括文档元信息查询、文本上传入库、索引状态查看、增量更新和全量重建等，这样知识库相关操作就能放在统一入口中处理，管理起来也更方便。

在知识入库过程中，后端接收到文本内容和来源信息后，会继续调用后续处理流程，依次完成文本清洗、内容切分、Embedding 编码和索引写入，写入成功以后，再触发模型服务对索引进行热更新；如果中间某个环节出现问题，系统会把错误状态记录下来，并返回较明确的提示信息，方便后面排查和恢复，这样处理之后，知识更新就不再是彼此分散的单独步骤，而是能和在线问答过程更自然地衔接起来。

4.5 模型服务实现

4.5.1Qwen 推理服务

模型服务采用 Python 独立实现，其中 Qwen 推理模块负责最终回答生成。系统启动时加载基础模型和分词器，并根据资源条件选择相应推理方式。问答过程中，模型服务接收后端转发的问题、上下文和参数配置，将其组织为统一输入后交给 Qwen 模型执行生成。

选择 Qwen 作为生成核心，主要考虑其中文能力较强，且能够较好处理长上下文和说明性回答。与 RAG 和 DPO 模块结合后，Qwen 不仅承担“生成文本”的任务，也成为系统将检索证据转化为自然语言答复的关键执行单元。

4.5.2bge Embedding 服务

为支持语义检索，模型服务内部集成 bge Embedding 模型，对用户查询和知识文本进行向量化表示。知识入库阶段，系统对文本块编码并写入向量索引；在线问答阶段，再对用户问题执行同样的编码操作，以完成相似度检索。

Embedding 服务的价值在于，它让系统能够理解不同表述之间的语义接近关系，而不必拘泥于字面一致。对于大量口语化、症状化的慢病咨询问题，这一点尤为重要。

4.5.3DPO 模型加载与推理

除基础 Qwen 模型外，系统还支持加载经 DPO 训练得到的适配权重，以进一步优化医学场景下的回答偏好。部署时，这部分权重通常以适配器形式保存，模型服务按配置完成加载，并与基础模型共同组成最终推理模型。

在实际推理中，DPO 优化不会改变检索结果本身，但会影响模型如何组织回答。例如，当问题涉及治疗建议、用药风险或证据不足时，模型会更倾向于采用审慎表述，并主动提醒线下就医或补充信息。这种变化正是偏好优化在医学场景中的主要价值。

4.5.4 流式输出

模型服务同时支持同步生成和流式生成两种模式。流式模式下，服务会持续返回模型生成的文本片段，使回答具备边生成边展示的效果，从而明显改善交互体验。

在实现上，模型服务通过 SSE 事件格式向后端发送 `delta`、`end` 和 `error` 等事件；后端再将这些事件继续转发到前端，形成端到端的流式问答链路。这一设计让系统既能保持低时延反馈，也能在异常情况下提供较清晰的错误处理路径。

4.6 RAG 服务工程实现

4.6.1 检索调用流程

在 RAG 服务运行时，模型服务首先接收用户问题，并结合必要的历史对话构造检索查询。随后，系统并行调用 BM25 和向量检索，分别得到关键词相关候选和语义相关候选，形成双路初召回结果。

完成召回后，系统对候选文本进行统一标识、合并与去重，再进入融合排序和重排阶段。最终保留下来的高质量证据会被组织为结构化上下文，并传递给生成模块。整个流程强调的是“先保证不漏，再尽量选准”。

4.6.2BM25 + 向量融合实现

在工程实现上，BM25 和向量检索保持相对独立的召回路径，系统在候选层面对两类结果进行统一融合。BM25 负责抓住关键术语，向量检索负责补足语义改写，两者组合后能够更稳妥地应对真实问答中的表达差异。

融合时，系统根据候选在不同检索列表中的相对位置综合计算优先级，使在多路检索中都表现靠前的文本获得更高排序。这样做避免了单一路径偏差对最终结果造成过大影响。

4.6.3Rerank 实现

融合后的候选结果仍可能包含主题相关但并不适合直接作答的文本，因此系统进一步引入重排模型进行精筛。与初召回不同，重排阶段更关注“这段文本是否最适合回答当前问题”，而不是“它是否大致相关”。

在实现中，系统逐条计算候选证据与问题之间的匹配程度，并据此重新排序，再从中选出 Top-K 文本作为最终证据。该步骤能够明显降低噪声片段进入生成阶段的概率，是提升回答质量的重要环节。

4.6.4 上下文拼接

在获得最终证据后，系统需要将其组织成模型可直接利用的输入上下文。拼接时，系统会保留证据来源、标题和正文片段，并按相关性顺序写入 Prompt 中，使模型既能

看到内容本身，也能感知其来源背景。

同时，系统会控制证据条数和单条长度，避免长文本挤占过多上下文空间。对于多轮问答，还会加入必要的近期历史消息，以帮助模型更准确地理解当前问题与前文之间的关系。

4.7 前端实现

4.7.1 前端 UI 架构与路由设计

前端界面采用 React 构建，并结合路由机制完成页面切换，整体上分为登录页、注册页、问答主页和知识库管理页，不同页面各自承担明确任务，这样既方便功能拆分，也有利于后续继续补充新模块。登录和注册页面主要处理身份验证，问答主页负责会话列表、消息展示和问题输入，知识库管理页则面向管理员，用来处理文档维护与索引相关操作。

在界面组织上，前端把通用能力拆分到页面、组件和 Hook 三个层次，页面负责整体布局和功能组合，组件负责消息列表、输入框、侧边栏等可复用界面，Hook 负责会话状态、消息请求和交互流程管理，这种划分方式能让界面结构更清楚，代码之间的联系也更容易梳理。主页部分采用侧边栏与主内容区的布局，侧边栏用于展示历史会话和常用操作，主区域用于展示问答内容与输入区域，页面层次比较直观，用户进入系统后也能较快找到对应功能。

4.7.2 对话交互与流式渲染实现

会话相关的核心逻辑集中放在自定义 Hook 中，发送问题时，界面会先把用户消息和助手的占位内容加入当前会话，再向后端发起流式请求，这样用户提交问题后能马上看到界面变化，等待过程也不会显得突兀。流式数据通过后端的 SSE 通道持续返回，前端再用 ReadableStream 按帧读取并解析事件，接收到 `delta` 内容后，就把新增文本接到助手回答后面，于是回答会一点点展开，形成较自然的实时反馈效果。

为了让多轮对话前后保持一致，流式输出结束后，前端还会重新拉取一次消息记录，并用后端已经保存的结果覆盖临时状态，避免在长对话过程中因为局部丢帧或上下文偏移，出现界面显示和实际数据不一致的情况；如果模型服务中途异常或连接中断，界面会直接给出明确的提示文本，使当前交互还能继续恢复，不会停在难以理解的状态里。

4.7.3 消息展示与检索证据可视化

消息展示部分支持 Markdown 和 GFM 语法渲染，因此回答中的分点说明、表格以及部分结构化内容都能较完整地显示出来，页面阅读体验也更清楚。在 RAG 问答场景下，系统会把检索得到的 `retrieved_docs` 附加到助手消息中，再在回答下方用“全部引用”的折叠区域统一展示，这样答案和证据能够放在同一界面里，用户查看结论时

也能顺带看到对应依据，有助于增强结果的可解释性与可追溯性。

为了减少重复信息，前端会按照 source 字段对引用文档进行去重，同时保留来源名称、标题层级等关键内容，便于快速核对回答依据，也便于进一步判断相关结论是否来自较可靠的医学资料，从而提高对系统输出结果的信任程度。

4.8 本章小结

本章从工程实现角度介绍了医学问答系统的整体设计。首先明确了系统在准确性、可解释性、实时性和可扩展性方面的目标；随后说明了总体架构和 RAG 运行流程；最后分别从后端、模型服务、RAG 工程实现和前端交互四个层面展开具体实现分析。

通过上述设计与实现，本文完成了一套具备知识检索、模型生成、证据展示和会话管理能力的医学问答系统，为后续实验评估和应用验证提供了完整工程基础。

5 实验与结果分析

5.1 实验环境

为验证本文所提出医学问答系统在检索与生成两个层面的有效性，本文围绕 RAG 检索效果、DPO 优化效果以及系统整体表现开展实验分析。实验环境覆盖前端、后端、模型服务与数据存储等完整运行链路，以保证实验结果能够反映真实系统使用情况。

在软件环境方面，系统整体采用“React + Node.js + Python”架构实现，后端数据库使用 PostgreSQL 存储业务数据，向量检索采用 FAISS 实现，Embedding 模型采用 bge 系列模型，生成模型采用 Qwen 系列模型，并在此基础上加载 DPO 微调权重进行对比实验。前端用于问答交互与结果展示，后端负责请求调度与结果回写，模型服务负责检索、推理和流式输出。

表 5.1 实验环境配置

类别	配置项	说明
前端环境	React + Vite	用户交互与问答展示
后端环境	Node.js + Express	业务编排与流式转发
模型服务	Python + Flask	模型推理与 RAG 服务
业务数据库	PostgreSQL	用户、会话与消息存储
向量检索	FAISS	知识向量索引与召回
Embedding 模型	bge	医学文本向量表示
生成模型	Qwen + DPO 权重	医学问答回答生成

5.2 评价指标

本文实验从检索质量、回答质量和系统综合表现三个维度进行评价。针对检索实验，重点考察不同检索策略在候选召回和相关性排序上的表现；针对 DPO 实验，重点关注模型回答在医学准确性、幻觉控制和回答稳健性方面的改善情况；针对系统整体效果，则综合考察回答质量、证据展示能力和交互体验。

在检索质量评价中，可采用命中率、召回率和 Top-K 相关性等指标，用于衡量不同检索策略能否有效召回与问题相关的医学文本。对于生成质量评价，本文重点从医学事实一致性、回答完整性、回答可读性以及幻觉程度等角度进行分析。在系统整体效果评价中，还结合流式展示、证据可追溯性和多轮问答体验进行综合观察。

5.3 RAG 检索效果实验

为验证混合检索策略在医学问答场景中的有效性，本文设计了 BM25 检索、向量检索和混合检索三种方案进行对比实验。实验中，从测试问题集合中选取具有代表性的医

学问答样本，将三种方法分别应用于知识库召回过程，并观察其在相关文本召回上的差异。

实验结果表明，BM25 方法在处理疾病名称、药物术语和检查指标等显式关键词时具有较好表现，能够较稳定地命中包含相同术语的文本片段；但当用户问题采用口语化表达或存在同义改写时，BM25 容易出现漏召回。向量检索在语义理解方面更具优势，对于“症状描述—疾病解释”这类词面差异较大但语义相关的问题能够取得更好的召回效果，但在个别情况下也会引入语义相关但实体不完全一致的文本。

相比之下，混合检索策略能够较好综合两者优势。一方面保留 BM25 对关键术语的精确匹配能力，另一方面利用向量检索增强对自然语言表达变化的适应能力，并通过后续融合排序和重排过程进一步提升候选证据质量。因此，在医学问答场景下，混合检索在召回覆盖与最终相关性方面均表现更为稳定。

表 5.2 RAG 检索效果对比

检索方法	关键词命中	语义召回	综合表现
BM25	高	中	对术语敏感，但易漏召回
向量检索	中	高	语义能力强，但实体约束较弱
混合检索	高	高	召回更全面，结果更稳定

5.4 DPO 优化效果实验

为验证 DPO 微调对医学问答生成质量的改善作用，本文设计了“优化前模型”与“DPO 优化后模型”的对比实验。在实验中，保持知识库、检索策略、Prompt 模板和生成参数基本一致，仅替换生成模型为是否加载 DPO 微调权重的版本，从而观察模型回答风格和内容质量的变化。

5.4.1Before vs After 对比

对比结果表明，在相同证据输入条件下，DPO 优化后的模型在回答表达和内容组织上更加稳定。优化前的模型虽然能够给出与问题相关的回答，但在部分情况下存在回答冗长、结构松散或边界不够清晰的问题；优化后的模型则更倾向于采用条理清晰、语气稳健的表达方式，使回答更符合医学问答系统面向普通用户服务的场景需求。

5.4.2 幻觉对比

在幻觉控制方面，优化前模型在面对证据不足、问题含糊或医学判断风险较高的场景时，更容易基于参数记忆进行扩展推断，导致回答中出现缺乏明确依据的内容。加载 DPO 微调权重后，模型在这类问题上表现出更明显的保守倾向，即更愿意依据现有证据回答，并在必要时提示用户进一步咨询专业医生或补充检查信息。由此可见，DPO 优

化对抑制医学问答中的无依据扩展具有积极作用。

5.4.3 医学准确性提升

从医学事实一致性角度看，DPO 优化后的模型在回答中更加贴近检索证据内容，回答中的结论、建议和风险提示与外部知识的一致性更高。这说明 DPO 不仅改善了回答风格，也在一定程度上增强了模型对检索证据的利用方式，使其更倾向于围绕已有依据作答，而非依赖模糊经验性生成。

表 5.3 DPO 优化效果对比

对比维度	优化前	优化后	变化趋势
回答结构	较松散	更清晰	提升
幻觉倾向	相对较高	明显降低	提升
医学一致性	一般	更贴近证据	提升
风险提示能力	偶有不足	更加稳定	提升

5.5 系统整体效果

从系统整体运行效果看，本文设计并实现的医学问答系统能够完成从用户提问、知识检索、回答生成到证据展示的完整闭环。前端支持实时流式渲染和引用证据展示，使用户能够更直观地理解回答及其依据；后端能够稳定完成会话管理、流式转发和结果持久化；模型服务能够在检索增强和 DPO 优化基础上生成较为稳健的医学回答。

综合实验结果可以看出，RAG 机制主要提升了回答的知识支撑能力与可追溯性，DPO 机制则进一步改善了回答的规范性、稳健性与医学场景适配性。二者结合后，系统在专业问答场景中表现出较好的综合效果，说明“RAG + DPO”技术路线具有一定的实践价值。

参考文献

[1] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]. Advances in Neural Information Processing Systems 30 (NeurIPS 2017). 2017: 5998-6008.

谢　辞

在本科四年期间，首先衷心感谢我的导师 XXX 教授